Título del Trabajo de Fin de Grado

Nombre del Autor

19 de enero de 2026

Resumen

Abstract

Agradecimientos

Índice general

Resumen **1**

Abstract **2**

Agradecimientos **3**

1. Introducción y justificación **10**

1.1. Contexto clínico del cáncer de piel 10
1.2. Importancia del diagnóstico precoz en dermatología 10
1.3. Limitaciones del diagnóstico visual tradicional 10
1.4. Aplicación de la inteligencia artificial en dermatología 10
1.5. Motivación del trabajo 10
1.6. Justificación técnica del enfoque propuesto 10
1.7. Justificación académica y social del estudio 10
1.8. Objetivos del trabajo 10
1.8.1. Objetivo general 10
1.8.2. Objetivos específicos 10
1.9. Alcance y delimitaciones del trabajo 10
1.10. Organización de la memoria 10

2. Estado del arte **11**

2.1. Introducción al estado del arte en clasificación de lesiones cutáneas 12
2.2. Métodos clásicos de diagnóstico asistido por ordenador 12
2.2.1. Extracción manual de características 12
2.2.2. Clasificadores tradicionales 12
2.3. Redes neuronales convolucionales en dermatología 12
2.3.1. CNN en clasificación de imágenes médicas 12
2.3.2. CNN aplicadas a lesiones cutáneas 12
2.4. Vision Transformers en visión por computador 12
2.4.1. Fundamentos de los Transformers 12
2.4.2. Aplicaciones de ViT en imagen médica 12
2.5. Modelos híbridos CNNTransformer 12

2.5.1. Motivación del enfoque híbrido 12
2.5.2. Resultados reportados en la literatura 12
2.6. Angular Radial Partitioning en análisis de imagen 12
2.6.1. Fundamentos teóricos del ARP 12
2.6.2. Uso de ARP en reconocimiento de patrones 12
2.7. Aprendizaje multimodal en medicina 12
2.7.1. Fusión de imagen y metadatos clínicos 12
2.7.2. Estrategias de fusión temprana, tardía e intermedia 12
2.8. Problemas abiertos en el estado del arte 12
2.8.1. Desbalanceo de clases 12
2.8.2. Heterogeneidad de bases de datos 12
2.8.3. Riesgos de *data leakage* 12
2.9. Posicionamiento del presente trabajo 12

3. Descripción de los datos **13**
3.1. Introducción a las bases de datos dermatológicas 13
3.2. Base de datos SLICE-3D (ISIC 2024 Challenge Dataset) 13
3.2.1. Descripción general 13
3.2.2. Tipos de imágenes 14
3.2.3. Metadatos clínicos disponibles 14
3.3. Base de datos ISIC Archive 15
3.3.1. Características principales 15
3.3.2. Diferencias respecto a SLICE-3D 15
3.4. Otras fuentes de datos consideradas 15
3.4.1. HAM10000 15
3.5. Análisis del desbalanceo de clases 16
3.6. Distribución de diagnósticos 16
3.7. Heterogeneidad entre fuentes de datos 16
3.8. Metadatos clínicos utilizados 17
3.9. Identificadores clínicos y prevención de *data leakage* 17
3.10. Consideraciones éticas y de uso de datos 18

4. Metodología **20**
4.1. Enfoque general del sistema propuesto 20
4.2. Planteamiento del problema de clasificación 20
4.3. Estrategia multimodal adoptada 20
4.4. Definición del espacio de clases clínicas 20
4.5. Supuestos y restricciones del modelo 20
4.6. Flujo general de procesamiento del sistema 20

5. Descripción del entorno de desarrollo: Python y TensorFlow **21**
5.1. Lenguaje Python para aprendizaje profundo 21
5.2. Librerías utilizadas 21
5.2.1. NumPy y Pandas 21
5.2.2. TensorFlow y Keras 21
5.2.3. Otras librerías auxiliares 21
5.3. Ventajas del uso de TensorFlow en el proyecto 21
5.4. Entorno de ejecución y recursos hardware 21
5.5. Reproducibilidad y control experimental 21

6. Preprocesamiento de los datos **22**
6.1. Introducción al preprocesamiento 22
6.2. Estrategia de fusión de bases de datos 22
6.3. Armonización de columnas y variables 22
6.4. Tratamiento de valores faltantes 22
6.5. Imputación de metadatos clínicos 22
6.6. Normalización y codificación de variables 22
6.7. División de conjuntos de entrenamiento, validación y test 22
6.8. Prevención de patient leakage 22
6.9. Estrategias de balanceo de datos 22

7. Métricas de cuantificación de la capacidad predictiva **23**
7.1. Introducción a la evaluación de modelos 23
7.2. Matriz de confusión 23
7.3. Exactitud (Accuracy) 23
7.4. Sensibilidad (Recall) 23
7.5. Especificidad 23
7.6. Precisión 23
7.7. F1-score 23
7.8. Curvas ROC y AUC 23
7.9. Justificación clínica de las métricas seleccionadas 23

8. Diseño de la red implementada **24**
8.1. Visión general de la arquitectura propuesta 24
8.2. Rama convolucional (CNN) 24
8.3. Rama basada en Vision Transformer 24
8.4. Extracción estructural mediante ARP 24
8.5. Procesamiento de metadatos mediante MLP 24
8.6. Estrategia de fusión multimodal 24
8.7. Cabezas de salida del modelo 24

8.7.1. Clasificación binaria 24
8.7.2. Clasificación multiclase 24
8.8. Funciones de pérdida utilizadas 24
8.9. Estrategia de entrenamiento 24

9. Evaluación, resultados y discusión **25**
9.1. Configuración experimental 25
9.2. Resultados obtenidos 25
9.3. Comparativa entre configuraciones 25
9.4. Impacto de la fusión multimodal 25
9.5. Impacto del desbalanceo 25
9.6. Discusión de resultados 25
9.7. Limitaciones del estudio 25

10. Conclusiones y trabajo futuro **26**
10.1. Conclusiones generales 26
10.2. Contribuciones del trabajo 26
10.3. Líneas futuras de investigación 26

A. Anexos **27**
A.1. Arquitecturas completas 27
A.2. Hiperparámetros 27
A.3. Diagramas adicionales 27

Índice de figuras

Índice de cuadros

Capítulo 1

Introducción y justificación

1.1 Contexto clínico del cáncer de piel

1.2 Importancia del diagnóstico precoz en dermatología

1.3 Limitaciones del diagnóstico visual tradicional

1.4 Aplicación de la inteligencia artificial en dermatología

1.5 Motivación del trabajo

1.6 Justificación técnica del enfoque propuesto

1.7 Justificación académica y social del estudio

1.8 Objetivos del trabajo

1.8.1 Objetivo general

1.8.2 Objetivos específicos

1.9 Alcance y delimitaciones del trabajo

1.10 Organización de la memoria

Capítulo 2

Estado del arte

2.1 Introducción al estado del arte en clasificación de lesiones cutáneas

2.2 Métodos clásicos de diagnóstico asistido por ordenador

2.2.1 Extracción manual de características

2.2.2 Clasificadores tradicionales

2.3 Redes neuronales convolucionales en dermatología

2.3.1 CNN en clasificación de imágenes médicas

2.3.2 CNN aplicadas a lesiones cutáneas

2.4 Vision Transformers en visión por computador

2.4.1 Fundamentos de los Transformers

2.4.2 Aplicaciones de ViT en imagen médica

2.5 Modelos híbridos CNNTransformer

2.5.1 Motivación del enfoque híbrido

2.5.2 Resultados reportados en la literatura

2.6 Angular Radial Partitioning en análisis de imagen

2.6.1 Fundamentos teóricos del ARP

2.6.2 Uso de ARP en reconocimiento de patrones

2.7 Aprendizaje multimodal en medicina

2.7.1 Fusión de imagen y metadatos clínicos

2.7.2 Estrategias de fusión temprana, tardía e intermedia

Capítulo 3

Descripción de los datos

3.1 Introducción a las bases de datos dermatológicas

El desarrollo de sistemas de diagnóstico asistido por ordenador basados en aprendizaje profundo depende de manera crítica de la calidad, validez y representatividad de las bases de datos empleadas. En el ámbito de la dermatología, y en particular en el estudio del cáncer de piel, esta dependencia es aún más acusada debido a la elevada variabilidad morfológica de las lesiones cutáneas y a la baja prevalencia relativa de los casos malignos en la población general.

Para que un modelo de *deep learning* resulte clínicamente relevante, no basta con disponer de un gran volumen de imágenes. Es imprescindible que dichas imágenes estén correctamente anotadas, procedan de fuentes fiables y reflejen de forma razonable la distribución real de las patologías, evitando sesgos sistemáticos que puedan comprometer la capacidad de generalización del sistema. Asimismo, el desbalanceo extremo entre clases, habitual en bases de datos médicas, constituye uno de los principales retos metodológicos, ya que puede conducir a modelos con una alta exactitud global pero una sensibilidad reducida en las clases de mayor interés clínico.

En este contexto, el presente trabajo se apoya en bases de datos públicas ampliamente utilizadas y validadas por la comunidad científica, que se combinan de forma controlada con el objetivo de construir un conjunto de datos robusto, multimodal y adecuado para el entrenamiento y la evaluación de arquitecturas profundas complejas.

3.2 Base de datos SLICE-3D (ISIC 2024 Challenge Dataset)

3.2.1 Descripción general

La principal fuente de datos del presente estudio es la base de datos *SLICE-3D*, proporcionada en el marco del *ISIC 2024 Challenge Dataset*. Este conjunto de datos está compuesto por un total de 401 059 imágenes en formato JPEG, lo que lo convierte en una de las colecciones públicas más extensas disponibles actualmente para el análisis

automatizado de lesiones cutáneas.

Las imágenes incluidas en SLICE-3D han sido recopiladas y anotadas siguiendo protocolos estandarizados, lo que garantiza un alto grado de consistencia y fiabilidad en las etiquetas diagnósticas asociadas. No obstante, al igual que ocurre en la práctica clínica real, la distribución de diagnósticos presenta un desbalanceo muy acusado, con una clara predominancia de lesiones benignas frente a un número considerablemente menor de casos malignos.

En concreto, el conjunto de datos contiene del orden de 400 000 lesiones benignas, mientras que el número de imágenes correspondientes a lesiones malignas es significativamente inferior, representando únicamente un pequeño porcentaje del total. Este desbalanceo refleja fielmente la epidemiología del cáncer de piel, pero introduce importantes desafíos para el entrenamiento de modelos de clasificación basados en *deep learning*, especialmente en términos de sensibilidad y capacidad de detección de las clases minoritarias.

3.2.2 Tipos de imágenes

Las imágenes de SLICE-3D proceden principalmente de sistemas de dermatoscopía digital y de plataformas de *Total Body Photography* (TBP), proporcionando imágenes de alta resolución centradas en lesiones individuales. La variabilidad en las condiciones de adquisición, los dispositivos empleados y las características visuales (iluminación, enfoque, resolución, contraste, etc.) hace que este conjunto de datos resulte especialmente adecuado para evaluar la robustez de modelos de aprendizaje profundo frente a cambios de dominio y escenarios clínicos heterogéneos.

3.2.3 Metadatos clínicos disponibles

Una característica distintiva de SLICE-3D es la disponibilidad de un conjunto amplio y detallado de metadatos clínicos, que incluye variables demográficas, información anatómica y métricas cuantitativas avanzadas derivadas de TBP (`TBP-LV`). Entre estos metadatos se encuentran, de forma general:

- variables demográficas básicas (como edad aproximada y sexo del paciente),
- localización anatómica general de la lesión,
- descriptores cuantitativos relacionados con forma, tamaño, color y asimetría de la lesión.

Estos metadatos aportan información complementaria a la imagen cruda que puede resultar de gran valor para la clasificación clínica, especialmente en contextos de cribado (*screening*) o en escenarios en los que la información puramente visual puede resultar ambigua. En el marco del enfoque multimodal propuesto en este trabajo, estas variables constituyen una fuente adicional de evidencia que puede contribuir a mejorar la capacidad discriminativa del modelo.

3.3 Base de datos ISIC Archive

3.3.1 Características principales

La base de datos *ISIC Archive* constituye un repositorio público de gran escala que agrupa un total de 549 590 imágenes dermatológicas, correspondientes a una amplia variedad de diagnósticos y procedentes de múltiples centros y estudios internacionales.

En el presente trabajo, *ISIC Archive* no se emplea de forma íntegra, sino que se utiliza de manera selectiva y estratégica. Con el objetivo de mitigar el desbalanceo extremo presente en *SLICE-3D*, se seleccionaron 27 084 imágenes correspondientes exclusivamente a casos malignos, incluyendo melanoma, carcinoma basocelular y carcinoma espinocelular.

Esta selección permite reforzar de forma significativa la representación de las clases malignas en el conjunto de datos global, manteniendo al mismo tiempo la coherencia clínica y la fiabilidad de las etiquetas diagnósticas. De este modo, *ISIC Archive* actúa como una fuente complementaria esencial para equilibrar el conjunto de entrenamiento sin introducir ruido innecesario ni comprometer la validez de los experimentos.

3.3.2 Diferencias respecto a SLICE-3D

Las principales diferencias entre ISIC Archive e ISIC Slice 3D son:

- **Distribución de clases**: ISIC Archive contiene únicamente lesiones malignas, mientras que Slice 3D incluye mayoritariamente lesiones benignas.
- **Riqueza de metadatos**: ISIC Archive dispone de un número menor de variables clínicas y descriptivas.
- **Rol en el estudio**: ISIC Archive se emplea como fuente estratégica para incrementar la presencia de lesiones malignas y reducir el desbalanceo de clases del conjunto global.

Estas diferencias motivan la adopción de estrategias específicas de fusión y tratamiento de datos, que se describirán en capítulos posteriores.

3.4 Otras fuentes de datos consideradas

3.4.1 HAM10000

La base de datos *HAM10000* fue analizada de forma preliminar como posible fuente complementaria. Sin embargo, se decidió no integrarla en la fase principal del estudio debido a diferencias en los criterios de anotación y a la existencia de solapamientos conceptuales con las bases ISIC, que podrían complicar la armonización de datos sin aportar un beneficio proporcional en términos de diversidad o volumen efectivo.

3.5 Análisis del desbalanceo de clases

Uno de los principales retos identificados es el desbalanceo severo entre lesiones benignas y malignas, especialmente en ISIC Archive. Mientras que las lesiones benignas superan ampliamente las 400 000 muestras, los casos malignos representan una fracción muy reducida del conjunto total.

Este desbalanceo condiciona tanto el diseño del modelo como la selección de métricas de evaluación, haciendo necesario priorizar la sensibilidad y la capacidad de detección de casos malignos frente a la mera exactitud global.

3.6 Distribución de diagnósticos

Con el fin de unificar los diagnósticos heterogéneos presentes en las distintas fuentes, se definió un espacio de clases clínicas común compuesto por las siguientes categorías:

- **BEN**: lesiones benignas (nevus y otros diagnósticos no malignos).
- **MEL**: melanoma.
- **BCC**: carcinoma basocelular.
- **SCC+**: carcinoma espinocelular y lesiones precursoras (queratosis actínica, queratoacantoma).

Esta categorización busca equilibrar la coherencia clínica con la viabilidad estadística, evitando una fragmentación excesiva de las clases que pudiera dificultar el entrenamiento y la interpretación de los modelos.

3.7 Heterogeneidad entre fuentes de datos

La combinación de múltiples bases de datos introduce heterogeneidad en términos de:

- protocolos de adquisición de imagen,
- calidad y resolución de las imágenes,
- disponibilidad y formato de los metadatos,
- criterios diagnósticos empleados por los distintos centros.

En lugar de eliminar esta heterogeneidad mediante filtrado agresivo, el presente trabajo adopta un enfoque de armonización controlada. El objetivo es preservar la máxima cantidad de información posible, al tiempo que se unifican los aspectos clave necesarios para el entrenamiento de modelos multimodales capaces de aprender patrones invariantes a las diferencias entre fuentes.

3.8 Metadatos clínicos utilizados

El tratamiento de los metadatos clínicos constituye un elemento central del enfoque multimodal propuesto en este trabajo. Durante el análisis de las bases de datos disponibles se observó que la información clínica no estaba distribuida de forma homogénea entre las distintas fuentes, tanto en términos de variables disponibles como de grado de completitud.

En particular, *SLICE-3D* es la única base de datos que contiene metadatos avanzados derivados de *Total Body Photography* (TBP-LV), mientras que los casos seleccionados de *ISIC Archive* carecen de este tipo de variables. Dado el alto valor informativo potencial de las características `TBP-LV`, se consideró inadecuado descartarlas por completo en el diseño experimental.

Por este motivo, se definieron dos configuraciones experimentales diferenciadas para el uso de metadatos:

Plan A: utilización de todos los metadatos disponibles en *SLICE-3D*, incluyendo las variables avanzadas `TBP-LV`. Esta configuración explota al máximo la riqueza informativa de la base de datos principal, a costa de reducir la compatibilidad directa con otras fuentes.

Plan B: utilización exclusiva de metadatos clínicos comunes a todas las bases de datos consideradas, excluyendo explícitamente las variables `TBP-LV`. Esta configuración garantiza la comparabilidad entre fuentes, aunque con un conjunto de variables más limitado.

Esta estrategia permite evaluar de forma controlada el impacto de los metadatos ricos frente a configuraciones más generales, ofreciendo una comparación directa entre modelos entrenados con información clínica avanzada y modelos basados únicamente en variables clínicamente relevantes pero ampliamente disponibles (por ejemplo, edad aproximada, sexo o localización anatómica general).

Adicionalmente, debido al fuerte desbalanceo de clases presente en *SLICE-3D*, se decidió combinar esta base de datos con aproximadamente 27 000 imágenes malignas procedentes de *ISIC Archive*, reforzando así la representación de las clases de mayor interés clínico. Esta combinación se integró de forma coherente con las configuraciones de metadatos descritas, de modo que los experimentos pudieran analizar de forma conjunta el efecto del enriquecimiento de clases y el papel de la información clínica estructurada.

3.9 Identificadores clínicos y prevención de *data leakage*

Para garantizar la validez experimental del estudio y evitar fugas de información entre los conjuntos de entrenamiento, validación y prueba, resulta fundamental analizar en detalle la estructura de los identificadores presentes en las bases de datos empleadas.

En general, las imágenes pueden estar asociadas a distintos tipos de identificadores:

- **Patient ID**: identifica de manera única a un paciente, que puede presentar una o varias lesiones.
- **Lesion ID**: identifica una lesión concreta, que pertenece a un único paciente pero puede estar representada por múltiples imágenes.
- **Identificador de imagen**: referencia una captura específica de una lesión determinada.

Esta estructura implica que no todas las imágenes son independientes entre sí. Un mismo paciente puede presentar varias lesiones, y una misma lesión puede estar representada por múltiples imágenes, lo que da lugar a grupos de datos altamente correlacionados. Si estos grupos se reparten de forma inadecuada entre los diferentes subconjuntos, se corre el riesgo de introducir *data leakage*, inflando artificialmente las métricas de rendimiento del modelo.

Durante el análisis preliminar se observó que la existencia de pacientes con múltiples lesiones y lesiones con múltiples imágenes daba lugar a grupos de tamaño elevado, lo que dificultaba la división equilibrada del conjunto de datos manteniendo, al mismo tiempo, la independencia entre los subconjuntos de entrenamiento y validación.

Para resolver este problema, se definió un identificador unificado denominado `master_group_id`, construido siguiendo las reglas que se detallan a continuación:

1. Si **Patient ID** y **Lesion ID** están presentes, el `master_group_id` se define a partir de la combinación de ambos identificadores, de forma que todas las imágenes correspondientes a una lesión concreta de un paciente queden agrupadas.
2. Si **Patient ID** es nulo pero **Lesion ID** no lo es, se utiliza directamente el **Lesion ID** como `master_group_id`.
3. Si **Lesion ID** es nulo pero **Patient ID** está disponible, se utiliza el **Patient ID** como `master_group_id`.
4. Si ambos identificadores son nulos, se asigna un identificador único por imagen, de modo que cada muestra forme un grupo independiente.

Este enfoque garantiza que todas las imágenes pertenecientes a un mismo paciente o a una misma lesión se asignen siempre al mismo subconjunto de datos (entrenamiento, validación o prueba), evitando *patient leakage* y asegurando una evaluación experimental rigurosa y realista del rendimiento de los modelos.

3.10 Consideraciones éticas y de uso de datos

Todas las bases de datos utilizadas en este trabajo son de acceso público y han sido anonimizadas por sus autores originales. No se dispone de información identificable de pacientes y el uso de los datos se realiza exclusivamente con fines académicos y de investigación, respetando las licencias y condiciones de uso establecidas por ISIC y por los repositorios correspondientes.

Además, se han adoptado medidas específicas para prevenir fugas de información entre

los conjuntos de entrenamiento, validación y prueba. En particular, se ha prestado especial atención a la separación de imágenes pertenecientes a un mismo paciente, con el objetivo de garantizar la validez experimental de los resultados y evitar una sobreestimación artificial del rendimiento de los modelos.

Capítulo 4

Metodología

4.1 Enfoque general del sistema propuesto

4.2 Planteamiento del problema de clasificación

4.3 Estrategia multimodal adoptada

4.4 Definición del espacio de clases clínicas

4.5 Supuestos y restricciones del modelo

4.6 Flujo general de procesamiento del sistema

Capítulo 5

Descripción del entorno de desarrollo: Python y TensorFlow

5.1 Lenguaje Python para aprendizaje profundo

5.2 Librerías utilizadas

5.2.1 NumPy y Pandas

5.2.2 TensorFlow y Keras

5.2.3 Otras librerías auxiliares

5.3 Ventajas del uso de TensorFlow en el proyecto

5.4 Entorno de ejecución y recursos hardware

5.5 Reproducibilidad y control experimental

Capítulo 6

Preprocesamiento de los datos

6.1 Introducción al preprocesamiento

6.2 Estrategia de fusión de bases de datos

6.3 Armonización de columnas y variables

6.4 Tratamiento de valores faltantes

6.5 Imputación de metadatos clínicos

6.6 Normalización y codificación de variables

6.7 División de conjuntos de entrenamiento, validación y test

6.8 Prevención de patient leakage

6.9 Estrategias de balanceo de datos

Capítulo 7

Métricas de cuantificación de la capacidad predictiva

7.1 Introducción a la evaluación de modelos

7.2 Matriz de confusión

7.3 Exactitud (Accuracy)

7.4 Sensibilidad (Recall)

7.5 Especificidad

7.6 Precisión

7.7 F1-score

7.8 Curvas ROC y AUC

7.9 Justificación clínica de las métricas seleccionadas

Capítulo 8

Diseño de la red implementada

8.1 Visión general de la arquitectura propuesta

8.2 Rama convolucional (CNN)

8.3 Rama basada en Vision Transformer

8.4 Extracción estructural mediante ARP

8.5 Procesamiento de metadatos mediante MLP

8.6 Estrategia de fusión multimodal

8.7 Cabezas de salida del modelo

8.7.1 Clasificación binaria

8.7.2 Clasificación multiclase

8.8 Funciones de pérdida utilizadas

8.9 Estrategia de entrenamiento

Capítulo 9

Evaluación, resultados y discusión

9.1 Configuración experimental

9.2 Resultados obtenidos

9.3 Comparativa entre configuraciones

9.4 Impacto de la fusión multimodal

9.5 Impacto del desbalanceo

9.6 Discusión de resultados

9.7 Limitaciones del estudio

Capítulo 10

Conclusiones y trabajo futuro

10.1 Conclusiones generales

10.2 Contribuciones del trabajo

10.3 Líneas futuras de investigación

Capítulo A

Anexos

A.1 Arquitecturas completas

A.2 Hiperparámetros

A.3 Diagramas adicionales