Título del Trabajo de Fin de Grado

Nombre del Autor

5 de mayo de 2026

Resumen

Abstract

Agradecimientos

Índice general

Resumen **1**

Abstract **2**

Agradecimientos **3**

1. Introducción y justificación **11**

1.1. Contexto clínico e importancia del diagnóstico precoz del cáncer de piel . . 11
1.2. Limitaciones del diagnóstico visual tradicional 11
1.3. Aplicación de la inteligencia artificial en dermatología 11
1.4. Motivación del trabajo 11
1.4.1. Justificación técnica del enfoque propuesto 11
1.4.2. Justificación académica y social del estudio 11
1.5. Objetivos del trabajo 11
1.5.1. Objetivo general 11
1.5.2. Objetivos específicos 11
1.6. Organización de la memoria 11

2. Estado del arte **12**

2.1. Introducción al estado del arte en clasificación de lesiones cutáneas 13
2.2. Métodos clásicos de diagnóstico asistido por ordenador 13
2.2.1. Extracción manual de características 13
2.2.2. Clasificadores tradicionales 13
2.3. Redes neuronales convolucionales en dermatología 13
2.3.1. CNN en clasificación de imágenes médicas 13
2.3.2. CNN aplicadas a lesiones cutáneas 13
2.4. Vision Transformers en visión por computador 13
2.4.1. Fundamentos de los Transformers 13
2.4.2. Aplicaciones de ViT en imagen médica 13
2.5. Modelos híbridos CNNTransformer 13
2.5.1. Motivación del enfoque híbrido 13
2.5.2. Resultados reportados en la literatura 13

2.6. Angular Radial Partitioning en análisis de imagen 13
2.6.1. Fundamentos teóricos del ARP 13
2.6.2. Uso de ARP en reconocimiento de patrones 13
2.7. Aprendizaje multimodal en medicina 13
2.7.1. Fusión de imagen y metadatos clínicos 13
2.7.2. Estrategias de fusión temprana, tardía e intermedia 13
2.8. Problemas abiertos en el estado del arte 13
2.8.1. Desbalanceo de clases 13
2.8.2. Heterogeneidad de bases de datos 13
2.8.3. Riesgos de *data leakage* 13
2.9. Posicionamiento del presente trabajo 13

3. Descripción y Exploración de los Datos 14
3.1. Introducción 14
3.2. Adquisición y Estructura del Dataset Original 15
3.2.1. Adquisición mediante `isic-cli` 15
3.2.2. Estructura y Composición Inicial 15
3.3. Diccionario de Variables y Naturaleza de los Datos 15
3.4. Análisis Exploratorio de Datos (EDA) Original 17
3.4.1. Distribución Demográfica 17
3.4.2. Detección de sesgos sistémicos mediante validación cruzada de metadatos 17
3.4.3. Análisis de correlación de valores nulos (NaNs) en diagnósticos . . . 18
3.4.4. El Desbalanceo Diagnóstico Natural 18
3.5. Definición del *Ground Truth* 18
3.5.1. Criterios para la validacion del *ground truth* 18
3.5.2. Selección de clases objetivo 18

4. Metodología 19
4.1. Introducción 19
4.2. Enfoque de la Investigación: Arquitectura de Doble Cabeza (*Dual-Head*) . 20
4.2.1. Definición de las 6 Clases Clínicas 21
4.3. Aprendizaje Multimodal 22
4.3.1. Imágenes Dermatoscópicas Estándar (RGB): Color y Textura . . . 22
4.3.2. Representación de Borde y Geometría (ARP): Topología Pura . . . 22
4.3.3. Contexto Clínico y Demográfico (Metadatos) 23
4.4. Abordaje del Desbalanceo y Funciones de Pérdida 23
4.4.1. Técnicas a nivel algorítmico y pérdidas específicas 24
4.4.2. Técnicas a nivel de datos (Descartadas) 24
4.5. Estrategias de Aprendizaje: De Ramas Expertas a Fusión Multimodal . . . 25

4.5.1. Entrenamiento Individual de las Ramas Expertas 25
4.5.2. Fusión y Prevención del Olvido Catastrófico Multimodal 26
4.5.3. Protocolo LP-FT Global: El Blindaje de los Expertos 26
4.5.4. Configuración de Tasas de Aprendizaje Diferenciales (DLR) 26
4.5.5. Optimización Computacional y de Memoria 27
4.6. Validación y Robustez: Validación Cruzada Estratificada 27
4.7. Búsqueda y Configuración de Hiperparámetros 28
4.7.1. Estrategias de búsqueda descartadas 29
4.7.2. Optimización Bayesiana con Optuna 29
4.8. Flujo General del Sistema (*Pipeline* de ejecución) 30

5. Entorno de desarrollo y herramientas tecnológicas 32
5.1. Lenguaje de programación 32
5.2. Framework principal de Deep Learning: PyTorch 33
5.2.1. Justificación de la elección de PyTorch 33
5.2.2. Ecosistema Torchvision y librerías asociadas 33
5.3. Herramientas de procesamiento y manipulación de datos 34
5.3.1. NumPy y Pandas 34
5.3.2. Scikit-Learn 34
5.4. Librerías de visión por computador 35
5.4.1. OpenCV y Pillow (PIL) 35
5.5. Librerías de optimización e interpretabilidad 36
5.5.1. Optimización Bayesiana con Optuna 36
5.5.2. Interpretabilidad visual con pytorch-grad-cam 36
5.6. Entorno de ejecución y recursos hardware 37
5.6.1. Configuración del entorno local 37
5.6.2. Limitaciones de VRAM y paralelización 37
5.7. Reproducibilidad y Control de Versiones 38
5.7.1. Fijación de Semillas Aleatorias (*Seed Locking*) 38
5.7.2. Registro de Métricas y Visualización con TensorBoard 39

6. Ingeniería y Preprocesamiento de los Datos 40
6.1. Introducción al preprocesamiento 40
6.2. Paso 1: Limpieza de Datos 40
6.2.1. Tratamiento de Identificadores y Lógica de `master_id` 40
6.2.2. Análisis de Valores Nulos (NaN) y Taxonomía en Cascada 41
6.2.3. Verificación de Duplicados 41
6.3. Paso 2: Integración de Datos 42
6.3.1. Análisis del Catálogo Diagnóstico Original 42
6.3.2. Armonización Taxonómica: El Sistema de 6 Clases (Head B) 42

6.3.3. Arquitectura Dual (*Dual-Head*) y Triaje Clínico 43
6.4. Paso 3: Transformación de Datos 44
6.4.1. Estrategia de Imputación de Valores Faltantes 44
6.4.2. Codificación Categórica: *One-Hot Encoding* (OHE) 44
6.4.3. Política de Escalado Numérico (Z-Score) 45
6.5. Paso 4: Reducción de Datos y Muestreo 45
6.5.1. Análisis Forense de Sesgos de Adquisición 45
6.5.2. El problema de la Red Perezosaz el Efecto *Clever Hans* 46
6.5.3. Estrategia de Muestreo Estratificado (227k Imágenes) 46
6.6. Preprocesamiento Vectorial de Imágenes (*Offline*) 47
6.6.1. Estandarización de la rama RGB 47
6.6.2. Transformación geométrica: Generación de la rama ARP 48
6.7. Partición del Dataset y Estrategia de Evaluación 49

7. Métricas de evaluación y ajuste de umbrales 50
7.1. Introducción a la evaluación en escenarios de extremo desbalanceo 50
7.2. La Matriz de Confusión como base evaluativa 50
7.2.1. Formulación binaria (Cabeza A: Triaje Clínico) 51
7.2.2. Formulación multiclase (Cabeza B: Diagnóstico Diferencial) 51
7.3. Métricas de evaluación deterministas 52
7.3.1. La trampa de la Exactitud (*Accuracy*) en imagen médica 52
7.3.2. Sensibilidad (*Recall*): La métrica prioritaria 52
7.3.3. Especificidad y Precisión 53
7.4. Métricas agregadas y de promediado 53
7.4.1. El *F1-Score* como medida de equilibrio 53
7.4.2. Estrategias de promediado: *Micro* vs. *Macro F1-Score* 54
7.5. Evaluación probabilística de la red 55
7.5.1. Curva ROC (*Receiver Operating Characteristic*) 55
7.5.2. Área Bajo la Curva (AUC) como medida de separabilidad 55
7.6. Ajuste del Umbral de Decisión y Factor de Seguridad Clínico 56
7.7. Justificación clínica de la estrategia de evaluación final 56

8. Diseño de la Red Implementada 58
8.1. Arquitectura Global del Sistema de Fusión Triple 58
8.2. Rama 1: Percepción Clínica (Metadatos MLP) 58
8.2.1. Topología del Perceptrón Multicapa Compartido 58
8.2.2. Sintonización de Hiperparámetros (Optuna) 59
8.3. Rama 2: Análisis Estructural (CNN ARP) 59
8.3.1. Arquitectura Convolucional Personalizada 60
8.3.2. Sintonización de Hiperparámetros (Optuna) 60

8.4. Rama 3: Percepción Visual Híbrida (RGB) 61
8.4.1. Extracción de rasgos locales: ResNet18 61
8.4.2. Modelado de relaciones globales: Vision Transformer (ViT) 61
8.4.3. Sintonización de hiperparámetros (Optuna) 62
8.5. Integración y Toma de Decisión (*Late Fusion*) 62
8.5.1. Concatenación de tensores multimodales 63
8.5.2. Topología de las Cabezas de Decisión (*Dual-Head*) 63
8.6. Modelado Matemático del Entrenamiento Combinado 63
8.6.1. Funciones de pérdida asimétricas e híbridas 63
8.6.2. Aprendizaje Jerárquico mediante *Differential Learning Rates* 64
8.7. Tácticas de Optimización y Rendimiento de Hardware 64
8.7.1. Regularización por *Modality Dropout* 65
8.7.2. Prevención de *GPU Starvation*: *Prefetch* y Múltiples *Workers* . . . 65
8.7.3. Escalado de memoria: *Gradient Accumulation* y *Mixed Precision* (AMP) 65

9. Evaluación, resultados y discusión **67**
9.1. Configuración experimental 67
9.2. Resultados obtenidos 67
9.3. Comparativa entre configuraciones 67
9.4. Impacto de la fusión multimodal 67
9.5. Impacto del desbalanceo 67
9.6. Discusión de resultados 67
9.7. Limitaciones del estudio 67

10. Conclusiones y trabajo futuro **68**
10.1. Conclusiones generales 68
10.2. Contribuciones del trabajo 68
10.3. Líneas futuras de investigación 68

A. Anexos **69**
A.1. Arquitecturas completas 69
A.2. Hiperparámetros 69
A.3. Diagramas adicionales 69

Índice de figuras

4.1. Diagrama de flujo representativo del *pipeline* de ejecución del sistema propuesto. 31

Índice de cuadros

Capítulo 1

Introducción y justificación

1.1 Contexto clínico e importancia del diagnóstico precoz del cáncer de piel

1.2 Limitaciones del diagnóstico visual tradicional

1.3 Aplicación de la inteligencia artificial en dermatología

1.4 Motivación del trabajo

1.4.1 Justificación técnica del enfoque propuesto

1.4.2 Justificación académica y social del estudio

1.5 Objetivos del trabajo

1.5.1 Objetivo general

1.5.2 Objetivos específicos

1.6 Organización de la memoria

Capítulo 2

Estado del arte

2.1 Introducción al estado del arte en clasificación de lesiones cutáneas

2.2 Métodos clásicos de diagnóstico asistido por ordenador

2.2.1 Extracción manual de características

2.2.2 Clasificadores tradicionales

2.3 Redes neuronales convolucionales en dermatología

2.3.1 CNN en clasificación de imágenes médicas

2.3.2 CNN aplicadas a lesiones cutáneas

2.4 Vision Transformers en visión por computador

2.4.1 Fundamentos de los Transformers

2.4.2 Aplicaciones de ViT en imagen médica

2.5 Modelos híbridos CNNTransformer

2.5.1 Motivación del enfoque híbrido

2.5.2 Resultados reportados en la literatura

2.6 Angular Radial Partitioning en análisis de imagen

2.6.1 Fundamentos teóricos del ARP

2.6.2 Uso de ARP en reconocimiento de patrones

2.7 Aprendizaje multimodal en medicina

2.7.1 Fusión de imagen y metadatos clínicos

2.7.2 Estrategias de fusión temprana, tardía e intermedia

Capítulo 3

Descripción y Exploración de los Datos

3.1 Introducción

El diseño y la obtención de buenos resultados en cualquier modelo de redes neuronales depende en gran parte de la cantidad, calidad y organización de los datos. En este capítulo se describe el *análisis exploratorio* que es la base para que nuestro modelo rinda a su mayor nivel: desde el estudio de la estructura, variables y distribución de los datos, hasta la selección del *ground truth* y las clases objetivo.

Los datos han sido obtenidos desde **ISIC Archive** (*International Skin Imaging Collaboration*), una de las bases de datos clínicas y académicas más grandes del mundo, diseñada para el estudio de lesiones cutáneas y sobre todo para el entrenamiento de algoritmos de Inteligencia Artificial como el que se esta desarrollando. La base de datos de **ISIC Archive** consiguió centralizar y estandarizar las imágenes, que por entonces, se encontraban dispersas por centros privados consiguiendo una colaboración de los centros médicos líderes en dermatología. La base de datos está compuesta por metadatos demográficos sobre los pacientes, metadatos clínicos sobre la obtención de las imágenes e información sobre la lesión y finalmente imágenes de lesiones asociadas a los datos. Sin embargo, como ocurre normalmente cuando se centralizan datos de diferentes lugares, la base de datos cuenta con algunas imperfecciones asociadas a falta de datos importantes, diferentes formatos en imágenes o heterogeneidad entre la escala de datos, entre otras cosas, que es imprescindible solucionar antes de entrenar cualquier modelo de este estilo.

En este capítulo se explica y justifica cómo se han obtenido los datos, cuál es la estructura original de los datos tanto del cuerpo de imágenes como del archivo de datos csv , se analizan las variables que componen el archivo, se hace un Análisis Exploratorio de Datos donde quedará representado la distribución actual de las variables, la detección de imperfecciones y problemas que deben ser afrontados más adelante como el desbalanceo de datos, y por último se justificará la selección del *ground truth* y las clases objetivo.

3.2 Adquisición y Estructura del Dataset Original

3.2.1 Adquisición mediante `isic-cli`

La base de datos original se obtuvo de **ISIC Archive**. Debido a la gran cantidad de imágenes e información que contiene este repositorio, descargarlo todo desde su página llevaba a problemas de velocidad de descarga y pérdidas de conexión que provocaba que se reiniciase este proceso. Para solucionar esto, se optó por usar la herramienta **`isic-cli`**, que es una aplicación de terminal que te permite hacer descargas masivas de datos a partir de comandos, o la creación de scripts de descarga específicos para evitar descargar todo el contenido sin orden ninguno. Esta herramienta permitió la descarga de la selección de datos que se va a usar para el estudio evitando hacer una descarga masiva de todos los datos, ahorrando así horas de descarga y garantizando la integridad de los archivos.

3.2.2 Estructura y Composición Inicial

La estructura del dataset original descargado, se compone de dos partes principales:

1. **Cuerpo de Imágenes:** Cuenta con exactamente 552 598 imágenes de alta resolución, obtenidas mediante varios tipos de captura de lesiones cutáneas, destacando sobre todo la dermatoscopia. Los diferentes métodos de captura de las lesiones provocan que no todas las imágenes tengan la misma extensión JPG que buscamos y sobre todo que no todas tengan el mismo tamaño en píxeles.
2. **Archivo de Metadatos (CSV):** Un archivo tabular, con los datos separados por comas comenzando con el identificador de la imagen que la relaciona. El resto de información son datos demográficos y clínicos del paciente así como datos técnicos de la lesión. El archivo cuenta con la misma cantidad de registros que imagenes, 552 598 como hemos comentado anteriormente, y 37 columnas de características.

3.3 Diccionario de Variables y Naturaleza de los Datos

Para comprender el contexto del problema, es necesario entender las variables que componen el archivo de metadatos, las 37 columnas de características. Por lo tanto, para una mejor organización y entendimiento, podríamos dividir estas variables en 5 grandes categorías organizadas por la función que nos aporta cada una:

- **Variables de Trazabilidad:** Como en todo dataset, aqui se incluyen los identificadores únicos alfanuméricos, de los que contamos con tres tipos diferentes de identificadores:
  - *Identificador de la imagen.* Uno por cada registro de fotografía en el dataset, independientemente de si son del mismo paciente o si es de una misma lesión.
  - *Identificadores de lesión* Uno por cada tipo de lesión, el seguimiento de las

lesiones cutáneas suele ser durante varios meses, por lo que no es de extrañar que una misma lesión tenga varias imágenes que se han ido tomando a lo largo del tiempo en un paciente.

- *Identificadores de paciente.* Uno por cada paciente, este puede tener una o varias lesiones con una o varias imágenes cada lesión. La mayor cantidad de registros de fotografías por paciente que se ha encontrado en el dataset original es de **XXXXX**.
- *rcm_case_id* Identificador de caso para microscopia, no es útil además de su gran porcentaje de nulos (99 99

- **Variables Sociodemográficas y Anatómicas:** Son las características del paciente en el momento en el que se captura la imagen de la lesión. Entre estas, las más importantes son:
  - *age_aprox* Edad aproximada del paciente en tramos de 5 años.
  - *sex* sexo biológico del paciente.
  - *anatom_site_general* Región corporal general en la que se encuentra la lesión, como por ejemplo torso, extremidades, cabeza o cuello entre otras. Además existen mas características relacionadas que complementan el contenido de esta, por ejemplo anatom_site_1 hasta anatom_site_5 con nivel de especificación creciente.
- **Variables Técnicas:** En este grupo se encuentran las variables con información sobre el hardware utilizado a la hora de tomar las fotografías y características de las imágenes. Entre estas, las más importantes son:
  - *image_type.* La más importante de todas, distingue principalmente fotografías tomadas con dermatoscopio digital y fotografías clínicas de cuerpo entero (TBP - *Total Body Photography*). Esta variable es tan importante tenerla en cuenta y estudiarla porque podría introducir un sesgo importante a nuestro modelo, que podría guiarse por el tipo de fotografía para clasificar, este problema lo abordamos mas adelante.
  - *pixels_x, pixels_y.* Definen las dimensiones originales de la imagen obtenida. La importancia de estas variables es meramente informativa, nos sirve simplemente para decidir que estrategia de redimensionado de imagen nos conviene hacer según el tamaño original para no perder demasiado detalle. Finalmente como cambiaremos el tamaño para estandarizar la entrada del modelo no nos servirá esta variable.
  - *Otras* En este apartado se encuentran variables que no resultan importantes o por la poca información que aportan o por la gran cantidad de nulos que contiene cada una. Algunas son `dermoscopic_type` ofrece detalles sobre la iluminación (94 % nulos), `image_manipulation` indica si hubro procesamiento previo de la imagen (18 %), `tbp_tile_type` relacionada con las capturas de

tipo cuerpo entero (24 % nulos).

- **Variables Diagnósticas (*Ground Truth*):** Un conjunto de columnas que van desde `diagnosis_1` hasta `diagnosis_5`, donde el 1 es el diagnóstico más general y conforme vamos bajando encontramos un diagnóstico más especifico. En este tipo de variables también se incluyen otras columnas como `diagnosis_confirm_type` o `melanocytic` que al tener porcentajes tan alto de nulos no resultan muy útiles (74 % y 85 % respectivamente).
- **Variables clínicas sesgadas** La detección de información de este tipo es muy importante ya que introducen información no deseada en nuestra red provocando *Data Leakage*. Estas variables contienen datos obtenidos después de la biopsia, entre otras `mel_mitotic_index`, `mel_thick_mm` o `mel_ulcer` que son medidas y observaciones obtenidas post-biopsia.

3.4 Análisis Exploratorio de Datos (EDA) Original

Antes de aplicar cualquier técnica de curación, se realizó un estudio estadístico descriptivo sobre el conjunto bruto de 552 598 registros para comprender la distribución de la población de estudio.

3.4.1 Distribución Demográfica

El análisis reveló una población mayoritariamente adulta, con una edad media de aproximada de 56.3 años. En cuanto a la distribución por sexos biológicos, se observó una prevalencia de pacientes masculinos (59.7 %) frente a pacientes femeninos (32.4 %), existiendo un 7.9 % de registros sin esta información definida. Respecto a la localización anatómica, las lesiones se concentraban predominantemente en el torso posterior (25.4 %) y las extremidades inferiores (24.0 %).

3.4.2 Detección de sesgos sistémicos mediante validación cruzada de metadatos

Para garantizar que la futura red neuronal no aprendiera correlaciones espurias, el script realizó una validación cruzada entre cada metadato disponible y el diagnóstico final. Para cada valor único dentro de un metadato (por ejemplo, los distintos rangos de edad, sexos, o tipos de dispositivo), el algoritmo calculó la distribución porcentual exacta de lesiones malignas y benignas asociadas a dicho valor.
Fue este análisis granular el que permitió descubrir sesgos críticos en la base de datos original. El hallazgo más notable fue el sesgo instrumental: el script evidenció que el porcentaje de casos malignos estaba fuertemente sesgado hacia un tipo de fotografía específico (capturas con dermatoscopio), mientras que la inmensa mayoría de las imágenes

capturadas con sistemas de fotografía de cuerpo entero (TBP) resultaban ser diagnósticos benignos.

3.4.3 Análisis de correlación de valores nulos (NaNs) en diagnósticos

El script analizó el porcentaje de valores perdidos a través de las diferentes columnas diagnósticas originales. Específicamente, calculó para cada categoría de un diagnóstico primario (`diagnostico_x`), qué porcentaje de valores nulos presentaba el diagnóstico secundario (`diagnostico_y`). Este cruce de datos permitió revelar matemáticamente que el etiquetado médico en la base de datos de ISIC sigue una **clasificación en cascada**. Los facultativos diagnostican desde niveles muy generales a niveles muy específicos; por tanto, cuando una lesión no puede ser clasificada con certeza en un nivel superior, todos los subniveles diagnósticos descendentes aparecen sistemáticamente como nulos (NaN).

3.4.4 El Desbalanceo Diagnóstico Natural

El análisis de la variable objetivo primaria (`diagnosis_1`) demostró el severo desbalanceo inherente al cribado dermatológico en el mundo real. De los registros válidos iniciales:

- El **90.96 %** (502 646 muestras) correspondían a lesiones catalogadas estrictamente como **Benignas**.
- Apenas el **4.91 %** (27 111 muestras) eran tumores confirmados como **Malignos**.
- El resto se componía de diagnósticos indeterminados o campos vacíos.

Este hallazgo estadístico subrayó la necesidad imperativa de aplicar en fases posteriores funciones de pérdida especializadas (*Weighted CrossEntropy* o *BCE con pesos asimétricos*) para evitar que la futura red neuronal colapsara prediciendo siempre la clase mayoritaria sana.

3.5 Definición del *Ground Truth*

3.5.1 Criterios para la validacion del *ground truth*

3.5.2 Selección de clases objetivo

Capítulo 4

Metodología

4.1 Introducción

En el desarrollo de sistemas de aprendizaje profundo (*Deep Learning*) aplicados al ámbito médico, la obtención de métricas de alto rendimiento carece de valor si no está respaldada por un marco metodológico estricto, transparente y reproducible. A diferencia de otros dominios tecnológicos, la inteligencia artificial en dermatología clínica debe enfrentarse a desafíos inherentes a la naturaleza de los datos de salud: desbalanceos extremos entre clases, variabilidad en la calidad de las muestras y el riesgo constante de fugas de datos (*data leakage*) que pueden generar falsas estimaciones de éxito. Por ello, una metodología clara y rigurosa no solo es una herramienta de ingeniería, sino una garantía de seguridad y viabilidad clínica.

El presente capítulo detalla exhaustivamente la arquitectura y el diseño experimental del sistema propuesto, trazando el camino desde la concepción del modelo hasta su optimización final. Para facilitar su comprensión, el contenido de este capítulo se ha estructurado en tres grandes bloques temáticos:

- **Bloque I: Fundamentos Arquitectónicos y Datos.** La primera parte del capítulo aborda el diseño estructural del sistema. Se introduce el enfoque de la investigación mediante una arquitectura de doble cabeza (*Dual-Head*), diseñada para simular el flujo de decisiones del triaje médico real (detectando la urgencia maligna y clasificando la patología exacta simultáneamente). A continuación, se detalla el paradigma de aprendizaje multimodal, justificando científicamente cómo la combinación de imágenes a color (RGB), imágenes de reflectancia polarizada (ARP) y metadatos clínicos reduce la incertidumbre diagnóstica del modelo.
- **Bloque II: Estrategias de Entrenamiento y Compensación.** El segundo bloque profundiza en el "motor" del modelo y en cómo este se enfrenta a la realidad de los datos médicos. Se expone el abordaje matemático del desbalanceo de clases, justificando la elección de funciones de pérdida avanzadas frente a las técnicas clásicas de remuestreo de datos. Asimismo, se detallan las estrategias de aprendizaje empleadas para la transferencia de conocimiento (*Transfer Learning*), incluyendo

mecanismos para evitar el olvido catastrófico de la red mediante protocolos de entrenamiento por fases (*Linear Probing* y *Fine-Tuning*) y el uso de tasas de aprendizaje diferenciales.

- **Bloque III: Rigor Científico y Optimización.** Finalmente, el tercer bloque describe los mecanismos implementados para garantizar la robustez, objetividad y reproducibilidad de los resultados. Se explicará la metodología de validación cruzada estratificada con aislamiento hermético de pacientes, así como el control determinista del azar computacional. Como cierre, se presentará la estrategia de búsqueda y configuración de hiperparámetros, detallando el uso de técnicas de optimización bayesiana para maximizar la capacidad de generalización de las redes neuronales diseñadas.

4.2 Enfoque de la Investigación: Arquitectura de Doble Cabeza (*Dual-Head*)

La mayoría de los sistemas de diagnóstico dermatológico basados en Inteligencia Artificial tradicional abordan el problema como una tarea de clasificación única, ya sea puramente binaria (maligno vs. benigno) o puramente multiclase (identificando la patología específica). Sin embargo, en la práctica clínica real, el proceso de toma de decisiones del especialista no es unidimensional, sino que sigue un flujo jerárquico centrado en el riesgo del paciente.

Para replicar este flujo cognitivo, se ha diseñado una arquitectura de "Doble Cabeza" (*Dual-Head*), donde un único cuerpo extractor de características (el *backbone* de la red) se bifurca en la etapa final en dos clasificadores lineales independientes:

- **Head A (Alerta Binaria — Triaje).** Su único objetivo es determinar si la lesión es maligna o benigna. Actúa como el filtro de urgencias de un hospital. Su entrenamiento está fuertemente sesgado hacia la sensibilidad clínica, priorizando minimizar los falsos negativos a toda costa. Para este clasificador, confundir un melanoma con un carcinoma basocelular es irrelevante, ya que ambos requieren derivación urgente; su misión es levantar la bandera roja.
- **Head B (Diagnóstico Diferencial — Multiclase).** Actúa como el especialista dermatólogo. Su objetivo es identificar la patología exacta entre seis posibles categorías. Su entrenamiento busca la máxima precisión global (*F1-Score*) y el correcto mapeo de las características visuales sutiles que separan lesiones similares.

Esta separación arquitectónica ofrece una ventaja técnica crucial: permite aplicar funciones de pérdida (*loss functions*) y castigos matemáticos de forma independiente. Mientras el *Head* A puede ser hiperpenalizado por pasar por alto un cáncer, el *Head* B puede centrarse tranquilamente en distinguir la textura diferencial entre dos lesiones benignas. Al final, los gradientes matemáticos de ambas cabezas retropropagan sus errores

hacia el mismo *backbone* compartido, obligando a la red a aprender representaciones visuales mucho más ricas, robustas y clínicamente útiles que si se entrenara una sola cabeza.

4.2.1 Definición de las 6 Clases Clínicas

Los conjuntos de datos públicos masivos, como el archivo del *International Skin Imaging Collaboration* (ISIC), contienen decenas de diagnósticos histológicos extremadamente granulares (p. ej., queratosis liquenoide, lentigo solar, queratosis seborreica, nevus atípico, etc.). Entrenar un modelo para distinguir entre decenas de subtipos no solo fragmenta excesivamente los datos y dificulta el aprendizaje de la red neuronal, sino que carece de utilidad práctica inmediata en un entorno de atención primaria.

Por ello, se ha llevado a cabo una armonización taxonómica, agrupando la multiplicidad de diagnósticos del ISIC en **seis clases clínicas maestras**. Esta agrupación no se ha hecho en base a similitudes visuales, sino siguiendo criterios de estirpe celular, comportamiento biológico y, sobre todo, **manejo terapéutico**:

1. **NV (Nevus Melanocítico).** Lesiones benignas derivadas de los melanocitos (lunares comunes). Clínicamente, su manejo es la simple observación rutinaria o la tranquilidad del paciente.
2. **MEL (Melanoma).** El cáncer de piel más letal, derivado de los melanocitos. Tiene un alto potencial de metástasis rápida. Su diagnóstico exige una escisión quirúrgica urgente con márgenes amplios. Representa la métrica crítica de seguridad del sistema.
3. **BCC (Carcinoma Basocelular).** Cáncer de piel no melanoma (NMSC). Es el cáncer humano más frecuente. Aunque es localmente destructivo y requiere cirugía (frecuentemente cirugía de Mohs), su capacidad de metástasis es extremadamente baja, por lo que su urgencia vital es menor que la del melanoma.
4. **SCC (Carcinoma Espinocelular y precursores).** Cáncer de piel no melanoma originado en los queratinocitos epidérmicos. Incluye tanto el SCC invasivo como sus precursores directos (Queratosis Actínica y Enfermedad de Bowen). Presenta un riesgo de metástasis significativamente mayor que el BCC, especialmente en zonas mucosas o inmunodeprimidos, requiriendo tratamiento activo e inmediato.
5. **BKL (*Benign Keratotic Lesions* — Lesiones Queratósicas Benignas).** Una supercategoría que agrupa la Queratosis Seborreica, el Lentigo Solar y la Queratosis Liquenoide. Son lesiones no melanocíticas, originadas en la epidermis, sin ningún potencial de malignización. Frecuentemente se confunden visualmente con melanomas (las "grandes simuladoras"), pero su manejo clínico es nulo o puramente estético.
6. **BG (*Background* / Otros Benignos).** Agrupa entidades benignas misceláneas que no encajan en las anteriores, como el Dermatofibroma (reacción fibrosa a picaduras o microtraumas) o lesiones vasculares (angiomas, hemangiomas). Es vital que el modelo conozca esta clase para no clasificar por descarte estas lesiones comunes

como malignas.

Esta reducción a seis clases garantiza que el modelo dedique toda su capacidad computacional a trazar las fronteras de decisión que realmente salvan vidas y determinan el protocolo quirúrgico a seguir, eliminando el ruido estadístico de patologías cuyo pronóstico es idéntico.

4.3 Aprendizaje Multimodal

El diagnóstico dermatológico en la práctica clínica real rara vez se fundamenta en una única observación aislada. Un especialista no solo evalúa el color de una lesión, sino que analiza la regularidad de sus bordes, su simetría estructural y, de manera crucial, el historial clínico y el contexto demográfico del paciente. Basarse en una única fuente de información eleva el riesgo de sesgo y reduce la capacidad de generalización ante casos atípicos.

Para replicar este proceso holístico y minimizar la incertidumbre diagnóstica, el sistema propuesto abandona el enfoque unimodal tradicional en favor de un paradigma de **Aprendizaje Multimodal**. Este enfoque divide la extracción de características en tres ramas de procesamiento independientes y especializadas, donde cada modalidad aporta un eje de información complementario que cubre las carencias de las demás:

4.3.1 Imágenes Dermatoscópicas Estándar (RGB): Color y Textura

La primera modalidad constituye el núcleo visual del sistema, utilizando imágenes dermatoscópicas estándar en el espacio de color RGB. Esta rama es la encargada de capturar los biomarcadores visuales clásicos que busca un dermatólogo, tales como las redes de pigmento, la asimetría cromática, los velos blanco-azulados o las estructuras vasculares.

- **Aportación:** Extrae la semántica visual profunda, el color y la textura de la lesión. Es la modalidad con mayor riqueza de información bruta, pero también la más susceptible a artefactos visuales (vello, variaciones de iluminación o burbujas de gel).
- **Implementación:** Dada la enorme complejidad de esta tarea, se procesa mediante una **Arquitectura Híbrida de alta capacidad** que combina una red convolucional (*ResNet18*) para la extracción de patrones locales de textura, y un Transformador de Visión (*ViT-Base*) para comprender el contexto global y espacial de la imagen.

4.3.2 Representación de Borde y Geometría (ARP): Topología Pura

La segunda modalidad, denominada ARP (basada en coordenadas polares), transforma la imagen espacial tradicional en una representación geométrica donde el eje X representa el ángulo y el eje Y representa el radio desde el centroide de la lesión.

- **Aportación:** Esta transformación aísla por completo la topología estructural y la geometría de los bordes. Al desenrollar la lesión, métricas clínicas fundamentales como la simetría, la regularidad de los bordes o la dispersión radial del pigmento se convierten en patrones lineales fácilmente interpretables matemáticamente. Permite al modelo evaluar la "forma" pura sin distraerse por el color de la piel del paciente o la iluminación del dermatoscopio.
- **Implementación:** Al tratarse de una representación estructural simplificada, no requiere un modelo masivo. Se procesa utilizando una **Red Convolucional (CNN) ligera y personalizada** creada desde cero. Su entrenamiento requiere un protocolo de *Data Augmentation* muy estricto (como la prohibición de volteos verticales, que invertirían matemáticamente el núcleo de la lesión hacia la periferia), respetando así las leyes de la física del espacio polar.

4.3.3 Contexto Clínico y Demográfico (Metadatos)

La tercera modalidad abandona el dominio de la visión artificial e introduce datos tabulares. Contiene la anamnesis básica del paciente, incluyendo variables como la edad, el sexo y la localización anatómica exacta de la lesión.

- **Aportación:** Actúa como un "filtro bayesiano de probabilidad previa". Por ejemplo, aunque el modelo RGB detecte un patrón atípico, la probabilidad de que sea un Carcinoma Basocelular (BCC) aumenta drásticamente si los metadatos indican que el paciente tiene 80 años y la lesión está en una zona de alta exposición solar (como la cabeza o el cuello). Del mismo modo, un melanoma es estadísticamente improbable en un paciente pediátrico. Los metadatos anclan las predicciones visuales a la realidad epidemiológica.
- **Implementación:** Estos datos tabulares se procesan mediante un **Perceptrón Multicapa (MLP)**, una red neuronal clásica que aprende las correlaciones no lineales entre las variables demográficas y las distintas estirpes tumorales.

En conclusión, la sinergia de estas tres modalidades aborda la lesión desde el detalle microscópico (RGB), pasando por su estructura geométrica (ARP), hasta su contexto epidemiológico (Metadatos). Si una de las modalidades falla (por ejemplo, una imagen borrosa), las otras dos actúan como red de seguridad, reduciendo drásticamente la tasa de falsos positivos y falsos negativos en la decisión final de la red.

4.4 Abordaje del Desbalanceo y Funciones de Pérdida

Uno de los desafíos más críticos en este proyecto es el desbalanceo extremo del conjunto de datos. En el archivo ISIC, la proporción entre lesiones benignas y malignas es aproximadamente de 8 a 1, y si analizamos las seis clases maestras, la disparidad es aún mayor (con clases como el Carcinoma Espinocelular representando menos del 2 % del

total). Un modelo entrenado con una función de pérdida estándar tendería a ignorar las clases minoritarias, obteniendo una alta precisión total simplemente clasificando todo como "Nevus" o "Benigno", lo cual sería catastrófico en un entorno médico.

Para resolver esto, se ha optado por un enfoque centrado en la **optimización algorítmica**. En lugar de alterar la cantidad de imágenes, se ha modificado la forma en la que el modelo "siente el error" durante el entrenamiento, obligándole a prestar más atención a los casos raros y difíciles.

4.4.1 Técnicas a nivel algorítmico y pérdidas específicas

Se han implementado tres mecanismos matemáticos complementarios para asegurar que el modelo aprenda con la misma intensidad de todas las categorías:

1. **Pesos por Clase (*Class Weights*) mediante Frecuencia Inversa.** Se ha aplicado un factor de ponderación a la función de pérdida multiclase. Este factor se calcula automáticamente como la inversa de la frecuencia de cada clase. De este modo, el error cometido al clasificar erróneamente una imagen de una clase rara (como el SCC) se multiplica por un valor mucho mayor que el error en una clase común (como el BG). Esto equilibra el gradiente matemático, permitiendo que las clases minoritarias tengan el mismo peso específico en la actualización de los pesos de la red.
2. ***Focal Loss* con Parámetro γ (*Head* B).** Para la clasificación multiclase, se ha sustituido la entropía cruzada tradicional por la *Focal Loss*. Esta función introduce un factor modulador $(1 - p_t)^\gamma$ que reduce la contribución de los ejemplos "fáciles" (aquellos que la red ya clasifica con alta confianza) y se centra en los ejemplos "difíciles" o ambiguos. El parámetro γ (ajustado mediante optimización bayesiana entre 2.0 y 5.0) controla la agresividad de este enfoque, permitiendo que la red se especialice en los detalles sutiles que diferencian, por ejemplo, un melanoma de una lesión queratósica benigna.
3. **`BCEWithLogitsLoss` con Factor de Seguridad Clínico (*Head* A).** Para la cabeza binaria, se utiliza una pérdida de entropía cruzada binaria ponderada. Se ha introducido un **Factor de Seguridad** manual que multiplica el castigo por falso negativo. En términos clínicos, esto significa que el modelo "sufre" mucho más si etiqueta un cáncer como benigno que si comete el error inverso. Esto garantiza una alta sensibilidad (*Recall*), fundamental para un sistema de triaje.

4.4.2 Técnicas a nivel de datos (Descartadas)

Durante la fase de diseño, se consideraron diversas estrategias clásicas de balanceo de datos, pero fueron descartadas por los siguientes motivos técnicos:

- **Sobremuestreo (*Random Oversampling*).** Consiste en duplicar imágenes de las

clases minoritarias. Se descartó porque, en modelos de alta capacidad como el *Vision Transformer* (ViT), esta técnica induce rápidamente al sobreajuste (*overfitting*). El modelo termina memorizando los píxeles exactos de las pocas imágenes repetidas en lugar de aprender características clínicas generales.

- **Submuestreo (*Random Undersampling*).** Consiste en eliminar imágenes de la clase mayoritaria. Se descartó por la pérdida masiva de información. La clase benigna BG es extremadamente heterogénea; eliminar 80.000 imágenes de esta clase privaría al modelo de conocer la enorme variabilidad de la piel sana y otras lesiones irrelevantes, aumentando los falsos positivos.
- **SMOTE y técnicas de generación sintética.** Herramientas como SMOTE generan muestras nuevas mediante la interpolación de vecinos cercanos. Aunque son eficaces en datos tabulares, en imágenes médicas generan artefactos visuales y "ruido" que no tienen base biológica real, lo que podría confundir los filtros convolucionales de la red y generar patrones diagnósticos inexistentes.

En conclusión, la combinación de pesos por clase y *Focal Loss* permite aprovechar el 100 % del *dataset* original sin introducir sesgos de memorización ni perder la riqueza visual de las clases mayoritarias.

4.5 Estrategias de Aprendizaje: De Ramas Expertas a Fusión Multimodal

El entrenamiento del sistema propuesto no se realiza en un solo bloque, sino mediante un proceso de desarrollo jerárquico. Primero se optimizan tres "modelos expertos"de forma independiente para cada modalidad de información y, posteriormente, estos se integran en una arquitectura híbrida final. Debido a la naturaleza dispar de los datos, cada componente requiere una estrategia de aprendizaje adaptada.

4.5.1 Entrenamiento Individual de las Ramas Expertas

Antes de la integración final, cada rama fue entrenada por separado para asegurar que los extractores de características fuesen capaces de interpretar sus respectivos dominios:

- **Rama RGB (Híbrida ViT + ResNet):** Es la única que emplea *Transfer Learning* desde ImageNet. Debido a la complejidad de las imágenes a color, se utilizó el protocolo **LP-FT** (congelación inicial y posterior ajuste fino) y **Tasas de Aprendizaje Diferenciales** para adaptar los filtros genéricos a la patología cutánea. El resultado es un .^{ex}perto.^{en} texturas y colores dermatoscópicos.
- **Rama ARP (Coordenadas Polares):** Se entrenó mediante **Aprendizaje desde Cero** (*Training from scratch*). Al ser un dominio geométrico nuevo (no natural), la red tuvo que aprender de forma pura a identificar irregularidades en los bordes y

asimetrías radiales sin sesgos previos de otras bases de datos.

- **Rama de Metadatos (MLP):** Al tratarse de datos tabulares sencillos, se entrenó desde cero para correlacionar variables demográficas (edad, sexo, ubicación) con la probabilidad diagnóstica previa.

4.5.2 Fusión y Prevención del Olvido Catastrófico Multimodal

Una vez obtenidos los tres modelos expertos, estos se integran en el modelo híbrido final. En este punto surge de nuevo el riesgo del **Olvido Catastrófico**. Las ramas expertas ya tienen un conocimiento "maduro"sobre sus datos, pero la nueva cabeza de clasificación final (*Head* A y B) nace con pesos aleatorios.

Si entrenáramos todo el conjunto desde el segundo uno, el error masivo de la cabeza final se propagaría hacia atrás, çontaminandoz destruyendo el conocimiento especializado que tanto costó conseguir en las ramas expertas.

4.5.3 Protocolo LP-FT Global: El Blindaje de los Expertos

Para integrar las ramas sin degradar su rendimiento, el modelo final repite el protocolo de entrenamiento en dos fases:

1. **Fase 1: *Linear Probing* (LP) de Fusión.** Se congelan las tres ramas expertas por completo. Actúan como extractores de características estáticos. El optimizador solo actualiza los pesos de la nueva cabeza de fusión. Esto permite que el sistema aprenda a combinar la información de los tres mundos (RGB, ARP y Metadatos) sin alterar la "vistaïnterna de cada experto.
2. **Fase 2: *Fine-Tuning* (FT) Holístico.** Una vez que la cabeza final comprende cómo ponderar cada rama, se descongelan todos los parámetros. Toda la arquitectura se ajusta como un único organismo para maximizar la precisión diagnóstica global.

4.5.4 Configuración de Tasas de Aprendizaje Diferenciales (DLR)

En la fase de ajuste fino del modelo final, la sensibilidad de cada componente dicta su velocidad de aprendizaje. Se ha diseñado un esquema de DLR de tres niveles para proteger la estabilidad del sistema:

- **Nivel 1 — Alta Velocidad (*LR Base*):** Aplicado a las cabezas de clasificación finales y a la red de metadatos. Son las capas que más deben cambiar para aprender la tarea de fusión final.
- **Nivel 2 — Velocidad Moderada (*LR Base* / 10):** Aplicado a las ramas convolucionales (ResNet18 y la CNN de ARP). Al ser redes robustas, se les permite un ajuste más ágil de sus filtros de bordes y formas.
- **Nivel 3 — Velocidad Restrictiva (*LR Base* / 100):** Aplicado exclusivamente al Transformador de Visión (ViT). Debido a su tendencia al sobreajuste y a la

complejidad de sus mapas de atención, el ViT solo se ajusta con una tasa de aprendizaje mínima, asegurando que su comprensión global de la imagen no se desestabilice por el aporte de las otras ramas.

4.5.5 Optimización Computacional y de Memoria

Entrenar simultáneamente un Transformador de Visión y una red convolucional exige recursos de memoria de vídeo (VRAM) excepcionales. Para viabilizar el entrenamiento de este modelo masivo en *hardware* local, se han implementado dos estrategias críticas a nivel de ingeniería de *software*:

- **Precisión Mixta Automática (AMP).** Mediante el uso de la tecnología *Automatic Mixed Precision* de PyTorch, la red evalúa dinámicamente qué operaciones matemáticas requieren precisión de 32 bits (FP32) y cuáles pueden resolverse con 16 bits (FP16) sin pérdida de exactitud. Esto reduce a la mitad la huella de memoria durante el paso hacia adelante (*forward pass*) y acelera sustancialmente el cálculo numérico en la tarjeta gráfica.
- **Carga de Datos Asíncrona (*Prefetching*).** Para evitar que la Unidad de Procesamiento Gráfico (GPU) permanezca inactiva esperando a que el disco duro lea las imágenes, se ha implementado un sistema multiproceso (`num_workers`). Mientras la GPU entrena con un lote de imágenes, los núcleos del procesador (CPU) cargan y aplican las transformaciones matemáticas al siguiente lote en segundo plano. Adicionalmente, el uso de memoria anclada (`pin_memory`) crea un túnel de acceso directo a la memoria PCI-Express, acelerando la transferencia de tensores entre el sistema y la GPU.

4.6 Validación y Robustez: Validación Cruzada Estratificada

El desarrollo de un modelo de aprendizaje profundo en el ámbito médico carece de validez si su rendimiento no puede ser garantizado ante datos clínicos no vistos previamente. Un error común en arquitecturas de alta capacidad es la memorización del conjunto de entrenamiento (*overfitting*), lo que produce métricas ilusoriamente altas que colapsan en la práctica real. Para mitigar este riesgo y certificar la fiabilidad del sistema, se ha descartado la tradicional división estática de datos (por ejemplo, 80 % entrenamiento y 20 % validación) en favor de una **Validación Cruzada de cinco particiones** (*5-Fold Cross-Validation*).

Este método divide el conjunto de datos en cinco subconjuntos independientes, entrenando el modelo cinco veces distintas y utilizando en cada iteración un subconjunto diferente como validación. Esto asegura una evaluación estadística robusta, garantizando que el rendimiento final (calculado como la media de las cinco ejecuciones) sea independiente de la porción de datos seleccionada.

Adicionalmente, esta validación cruzada incorpora dos restricciones fundamentales para el entorno médico:

- **Estratificación (*Stratified*).** Asegura que la proporción original de las seis clases maestras se mantenga constante en todos los subconjuntos. Dado el extremo desbalanceo del *dataset*, esto garantiza que ninguna partición de validación se quede sin representación de las clases más críticas y minoritarias (como el Melanoma o el SCC).
- **Aislamiento hermético de pacientes (*Group*).** En conjuntos de datos dermatológicos, es frecuente tener múltiples fotografías del mismo paciente (diferentes lesiones o distintos ángulos anatómicos). Si imágenes del mismo paciente cayeran simultáneamente en el conjunto de entrenamiento y de validación, se produciría una "fuga de datos" (*Data Leakage*). El modelo podría aprender a identificar al paciente (por su tono de piel, vello o fondo de la imagen) en lugar de la patología. Para evitarlo, la partición se ha agrupado forzosamente utilizando el identificador único del paciente (*Master Group ID*), asegurando un aislamiento hermético: el modelo nunca se evalúa con lesiones de un paciente que ya ha "visto" durante su entrenamiento.

4.7 Búsqueda y Configuración de Hiperparámetros

A diferencia de los pesos y sesgos de una red neuronal, que se ajustan automáticamente de forma interna mediante el cálculo de gradientes (retropropagación), los **hiperparámetros** son las variables de configuración externas que gobiernan cómo se lleva a cabo ese proceso de aprendizaje.

La correcta sintonización de estos valores es la frontera que separa a un modelo que sufre subajuste (*underfitting*, incapacidad de extraer patrones) de uno que cae en el sobreajuste (*overfitting*, memorización estéril de los datos de entrenamiento). Entre los hiperparámetros más críticos que se han optimizado en este proyecto destacan:

- **Tasa de Aprendizaje (*Learning Rate* — LR).** Determina el tamaño del "paso" que da el optimizador al actualizar los pesos. Un LR muy alto provoca divergencia e inestabilidad matemática, mientras que un LR muy bajo hace que el modelo se estanque en mínimos locales o tarde un tiempo inasumible en converger.
- **Decaimiento de Pesos (*Weight Decay*).** Actúa como una penalización de regularización L2. Fuerza a la red a mantener sus pesos en valores pequeños, limitando su complejidad matemática y siendo la principal barrera de defensa contra el sobreajuste, especialmente vital en arquitecturas de alta capacidad como los Transformadores de Visión (ViT).
- ***Dropout.*** Apaga aleatoriamente un porcentaje de neuronas en cada paso de entrenamiento, obligando a la red a no depender de características individuales aisladas y

fomentando el aprendizaje de representaciones más distribuidas y robustas.

- **Parámetro Gamma (γ).** Específico de la función *Focal Loss*, modula la agresividad con la que la red ignora las imágenes clínicas sencillas para focalizar sus esfuerzos matemáticos en los casos diagnósticos ambiguos.

4.7.1 Estrategias de búsqueda descartadas

Encontrar la combinación perfecta de hiperparámetros es un desafío de alta complejidad debido a lo que en la literatura científica se conoce como "la maldición de la dimensionalidad". Durante el diseño del marco experimental, se descartaron las dos estrategias más tradicionales de optimización:

1. **Búsqueda en Cuadrícula (*Grid Search*).** Consiste en probar exhaustivamente todas las combinaciones posibles de una lista predefinida de valores. Se descartó por ser computacionalmente inviable. Para un espacio de búsqueda con cinco parámetros y cinco valores posibles cada uno, la red tendría que entrenarse desde cero 3125 veces. En modelos profundos que requieren uso intensivo de GPU, esto supondría meses de procesamiento.
2. **Búsqueda Aleatoria (*Random Search*).** Muestrea puntos al azar dentro del espacio de hiperparámetros. Aunque estadísticamente supera al *Grid Search* al explorar una mayor variedad de valores continuos, su naturaleza es completamente "ciega". No tiene memoria: si probar un *Learning Rate* alto resulta en un colapso del modelo, el algoritmo es incapaz de aprender de ese fallo y podría volver a seleccionar valores similares en el futuro.

4.7.2 Optimización Bayesiana con Optuna

Para superar las limitaciones computacionales y realizar una exploración inteligente del espacio de hiperparámetros, se ha implementado un sistema de **Optimización Bayesiana** utilizando el *framework* avanzado **Optuna**.

A diferencia de las búsquedas ciegas, la optimización bayesiana utiliza un modelo probabilístico (en este estudio, el estimador TPE o *Tree-structured Parzen Estimator*). Este algoritmo actúa como un "investigador" que aprende de sus errores pasados: analiza los resultados métricos (*F1-Score*) de los experimentos (*trials*) anteriores y construye un mapa de probabilidad para decidir qué región del hiperespacio tiene mayor potencial de éxito para el siguiente intento. Esto genera un equilibrio matemático perfecto entre la *exploración* de nuevas configuraciones y la *explotación* de las regiones que ya han demostrado buenos resultados.

Adicionalmente, el uso de Optuna ha permitido integrar dos estrategias clave de optimización computacional en la metodología:

- **Podado Dinámico (*Pruning*).** Se ha integrado el algoritmo *Median Pruner*. Este

mecanismo monitoriza el rendimiento de la red neuronal época a época durante un experimento. Si en la época 3 (por ejemplo) la red tiene un rendimiento drásticamente inferior a la mediana histórica de los experimentos previos en esa misma etapa, Optuna corta la ejecución de inmediato (*Trial Pruned*). Esto evita desperdiciar horas de GPU completando entrenamientos que nacieron matemáticamente condenados al fracaso.

- **Acotamiento por Importancia (Análisis fANOVA).** La metodología de búsqueda no se ha realizado en un solo paso. Inicialmente, se ejecutó un estudio exploratorio amplio con múltiples variables. Utilizando la herramienta de análisis de varianza funcional (fANOVA) integrada en Optuna, se evaluó empíricamente la importancia de cada hiperparámetro. Al detectar que parámetros como las épocas de congelación inicial o los divisores finos del LR tenían una importancia nula a corto plazo frente al peso abrumador del *Weight Decay* y el *Learning Rate* base, se fijaron los parámetros de impacto nulo a valores estándar de la literatura. Esto redujo drásticamente las dimensiones del problema, permitiendo al algoritmo bayesiano destinar todo su poder de cómputo a afinar milimétricamente las tres variables que realmente dictaminaban la capacidad de diagnóstico del sistema.

4.8 Flujo General del Sistema (*Pipeline* de ejecución)

Para finalizar la descripción metodológica, se presenta el *pipeline* de ejecución secuencial que integra todos los componentes descritos anteriormente. El sistema no opera como un bloque monolítico, sino como una cadena de procesos orquestados que transforman los datos brutos en una decisión clínica fundamentada.

Este flujo general se divide en cuatro etapas maestras que garantizan la integridad y la optimización del modelo:

1. **Etapa de Ingesta y Armonización de Datos.** El proceso comienza con la carga de las bases de datos originales. En este punto, se realiza la limpieza de registros sin imagen y se ejecutan las tres rutas de transformación:
   - Normalización de metadatos clínicos.
   - Redimensionamiento y normalización del espectro RGB.
   - Transformación topológica al espacio polar (ARP).
2. **Etapa de Configuración y Optimización Inteligente.** Antes del entrenamiento final, el sistema entra en un ciclo de **Optimización Bayesiana con Optuna**. Durante esta etapa, se realizan múltiples ejecuciones rápidas (submuestreando el *dataset* al 25 % para ahorrar tiempo) con el objetivo de encontrar la combinación ideal de *Learning Rate*, *Weight Decay* y el parámetro γ (gamma) de la *Focal Loss*. Solo una vez hallados estos valores óptimos, se procede al entrenamiento definitivo.
3. **Etapa de Entrenamiento en Bucle *K-Fold*.** Se inicia la validación cruzada de

cinco particiones. Para cada uno de los cinco *folds*, el sistema ejecuta el protocolo de aprendizaje en dos fases:

- **Fase LP (Épocas 1–5):** Entrenamiento exclusivo de las cabezas de clasificación con los *backbones* congelados.
- **Fase FT (Épocas 6–40):** Entrenamiento global de toda la arquitectura multimodal utilizando tasas de aprendizaje diferenciales (DLR) y precisión mixta (AMP).

4. **Etapa de Consolidación y Evaluación Clínica.** Tras completar los cinco ciclos de entrenamiento, el sistema consolida los resultados. Se calculan las métricas de rendimiento tanto para el ***Head* A** (priorizando la sensibilidad para el triaje) como para el ***Head* B** (evaluando la precisión diagnóstica multiclase). Finalmente, se generan las matrices de confusión y las curvas ROC que permiten interpretar el comportamiento del modelo ante cada estirpe tumoral.

Este diseño de *pipeline* asegura que cada decisión tomada por la Inteligencia Artificial ha pasado por un filtro de validación cruzada, una optimización estadística de sus parámetros y un entrenamiento respetuoso con el conocimiento previo de la red, garantizando así un sistema final de alta fidelidad clínica y técnica.

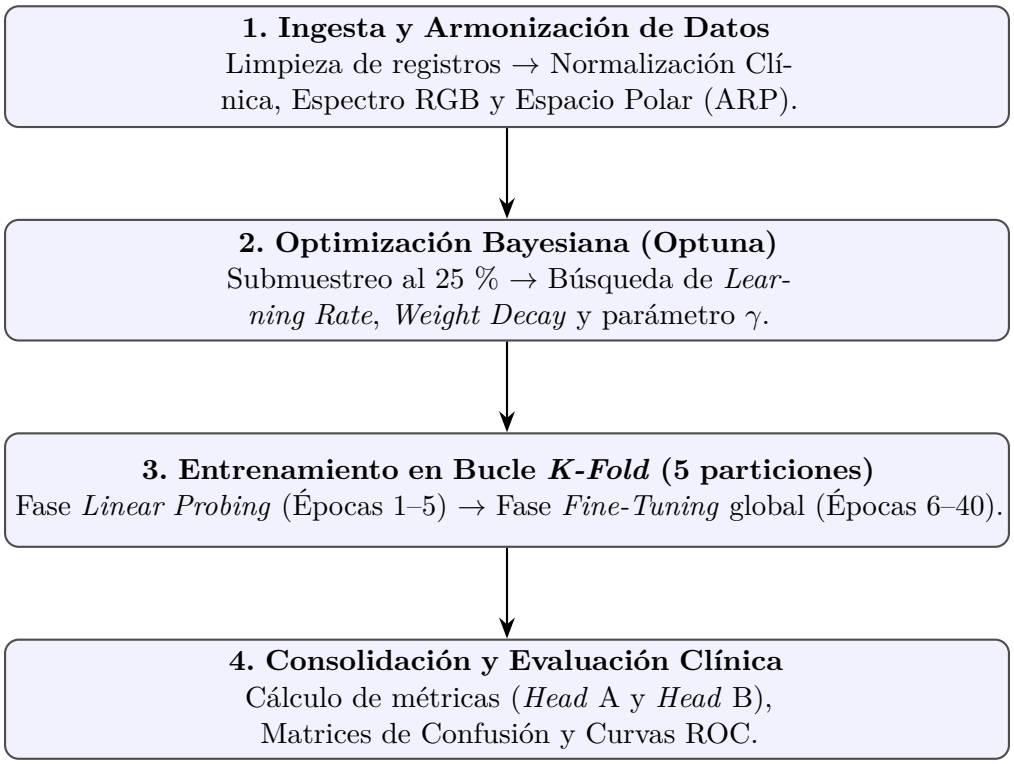

Figura 4.1: Diagrama de flujo representativo del *pipeline* de ejecución del sistema propuesto.

Capítulo 5

Entorno de desarrollo y herramientas tecnológicas

En este capítulo se detallan las herramientas hardware y software seleccionadas para la consecución de los objetivos del proyecto, justificando su elección en base a los requisitos de flexibilidad y rendimiento computacional exigidos por el procesamiento de imágenes médicas.

5.1 Lenguaje de programación

El desarrollo íntegro de este Trabajo de Fin de Grado se ha llevado a cabo utilizando **Python** (en su versión 3.x) como lenguaje de programación principal. La elección de Python no es arbitraria, sino que responde a su consolidación como el estándar *de facto* en la industria y en la comunidad investigadora dentro de los campos de la Inteligencia Artificial, el Aprendizaje Automático (*Machine Learning*) y el Aprendizaje Profundo (*Deep Learning*).

La principal ventaja que ofrece Python frente a lenguajes compilados de más bajo nivel (como C++ o Java) es su sintaxis clara y legible, la cual permite una abstracción total de la gestión de memoria y otorga al desarrollador la capacidad de centrarse enteramente en el diseño lógico y matemático de los algoritmos. Además, su naturaleza multiparadigma soportando programación orientada a objetos y programación funcional resulta ideal para estructurar proyectos de experimentación científica iterativa.

Sin embargo, el factor decisivo para su implementación en este trabajo es su inmenso y maduro ecosistema de librerías científicas. Python actúa como un lenguaje *"pegamento"* (*glue language*), lo que significa que, aunque el código se escriba con una sintaxis de alto nivel, las operaciones matemáticas subyacentes más costosas son ejecutadas en el *backend* mediante rutinas compiladas en C o C++, garantizando un rendimiento óptimo al procesar cientos de miles de imágenes médicas.

5.2 Framework principal de Deep Learning: PyTorch

Para la construcción, entrenamiento y evaluación de las redes neuronales, se ha optado por utilizar **PyTorch**, un marco de trabajo (*framework*) de código abierto desarrollado originalmente por el laboratorio de investigación en inteligencia artificial de Meta (FAIR).

5.2.1 Justificación de la elección de PyTorch

Aunque existen otras alternativas populares en la industria, como TensorFlow o Keras, la naturaleza específica de este proyecto exigía un *framework* que ofreciera el máximo nivel de flexibilidad y control a bajo nivel sobre la arquitectura de la red. PyTorch fue seleccionado por dos razones arquitectónicas fundamentales:

1. **El paradigma del Grafo Computacional Dinámico (*Define-by-Run*):** A diferencia de otros *frameworks* que exigen compilar un grafo estático antes de que fluyan los datos, PyTorch construye el grafo computacional sobre la marcha en cada iteración (*forward pass*). Esta característica resulta indispensable cuando se diseñan arquitecturas a medida que no siguen un flujo lineal tradicional. En el caso de este trabajo, el modelo propuesto (`HybridViTCNN`) fusiona las extracciones de características de dos paradigmas radicalmente distintos: una Red Neuronal Convolucional (CNN) y un *Vision Transformer* (ViT). Manejar la concatenación de estos tensores de diferente naturaleza geométrica es un proceso mucho más natural bajo un paradigma dinámico.
2. **Naturaleza "Pythónica" y depuración (*Debugging*):** PyTorch se integra de manera nativa con las herramientas de depuración de Python. Al trabajar con tensores directamente, es posible inspeccionar el valor numérico exacto de una activación o un gradiente en cualquier capa intermedia de la red. Esta transparencia ha sido crucial para diagnosticar problemas complejos durante el desarrollo, como la explosión de gradientes o la inspección de mapas de características para los algoritmos de interpretabilidad visual (Grad-CAM), permitiendo abrir la "caja negra" del modelo híbrido.

5.2.2 Ecosistema Torchvision y librerías asociadas

Uno de los pilares que sustentan a PyTorch es el paquete auxiliar `torchvision`, diseñado específicamente para resolver problemas de visión por computador. En este proyecto, su uso se ha centrado en dos tareas fundamentales:

- **Transfer Learning y extracción de pesos preentrenados:** Mediante `torchvision.models`, se ha instanciado la rama convolucional del modelo cargando una arquitectura *ResNet18* preentrenada con los pesos óptimos del desafío ImageNet1K. De manera análoga y complementaria, se integró la librería especializada `timm` (*PyTorch Image*

Models) para instanciar la rama atencional de la red, cargando los pesos de un *Vision Transformer* (`ViT-Tiny`).

- **Transformaciones y Aumento de Datos (*Data Augmentation*):** El módulo `torchvision.transforms` ha sido el motor encargado de procesar los lotes de imágenes en tiempo real. Permitió aplicar perturbaciones estocásticas (`RandomHorizontalFlip`, `ColorJitter`, `ElasticTransform`) durante el entrenamiento para actuar como un poderoso método de regularización, mitigando el sobreajuste y combatiendo los sesgos intrínsecos de los dispositivos de adquisición de las bases de datos.

5.3 Herramientas de procesamiento y manipulación de datos

El ecosistema de Python para ciencia de datos ha sido la columna vertebral del preprocesamiento y estructuración de la información clínica antes de su ingesta en las redes neuronales.

5.3.1 NumPy y Pandas

Para la manipulación de datos tabulares y metadatos clínicos, se ha recurrido a la combinación de las librerías `Pandas` y `NumPy`.

`Pandas` ha sido la herramienta fundamental para realizar la carga, limpieza y fusión (mediante operaciones *merge* y *concat*) de las múltiples bases de datos originadas tanto en repositorios históricos (ISIC Archive) como modernos (SLICE-3D). Su uso fue crítico para la limpieza de valores nulos, la imputación de datos faltantes —utilizando valores sentinela como -1— y, de manera muy especial, para la creación del identificador sintético *Master Group ID*. Este identificador, generado a partir de condiciones lógicas jerárquicas (priorizando el ID del paciente sobre el de la lesión), permitió consolidar el historial clínico y evitar colisiones de datos.

Por su parte, `NumPy` se utilizó para las transformaciones matriciales de bajo nivel y la vectorización de operaciones matemáticas. Funciones como `np.where` facilitaron la ejecución de lógica condicional rápida sobre conjuntos de más de 400.000 registros, mientras que las operaciones de apilamiento de matrices (`np.hstack`) permitieron ensamblar eficientemente las características numéricas y categóricas en un único tensor de entrada para alimentar la rama tabular del modelo (Perceptrón Multicapa).

5.3.2 Scikit-Learn

`Scikit-Learn` es el estándar *de facto* en el aprendizaje automático clásico, y en el marco de este proyecto de *Deep Learning* ha desempeñado un papel auxiliar indispensable para preparar el terreno de los datos y auditar los resultados. En concreto, se ha hecho un uso exhaustivo de sus módulos de preprocesamiento, partición y evaluación:

- **Normalización y Codificación:** Se empleó `StandardScaler` para aplicar una estandarización *Z-score* a las variables clínicas y geométricas numéricas (como la edad o el área de la lesión), garantizando que las magnitudes dispares no desestabilizaran los gradientes de la red neuronal. Paralelamente, se utilizó `OneHotEncoder` para transformar variables categóricas (como el sexo o la ubicación anatómica) en vectores binarios ortogonales.
- **Prevención de Fuga de Datos (*Data Leakage*):** Se implementó la clase `StratifiedGroupKFold` para generar las particiones de la validación cruzada. Esta herramienta matemática fue vital para asegurar dos condiciones simultáneamente: que la distribución fuertemente desbalanceada de clases de cáncer se mantuviera constante en cada partición (estratificación), y que todas las imágenes asociadas a un mismo *Master Group ID* recayeran de forma íntegra en el mismo subconjunto. Esto último previno de forma absoluta que el modelo memorizara anomalías sistémicas de un paciente concreto durante el entrenamiento.
- **Cálculo de Métricas Clínicas:** Los módulos de `sklearn.metrics` se integraron en el bucle nativo de PyTorch para evaluar el rendimiento del modelo en tiempo de ejecución. Permitió calcular de forma robusta métricas clínicas complejas como el Área Bajo la Curva ROC (AUC), el *F1-Score* macro, la sensibilidad (*Recall*) específica para el melanoma y la matriz de confusión multiclase.

5.4 Librerías de visión por computador

El preprocesamiento de imágenes dermatoscópicas, paso previo ineludible a la extracción de características profundas, se apoyó en dos de las librerías más consolidadas en el campo de la visión por computador.

5.4.1 OpenCV y Pillow (PIL)

La librería **Pillow (PIL)** se utilizó nativamente dentro de las clases de iteración de datos de PyTorch (`Dataset`). PIL destaca por su eficiencia y rapidez al decodificar archivos de imagen en formato RGB desde el disco de estado sólido, integrándose a la perfección con la cadena de transformaciones estocásticas (*Data Augmentation*) definida en el entrenamiento.

Por otro lado, **OpenCV** (*Open Source Computer Vision Library*) se erigió como el motor matemático crítico para la ingeniería de características visuales. Dada la variabilidad en la iluminación, los bordes artificiales (viñetas del dermatoscopio) y la presencia de artefactos clínicos (como reglas de medición o vello) en las imágenes originales, se empleó OpenCV para generar una representación alternativa de las lesiones: la transformada *Adaptive Radial Polar* (ARP).

Mediante funciones de conversión de espacios de color y la aplicación algorítmica de

proyecciones log-polares (`cv2.linearPolar`), OpenCV permitió desenrollar geométricamente la lesión, aislando su estructura morfológica y la asimetría de los bordes frente al ruido de adquisición. Esto fue determinante para alimentar una rama específica de la red neuronal, forzándola a ignorar el sesgo de la cámara (efecto *Clever Hans*) y centrarse en la patología.

5.5 Librerías de optimización e interpretabilidad

El entrenamiento de arquitecturas de aprendizaje profundo no solo requiere la definición de la red, sino también la búsqueda eficiente de sus hiperparámetros óptimos y la posterior auditoría clínica de sus decisiones. Para cubrir estas necesidades, se integraron herramientas avanzadas de optimización e Inteligencia Artificial Explicable (XAI).

5.5.1 Optimización Bayesiana con Optuna

La búsqueda de hiperparámetros óptimos es uno de los mayores desafíos computacionales en el entrenamiento de redes neuronales profundas. Tradicionalmente, se han utilizado enfoques de fuerza bruta como la búsqueda en cuadrícula (*Grid Search*). Sin embargo, dada la magnitud de los datos de este estudio y el coste temporal de entrenar la arquitectura `HybridViTCNN`, explorar todas las combinaciones posibles resultaba computacionalmente inasumible.

Para solventar esta limitación, se implementó el *framework* `Optuna`, el cual emplea algoritmos de Optimización Bayesiana —específicamente el estimador TPE (*Tree-structured Parzen Estimator*)—. A diferencia de la búsqueda aleatoria o en cuadrícula, `Optuna` utiliza el historial de los experimentos previos para predecir probabilísticamente qué zonas del espacio de hiperparámetros tienen mayor potencial de mejorar el modelo, convergiendo a la solución óptima en una fracción del tiempo.

En este trabajo, `Optuna` fue fundamental para sintonizar el *Learning Rate*, el decaimiento de pesos (*Weight Decay*) y, de forma crítica, el parámetro γ (gamma) de la función de coste *Focal Loss*, esencial para calibrar la penalización ante el fuerte desbalanceo clínico de las clases.

5.5.2 Interpretabilidad visual con pytorch-grad-cam

Uno de los principales impedimentos para la adopción clínica de los modelos de *Deep Learning* es su naturaleza de "caja negra" (*black-box*). Un modelo puede arrojar excelentes métricas de validación por los motivos equivocados, aprendiendo atajos estadísticos en lugar de características anatómicas reales.

Para dotar al modelo de explicabilidad clínica, se integró la librería `pytorch-grad-cam`. Esta herramienta implementa el algoritmo *Grad-CAM* (*Gradient-weighted Class Activation*

Mapping), el cual utiliza los gradientes que fluyen hacia la última capa convolucional de la red —en este caso, el bloque de extracción de la arquitectura *ResNet18*— para generar un mapa de calor que resalta las regiones espaciales de la imagen que mayor impacto tuvieron en la decisión final.

El uso de esta librería resultó de incalculable valor durante la fase forense del proyecto para identificar fugas de información (*Target Leakage*) y diagnosticar el conocido efecto *Clever Hans* o sesgo de dominio. Como se analizará en la memoria, los mapas de calor permitieron descubrir que, antes de aplicar técnicas de regularización geométricas, el modelo ignoraba la lesión cutánea y basaba su diagnóstico maligno en artefactos visuales de los dispositivos de adquisición (como viñetas oscuras de dermatoscopios antiguos o marcas de tinta quirúrgica).

5.6 Entorno de ejecución y recursos hardware

El entrenamiento de modelos híbridos que fusionan tensores de distinta naturaleza sobre cientos de miles de imágenes exige una orquestación precisa de los recursos de *hardware* y *software*.

5.6.1 Configuración del entorno local

Como Entorno de Desarrollo Integrado (IDE) principal se utilizó **Visual Studio Code** (VS Code). Su elección se fundamenta en su robusta integración con Python, su capacidad para ejecutar y depurar *Jupyter Notebooks* de forma nativa, y su versatilidad para gestionar entornos virtuales aislados.

5.6.2 Limitaciones de VRAM y paralelización

El desarrollo del proyecto se enfrentó a un desafío de infraestructura significativo, dividiéndose la ejecución en dos entornos distintos:

- **Entorno Local (Estación de trabajo):** Equipado con un procesador de alto rendimiento y 32 GB de memoria RAM de sistema, pero limitado por una unidad de procesamiento gráfico (GPU) NVIDIA de 6 GB de VRAM. Este entorno se utilizó para la limpieza de datos tabulares, ingeniería de características, análisis forense y pruebas unitarias.
- **Entorno en la Nube (Kaggle):** Para el entrenamiento exhaustivo a gran escala, se recurrió a un entorno multi-GPU compuesto por dos tarjetas **NVIDIA Tesla T4** de 15 GB de VRAM cada una.

El principal cuello de botella radicó en el consumo de memoria gráfica. La arquitectura propuesta procesa simultáneamente un bloque convolucional y un *Vision Transformer*, los cuales deben almacenar sus respectivos mapas de activaciones y gradientes durante el paso

hacia atrás (*backward pass*). Al intentar procesar tamaños de lote (*batch sizes*) de 128 o 256 imágenes, la red saturaba la capacidad gráfica, provocando errores de tipo *CUDA Out of Memory* (OOM).

Adicionalmente, el trasiego de imágenes de alta resolución desde el disco hacia la GPU corría el riesgo de generar un cuello de botella de entrada/salida (E/S). Esto se mitigó mediante el uso de discos de estado sólido **NVMe** y el uso de múltiples hilos de lectura (*DataLoaders workers*). La solución técnica para sortear la limitación de VRAM —basada en la Acumulación de Gradientes (*Gradient Accumulation*) y la Precisión Mixta Automática (*AMP*)— será detallada en el Capítulo 8.

5.7 Reproducibilidad y Control de Versiones

La investigación en Inteligencia Artificial sufre con frecuencia problemas de reproducibilidad debido a la naturaleza estocástica (aleatoria) del *hardware* y de los algoritmos. Operaciones como la inicialización de los pesos de la red neuronal, el barajado de las imágenes o la distribución en la memoria gráfica pueden generar variaciones en los resultados si el código se ejecuta múltiples veces. Para otorgar validez científica a los resultados de este proyecto, se ha diseñado un entorno de ejecución estrictamente controlado.

5.7.1 Fijación de Semillas Aleatorias (*Seed Locking*)

Para garantizar que este proyecto se rija por estándares de reproducibilidad del 100 %, se ha esterilizado el azar computacional forzando un comportamiento completamente determinista. Para ello, se ha fijado una "semilla global" (un valor constante establecido en 42) que sincroniza todos los motores de generación de números pseudoaleatorios del sistema:

1. **Librerías base:** Fijación de la semilla en los módulos `random` nativo de Python y `NumPy`, asegurando que el muestreo de datos para Optuna y las divisiones de la validación cruzada (*5-fold*) asignen matemáticamente las mismas imágenes a los mismos grupos en cada ejecución.
2. **PyTorch y CUDA:** Fijación de la semilla en `torch` y `torch.cuda` para la inicialización determinista de los pesos de las redes neuronales. Adicionalmente, se ha forzado el modo determinista de `cuDNN` (librería base de aceleración de NVIDIA), sacrificando una fracción mínima de rendimiento en favor de una repetibilidad exacta en las operaciones con tensores gráficos.
3. **Optimizador Bayesiano:** Se ha aplicado la misma semilla global al algoritmo de muestreo de Optuna, asegurando que la IA exploratoria pruebe las combinaciones de hiperparámetros en el mismo orden cronológico si el experimento es replicado.

5.7.2 Registro de Métricas y Visualización con TensorBoard

El entrenamiento de arquitecturas profundas e híbridas como la propuesta requiere horas de procesamiento ininterrumpido, lo que hace indispensable contar con un sistema robusto de monitorización y persistencia de datos. Para ello, se ha desarrollado un módulo de registro unificado (`ExperimentLogger`) que actúa como la "caja negra" del sistema.

Este módulo gestiona la información en dos vertientes complementarias:

- **Persistencia y Auditoría Estática:** El sistema genera archivos de registro en formato plano y CSV donde se almacenan, época a época, las métricas clave: pérdidas independientes de ambas cabezas, precisión, *F1-Macro* y evolución de las tasas de aprendizaje diferenciales. Estos archivos permiten una auditoría forense posterior y la generación de tablas comparativas para la memoria de resultados.
- **Visualización Dinámica con TensorBoard:** Para la monitorización en tiempo real, se ha integrado la plataforma *TensorBoard*. Mediante el uso de `SummaryWriter` de PyTorch, el sistema exporta los escalares de rendimiento a eventos binarios que permiten visualizar gráficamente la convergencia del modelo. Esta herramienta es crítica para:
  1. Comparar visualmente el comportamiento de distintos *folds* de la validación cruzada.
  2. Detectar de forma inmediata discrepancias entre las curvas de entrenamiento y validación (indicios de sobreajuste).
  3. Analizar el impacto de los cambios de la tasa de aprendizaje durante la transición entre las fases de *Linear Probing* y *Fine-Tuning*.
- **Persistencia Inteligente de Pesos (*Checkpointing*):** Guardar el estado completo de un modelo que combina ViT y ResNet18 en cada iteración consumiría un espacio de almacenamiento inasumible. En su lugar, se ha implementado una política de guardado condicional. Al finalizar cada época, el sistema evalúa el rendimiento en el conjunto de validación (priorizando el *F1-Macro* del *Head* B). Solo si este valor supera el mejor registro histórico absoluto de ese *fold*, se exportan los parámetros y pesos de la red a un archivo binario (`best_model.pth`).

Gracias a este enfoque condicional, no solo se asegura el progreso ante posibles interrupciones de *hardware*, sino que se garantiza que el modelo final evaluado en la fase de *test* sea matemáticamente aquel que demostró la máxima capacidad de generalización, ignorando las posibles fluctuaciones o degradaciones de rendimiento que suelen ocurrir en las épocas finales del entrenamiento.

Capítulo 6

Ingeniería y Preprocesamiento de los Datos

6.1 Introducción al preprocesamiento

La validez de cualquier sistema de diagnóstico asistido por computadora (*Computer-Aided Diagnosis*) basado en aprendizaje profundo depende, en última instancia, de la integridad y representatividad de los datos de entrenamiento. En dermatología, el desafío es doble: por un lado, existe un desbalance natural entre lesiones benignas y malignas; por otro, la captura de datos médicos suele estar sujeta a variabilidades técnicas que pueden introducir correlaciones espurias o sesgos.

Este capítulo detalla el exhaustivo proceso de ingeniería de datos llevado a cabo, desde la adquisición de la base de datos original hasta la generación de un dataset curado, transformado y particionado para garantizar un entrenamiento robusto y una evaluación exenta de *data leakage*.

6.2 Paso 1: Limpieza de Datos

La primera fase del preprocesamiento consistió en auditar la completitud de la base de datos original (552 598 imágenes y 37 columnas), tratar los valores perdidos (*Missing Values*), eliminar redundancias e inconsistencias en la identificación de los pacientes.

6.2.1 Tratamiento de Identificadores y Lógica de `master_id`

El rastreo de los pacientes es un aspecto crítico en el análisis de imágenes médicas para garantizar que las particiones de entrenamiento y evaluación sean completamente independientes (*Patient-Level Split*). Tras realizar la auditoría forense sobre los 552 598 identificadores de imágenes originales (`isic_id`), se detectaron inconsistencias severas en las columnas de seguimiento (`patient_id` y `lesion_id`):

- **Registros Completos (14.6 %):** Un total de 80 612 imágenes poseían simultáneamente `patient_id` y `lesion_id`. En estos casos, se priorizó el `patient_id` como clave principal para agrupar todas las lesiones de un mismo individuo.

- **Pacientes sin lesión definida (71.5 %):** 395 154 imágenes presentaban `patient_id` pero carecían de `lesion_id`. Dado que se conocía al individuo, se utilizó directamente el `patient_id` como clave de agrupación.
- **Lesiones sin paciente asignado (8.2 %):** 45 249 imágenes tenían `lesion_id` pero no `patient_id`. En este escenario, la lesión en sí misma se trató como un grupo clínico aislado y se empleó su `lesion_id` como clave.
- **El "Limbo Clínico"(5.7 %):** Se identificaron 31 583 imágenes (casi el 6 % del dataset) que carecían de ambos identificadores. Ante la imposibilidad de garantizar la trazabilidad de estas muestras y el alto riesgo de provocar fugas de datos (*Data Leakage*) en etapas posteriores, **estos registros fueron eliminados permanentemente**.

Para unificar esta disparidad en una estructura hermética, se programó la generación de la columna algorítmica **`master_id`**, la cual actúa como la única variable de control para agrupar datos según las reglas de priorización descritas.

6.2.2 Análisis de Valores Nulos (NaN) y Taxonomía en Cascada

La auditoría también reveló un volumen crítico de valores perdidos en los metadatos. Se observó que múltiples columnas presentaban más del 90 % de nulos (ej., `mel_mitotic_index`: 99.97 %, `mel_thick_mm`: 99.84 %).

En cuanto a las columnas de diagnóstico principal, se observó que el etiquetado médico seguía una lógica de **clasificación en cascada**: los facultativos catalogan la lesión desde términos generales a específicos. Al cruzar las columnas `diagnosis_1`, `diagnosis_2` y `diagnosis_3`, se comprobó que si un nivel superior presentaba un valor nulo (NaN) o el término Ïndeterminate"(3 314 casos, un 0.60 % del total), los subniveles descendentes arrastraban ese vacío.

En consecuencia, los registros con información diagnóstica faltante o clasificados como Ïndeterminate"fueron suprimidos para asegurar que la red neuronal solo asimile *Ground Truth* validado clínicamente.

6.2.3 Verificación de Duplicados

Finalmente, se ejecutó una comprobación automatizada sobre el subconjunto restante. El análisis de integridad certificó que existían **0 filas idénticas** en su totalidad y **0 identificadores de imagen duplicados**, asegurando que ninguna muestra inflaría artificialmente el rendimiento del modelo durante el entrenamiento.

6.3 Paso 2: Integración de Datos

La integración de datos implicó armonizar la inmensa disparidad de nomenclaturas patológicas del dataset original para diseñar un sistema objetivo, clínicamente coherente y viable para el aprendizaje profundo multitarea.

6.3.1 Análisis del Catálogo Diagnóstico Original

La auditoría del dataset reveló que la clasificación original estaba fragmentada en cinco niveles de profundidad (`diagnosis_1` a `diagnosis_5`).

- El nivel `diagnosis_1` ofrecía una visión puramente binaria (90.96 % Benigno, 4.91 % Maligno).
- El nivel `diagnosis_2` separaba por linaje celular (ej. proliferaciones melanocíticas frente a epiteliales).
- Los niveles `diagnosis_3`, `diagnosis_4` y `diagnosis_5` contenían un catálogo exhaustivo con docenas de patologías y sus respectivos subtipos histopatológicos (ej. Melanoma in situ, Melanoma nodular, Nevus de Spitz, Nevus displásico, etc.).

Entrenar una red neuronal para predecir docenas de subtipos histológicos (como diferenciar un Nevus de Clark de un Nevus de Reed) a partir de imágenes macroscópicas es clínicamente inviable e introduce un ruido matemático severo debido a la escasez de muestras en las clases minoritarias. Por tanto, se hizo imprescindible un proceso de fusión de clases (*Class Mapping*).

6.3.2 Armonización Taxonómica: El Sistema de 6 Clases (Head B)

Se analizaron todas las subcategorías y se agruparon en 6 clases maestras basándose en su comportamiento biológico, su apariencia visual y la decisión clínica subyacente. Esta agrupación define la salida multiclase del modelo (**Head B**):

1. **[0] Nevus (NV) – 37 197 muestras:** Se agruparon aquí todas las proliferaciones melanocíticas benignas. Esto incluye el término genérico "Nevus.ªsí como todos sus subtipos descritos en los niveles 4 y 5 (*Nevus displásico, atípico, de Spitz, de Reed, dérmico, congénito, etc.*). **Justificación clínica:** Independientemente de su subtipo histológico, todos los nevus son lunares benignos cuyo manejo clínico es la simple observación rutinaria.
2. **[1] Melanoma (MEL) – 10 245 muestras:** Se fusionaron todos los estadios y variantes del cáncer melanocítico (*Melanoma in situ, invasivo, lentigo maligno, diseminación superficial, nodular, etc.*). **Justificación clínica:** El melanoma es el cáncer de piel con mayor tasa de mortalidad. Agrupar todas sus variantes asegura que el modelo disponga del mayor volumen de datos posible para aprender a detectar cualquier morfología que requiera escisión quirúrgica urgente.

3. **[2] Carcinoma Basocelular (BCC) – 12 195 muestras:** Agrupa los carcinomas basocelulares (*nodular, superficial, infiltrante, esclerosante*). **Justificación clínica:** Es el cáncer de piel no melanocítico (NMSC) más común. Posee un perfil visual muy distinto al melanoma (apariencia perlada, telangiectasias), por lo que debe ser una clase independiente.
4. **[3] Carcinoma Espinocelular (SCC) – 3 018 muestras:** Incluye los carcinomas de células escamosas (*in situ, invasivo, enfermedad de Bowen*) y el queratoacantoma. **Justificación clínica:** Al igual que el BCC, es un cáncer queratinocítico, pero con mayor potencial de metástasis, requiriendo un manejo terapéutico diferenciado.
5. **[4] Queratosis Benignas (BKL) – 6 194 muestras:** Esta clase es de vital importancia algorítmica. Agrupa las queratosis seborreicas, los lentigos solares y las queratosis liquenoides. **Justificación clínica:** Estas lesiones benignas son los grandes ïmitadores"del melanoma. Suelen ser oscuras, asimétricas y con bordes irregulares, siendo la causa principal de falsos positivos en la práctica clínica. Aislar estas patologías en una clase propia obliga a la red neuronal a aprender específicamente las sutilezas visuales que las diferencian de un melanoma real.
6. **[5] Benigno Genérico (BG) – 156 087 muestras:** Esta clase actúa como un çajón de sastre"para el resto de afecciones cutáneas inocuas no melanocíticas (*Dermatofibromas, hemangiomas, cicatrices, verrugas, quistes, pólipos, etc.*). **Justificación clínica:** Estas lesiones presentan morfologías muy variadas pero comparten el mismo desenlace médico: no representan peligro para el paciente. Poseen muy pocas muestras individuales para conformar sus propias clases sin generar un desbalance extremo, por lo que su agrupación es la solución matemática óptima.

6.3.3 Arquitectura Dual (*Dual-Head*) y Triaje Clínico

Para maximizar la utilidad médica del sistema, se configuró una arquitectura de red con dos ramas de decisión simultáneas (*Multi-task Learning*):

- **Head A (Clasificación Binaria de Riesgo):** Su función es realizar un triaje primario simulando la decisión crítica de un médico generalista: *£Es peligroso o no?*. Para ello, mapea internamente las 6 clases en dos grupos absolutos:
  - **Maligno (Etiqueta 1):** Engloba las clases 1 (MEL), 2 (BCC) y 3 (SCC).
  - **Benigno (Etiqueta 0):** Engloba las clases 0 (NV), 4 (BKL) y 5 (BG).

  Esta cabeza se entrena con una función de pérdida fuertemente penalizada para evitar los falsos negativos (no dejar pasar ningún cáncer).
- **Head B (Clasificación Diagnóstica Multiclase):** Su función simula la evaluación de un dermatólogo especialista, intentando predecir la patología exacta entre las 6 clases maestras (0 a 5) descritas anteriormente.

El entrenamiento conjunto de ambas cabezas permite que la red extraiga características más robustas, forzando al modelo a aprender primero la gravedad subyacente de la lesión

antes de especificar su diagnóstico exacto.

6.4 Paso 3: Transformación de Datos

La fase de transformación tuvo como objetivo adecuar matemáticamente los datos tabulares para su ingesta por parte de la red neuronal (Perceptrón Multicapa), garantizando que las representaciones numéricas no introdujeran suposiciones falsas ni sesgos artificiales.

6.4.1 Estrategia de Imputación de Valores Faltantes

En el procesamiento tradicional de datos, es común recurrir a técnicas de imputación estadística como la sustitución por la media (para números) o por la moda (para categorías). Sin embargo, en un contexto médico, inventar datos clínicos asumiendo que un valor faltante corresponde al paciente "promedio"supone un riesgo inaceptable y altera la distribución real de la población. Por ello, se adoptaron técnicas de **imputación explícita de ausencia**:

- **Variables Numéricas (`age_approx`): Imputación por Valor Centinela.**
  En lugar de rellenar las edades faltantes con la edad media del dataset (lo cual crearía un pico artificial en la distribución de edades y engañaría al modelo), se imputó el valor `-1.0`. Este valor actúa como un çentinela.º ancla fuera de la distribución natural. Al introducir este valor extremo, la red neuronal aprende que el `-1.0` no representa a un paciente que no ha nacido, sino que representa un patrón matemático distinto: la *ausencia de información*. Esto permite al modelo ajustar sus pesos para tomar decisiones basándose en el resto de variables cuando la edad es desconocida, sin ser engañado por una edad media ficticia.
- **Variables Categóricas (`sex`, `anatom_site_general`): Categoría `unknown`.**
  Del mismo modo, imputar un sexo faltante con la moda (por ejemplo, "masculino"si es la clase mayoritaria) introduce un sesgo de género directo en el paciente. La técnica óptima empleada fue crear e imputar la etiqueta explícita **`unknown`**. Al tratar la falta de datos como una categoría válida y separada, se respeta la incertidumbre clínica real y el modelo aprende a calibrar sus predicciones cuando ignora la localización anatómica o el sexo del individuo.

6.4.2 Codificación Categórica: *One-Hot Encoding* (OHE)

Las redes neuronales solo comprenden vectores numéricos. Una práctica ineficiente (y a menudo errónea) es aplicar *Label Encoding*, que asigna un número entero a cada categoría (ej. Cabeza = 1, Torso = 2, Piernas = 3). Hacer esto forzaría a la red a asumir una relación ordinal falsa, implicando matemáticamente que las Piernas valen "más.º son "tres veces la Cabeza", lo cual es un absurdo anatómico y biológico.

Para resolver esto, se aplicó la técnica de ***One-Hot Encoding* (OHE)**. Esta transformación toma cada variable categórica y genera tantas columnas nuevas como valores únicos existan. A cada fila se le asigna un 1 en la columna correspondiente y un 0 en el resto.

Ventajas de usar OHE frente a no usarlo:

1. **Ortogonalidad matemática:** Garantiza que todas las categorías sean equidistantes e independientes entre sí en el espacio vectorial. Ninguna ubicación anatómica ni sexo tiene un peso numérico superior inherente.
2. **Activación de pesos independiente:** Permite a la red neuronal (a través de los parámetros del Perceptrón Multicapa) aprender un peso (w) y un sesgo (b) completamente aislado para el "torso"frente a la çabeza", mejorando significativamente la interpretabilidad y el rendimiento del triaje.

6.4.3 Política de Escalado Numérico (Z-Score)

Para que la red neuronal converja correctamente y los gradientes no se desestabilicen, las variables numéricas (como la edad) deben ser estandarizadas mediante normalización *Z-score* ($z = \frac{x-\mu}{\sigma}$).

Sin embargo, se determinó metodológicamente que esta normalización **no debe realizarse de forma global** (*offline*) sobre la totalidad del dataset antes de la partición. Si se calculara la media (μ) y la desviación estándar (σ) usando todos los datos, la información de las edades del conjunto de prueba (*Test Set*) çontaminaría.[el] conjunto de entrenamiento, incurriendo en un sutil pero peligroso *Data Leakage*.

Por consiguiente, el escalado se difirió a la etapa de entrenamiento: el *Z-score* se calcula y se aplica dinámicamente, extrayendo la media y la desviación estándar de forma estricta y exclusiva del subconjunto de entrenamiento correspondiente a cada *fold* de la validación cruzada.

6.5 Paso 4: Reducción de Datos y Muestreo

6.5.1 Análisis Forense de Sesgos de Adquisición

Para garantizar la capacidad de generalización del modelo, se realizó un análisis cruzado entre todos los metadatos y las etiquetas diagnósticas buscando correlaciones espurias. El hallazgo más crítico de la auditoría fue el descubrimiento de un severo **sesgo instrumental** ligado a la variable `image_type` (tipo de fotografía).

La base de datos original (552 598 imágenes) presentaba la siguiente distribución instrumental:

- **Fotografía de cuerpo entero (*TBP tile: close-up*):** 401 059 imágenes. De estas, el **99.9 % (400 552)** eran lesiones benignas, y apenas un 0.1 % (393) eran malignas.

- **Dermatoscopía digital (*dermoscopic*):** 124 752 imágenes. Aquí se concentraba la gran mayoría de los cánceres, con **21 620 lesiones malignas** (17.3 %) frente a 98 745 benignas (79.2 %).
- **Fotografía clínica macroscópica (*clinical: close-up*):** 9 316 imágenes, con una altísima prevalencia de malignidad (4 787 malignas, 51.4 %).

6.5.2 El problema de la Red Perezosaz el Efecto *Clever Hans*

Las imágenes dermatoscópicas presentan artefactos visuales muy característicos, como bordes negros circulares, esquinas oscurecidas o marcas de gel de inmersión, ausentes en las fotografías TBP. Si la red neuronal se entrenase con la distribución original en bruto, se convertiría en una **red perezosa"** (*lazy network*). En lugar de aprender los intrincados patrones morfológicos del cáncer (asimetría, bordes, estructuras reticulares), la red optimizaría su función de pérdida aprendiendo a distinguir el tipo de cámara: si detecta un borde negro (dermatoscopio) sube la probabilidad de malignidad, y si ve piel limpia (TBP) asume que es benigno.

Este fenómeno, conocido como el **efecto *Clever Hans***, ya fue corroborado en iteraciones previas de modelos dermatológicos. Al aplicar técnicas de interpretabilidad visual como **Grad-CAM** (Mapas de Activación de Clase ponderados por Gradiente), se observó empíricamente que los mapas de calor (*heatmaps*) de la red no se centraban en la lesión cutánea, sino que se activaban intensamente en las esquinas negras del dermatoscopio.

Una posible solución técnica sería aplicar un *Data Augmentation* extremadamente agresivo (recortes severos, enmascaramiento de bordes, transformaciones elásticas extremas) para destruir los artefactos del dermatoscopio. Sin embargo, esta es una solución destructiva que elimina el contexto periférico de la lesión y altera la escala real de los lunares. La solución metodológicamente correcta debe aplicarse en la raíz: el balanceo representativo de los datos.

6.5.3 Estrategia de Muestreo Estratificado (227k Imágenes)

Para forzar al modelo a extraer características intrínsecas de las lesiones, es imperativo mostrarle tanto ejemplos benignos como malignos procedentes de todos los dominios instrumentales. En lugar de utilizar exclusivamente imágenes dermatoscópicas (lo que limitaría el modelo a un solo tipo de hardware), se diseñó un muestreo estratégico para conformar un corpus robusto de aproximadamente **227 000 imágenes**:

1. **Bloque Dermatoscópico (Homogeneidad de dominio):** Se seleccionaron ∼20 000 imágenes malignas dermatoscópicas (prácticamente la totalidad disponible). Para balancear este dominio, se emparejaron con ∼86 000 imágenes benignas tomadas exactamente con el mismo tipo de dermatoscopio. Así, la red aprende que el borde negro no es sinónimo de cáncer.

2. **Bloque TBP/Clínico (Compensación y Diversidad):** Dado que la tecnología TBP representa el futuro del cribado dermatológico, se retuvo un volumen masivo de ∼110 000 imágenes benignas de este formato. Para evitar que la red asocie TBP exclusivamente a benignidad, se inyectó la totalidad de las ∼7 000 imágenes malignas restantes procedentes de fotografías clínicas y TBP.

Esta técnica de reducción y balanceo garantiza un conjunto de datos **agnóstico al dispositivo de captura**. Una vez completado este muestreo, la columna `image_type` fue eliminada definitivamente del archivo de metadatos, garantizando que el algoritmo carezca de atajos matemáticos y se vea obligado a basar sus predicciones diagnósticas única y exclusivamente en la morfología de la lesión y la fisiología del paciente.

6.6 Preprocesamiento Vectorial de Imágenes (*Offline*)

El conjunto de datos original de ISIC presenta una heterogeneidad extrema no solo a nivel clínico, sino también a nivel de *hardware*. Las imágenes varían drásticamente en resolución (desde dimensiones de 600×400 píxeles hasta capturas macroscópicas en resoluciones 4K), relaciones de aspecto y formatos de compresión (`.jpg`, `.jpeg`, `.png`). Dado que arquitecturas profundas como *ResNet18* o *Vision Transformer* (ViT) exigen tensores de entrada de dimensiones estáticas y estandarizadas (típicamente 224×224 píxeles), se hizo indispensable diseñar un proceso de homogeneización visual.

6.6.1 Estandarización de la rama RGB

En las etapas iniciales de la investigación, la estandarización de las imágenes se implementó bajo un enfoque *Online*; es decir, las imágenes originales en alta resolución se leían directamente del disco duro y se redimensionaban dinámicamente en la memoria RAM durante cada época de entrenamiento. Para no perder información clínica vital durante esta reducción, se utilizaban algoritmos de interpolación complejos y de alta fidelidad geométrica, como el filtro de Lanczos.

Sin embargo, este enfoque dinámico generó un problema crítico a nivel de *hardware*:

- **Cuello de Botella de Entrada/Salida (*I/O Bottleneck*).** Leer cientos de miles de archivos pesados repetidamente saturaba el ancho de banda del disco.
- **Inanición de la GPU (*CPU Starvation*).** El procesador central (CPU) alcanzaba un 100 % de uso ejecutando las interpolaciones matemáticas de Lanczos para redimensionar los lotes (*batches*). Como consecuencia, la Unidad de Procesamiento Gráfico (GPU) —el componente más potente y necesario para calcular los gradientes de la red— permanecía inactiva esperando a que la CPU le enviara los datos, multiplicando inasumiblemente los tiempos de entrenamiento.

Para resolver esta ineficiencia técnica, se desarrolló un *pipeline* de preprocesamiento *Offline*. Mediante un *script* dedicado, se procesó de una sola vez la totalidad del corpus de

aproximadamente 227.000 imágenes antes de iniciar cualquier entrenamiento. Este proceso consistió en:

1. **Unificación de formatos.** Conversión de cualquier extensión heterogénea al formato estándar `.jpg` para homogeneizar la compresión y la lectura computacional.
2. **Redimensionamiento estático.** Escalamiento de todas las imágenes a la resolución exacta de 224×224 píxeles utilizando interpolación bicúbica de alta calidad, guardando el resultado en un directorio dedicado (`processed/images_RGB_ISIC`).

Este preprocesamiento *Offline* redujo drásticamente el peso físico del *dataset* en el disco duro (pasando de cientos de gigabytes a unos pocos gigabytes). Más importante aún, liberó completamente a la CPU de las tareas pesadas de interpolación. Durante el entrenamiento, las transformaciones *Online* pudieron limitarse única y exclusivamente a operaciones matriciales de coste computacional casi nulo (como rotaciones aleatorias, ajustes sutiles de brillo y la normalización estadística de los canales RGB con las medias de ImageNet), permitiendo que la GPU operase al 100 % de su capacidad.

6.6.2 Transformación geométrica: Generación de la rama ARP

Mientras que la rama RGB se centra en el color y la textura, la segunda modalidad visual del modelo tiene como objetivo aislar la topología y geometría de la lesión. Para lograrlo, se implementó un segundo *pipeline Offline* destinado a generar las imágenes para la red convolucional secundaria mediante la técnica de **Partición Radial Angular** (*Angular Radial Partitioning* o ARP).

Esta técnica transforma la imagen tradicional, basada en un sistema de coordenadas cartesianas espaciales (x, y), en una representación cilíndrica basada en coordenadas polares (r, θ). El proceso algorítmico sigue estos pasos:

1. **Cálculo del centroide.** Se asume que la lesión cutánea se encuentra predominantemente en el centro del encuadre fotográfico (dado que el *dataset* ISIC proporciona imágenes centradas en la lesión anatómica). Se establecen las coordenadas centrales de la imagen (x_c, y_c) como el origen anatómico.
2. **Mapeo de Coordenadas Puras.** Para cada píxel de la nueva imagen, se calcula su distancia radial (r) y su ángulo (θ) con respecto al centroide utilizando transformaciones trigonométricas fundamentales:

$$r = \sqrt{(x - x_c)^2 + (y - y_c)^2} \tag{6.6.1}$$

$$\theta = \operatorname{atan2}(y - y_c, x - x_c) \tag{6.6.2}$$

3. **Desenrollado (*Unwrapping*) y Remuestreo.** La imagen resultante se construye mapeando el radio r en el eje vertical y el ángulo θ en el eje horizontal, barriendo de $0°$ a $360°$ (0 a 2π radianes).

Justificación Clínica y Matemática:

Visualmente, esta transformación "desenrolla" el lunar como si se tratase de un mapa topográfico. El centro de la lesión se convierte en la franja superior de la imagen ARP, mientras que los bordes periféricos se extienden hacia la parte inferior. Si un lunar es perfectamente simétrico y redondo (signo clínico de benignidad), en la imagen ARP su borde se dibujará como una línea horizontal perfectamente recta y paralela. Por el contrario, las proyecciones asimétricas, seudópodos o irregularidades en los bordes (signos clásicos del melanoma) se transforman en pronunciados valles y picos en la imagen polar.

Al proporcionar esta vista geométrica precalculada, se exime a la red neuronal de tener que deducir complejas rotaciones espaciales, permitiendo que sus filtros convolucionales detecten anomalías estructurales simplemente identificando desviaciones verticales en el nuevo espacio de características horizontales.

6.7 Partición del Dataset y Estrategia de Evaluación

La fase final del preprocesamiento fue la división del dataset en una proporción 85/15:

- **Test Set (15 %):** Un conjunto ciego de pacientes extraído mediante `GroupShuffleSplit` basado en el `master_id`. Esto asegura que todas las imágenes de un mismo paciente estén exclusivamente en un conjunto, imposibilitando que el modelo memorice características individuales de la piel.
- **Training/Val Set (85 %):** Destinado al desarrollo del modelo, donde se aplicará una técnica de `StratifiedGroupKFold` para la validación cruzada.

Tras este proceso, las columnas finales que alimentarán el sistema son: `isic_id`, `patient_id`, `lesion_id`, `master_id`, `age_approx`, `target`, y las variantes vectorizadas de `sex` y `anatom_site_general`.

Capítulo 7

Métricas de evaluación y ajuste de umbrales

7.1 Introducción a la evaluación en escenarios de extremo desbalanceo

La validez de un sistema de diagnóstico asistido por computadora no reside únicamente en su capacidad de aprendizaje, sino en el rigor con el que se miden sus fallos. En el ámbito de la dermatología oncológica, la evaluación del rendimiento se enfrenta a un desafío estadístico crítico: el desbalanceo extremo del conjunto de datos.

En el archivo ISIC utilizado en este proyecto, la prevalencia de lesiones benignas (clase mayoritaria) frente a las malignas (clase minoritaria) es de aproximadamente ocho a uno. Si se utilizasen métricas de evaluación convencionales, se correría el riesgo de caer en la "paradoja de la exactitud": un modelo que simplemente clasificara todas las muestras como benignas obtendría una precisión cercana al 90 %, pero su utilidad clínica sería nula al no detectar ni un solo cáncer.

Por tanto, la evaluación de este sistema se ha diseñado para evitar el enmascaramiento de errores en las clases minoritarias. Se requiere un arsenal de métricas que penalicen con extrema dureza el error más costoso en medicina: el falso negativo (un cáncer no detectado).

7.2 La Matriz de Confusión como base evaluativa

La Matriz de Confusión es la herramienta fundamental sobre la que se construyen el resto de las métricas deterministas. Se trata de una tabla que permite visualizar el desempeño de un algoritmo de aprendizaje supervisado, comparando las etiquetas reales (*Ground Truth*) frente a las predicciones realizadas por el modelo. Cada columna de la matriz representa las instancias de una clase predicha, mientras que cada fila representa las instancias de una clase real.

7.2.1 Formulación binaria (Cabeza A: Triaje Clínico)

Para la evaluación del *Head* A, cuya misión es el triaje binario (benigno vs. maligno), la matriz se reduce a un formato de 2×2 que define cuatro estados fundamentales con implicaciones clínicas directas:

- **Verdaderos Positivos (VP).** El modelo identifica correctamente una lesión maligna (MEL, BCC o SCC). Es el éxito del sistema en su función de alarma.
- **Verdaderos Negativos (VN).** El modelo confirma correctamente que una lesión es benigna. Reduce la carga asistencial innecesaria.
- **Falsos Positivos (FP) — Error de Tipo I.** El modelo etiqueta como maligna una lesión que realmente es benigna. En clínica, esto se traduce en una biopsia o una derivación al especialista innecesaria, generando estrés en el paciente y gasto de recursos, pero sin riesgo vital.
- **Falsos Negativos (FN) — Error de Tipo II.** Es el escenario crítico. El modelo etiqueta como benigna una lesión que en realidad es un cáncer. Clínicamente, esto implica enviar a un paciente con un melanoma a casa sin tratamiento. **Es la métrica que este proyecto busca minimizar de forma prioritaria.**

7.2.2 Formulación multiclase (Cabeza B: Diagnóstico Diferencial)

Para el *Head* B, la evaluación se vuelve más compleja al enfrentarse a una matriz de 6×6 correspondiente a las seis clases maestras (NV, MEL, BCC, SCC, BKL, BG).

En esta formulación, la diagonal principal de la matriz representa los aciertos del modelo para cada patología. Sin embargo, el valor de esta matriz para un dermatólogo reside en los elementos fuera de la diagonal, que revelan la confusión semántica del modelo:

- Permite identificar si el modelo confunde sistemáticamente el **Melanoma (MEL)** con las **Queratosis Benignas (BKL)**. Dado que las BKL son las "grandes simuladoras" visuales, una alta concentración de valores en esa intersección indicaría que el modelo necesita mejorar su capacidad de extracción de texturas finas.
- Ayuda a distinguir si la red es capaz de diferenciar entre distintos tipos de cáncer no-melanoma, como el **BCC** y el **SCC**, lo cual tiene implicaciones directas en el tipo de cirugía que se programará.

En un escenario multiclase desbalanceado, la Matriz de Confusión es la que permite verificar que el modelo no está simplemente desplazando las predicciones hacia la clase mayoritaria (*Background* o Nevus), sino que realmente está trazando fronteras de decisión para cada una de las seis estirpes celulares.

7.3 Métricas de evaluación deterministas

Una vez definida la matriz de confusión, es necesario extraer indicadores numéricos que permitan cuantificar el rendimiento del modelo. En este proyecto, estas métricas no se analizan de forma aislada, sino que se interpretan según la función diagnóstica de cada una de las dos cabezas de la red.

7.3.1 La trampa de la Exactitud (*Accuracy*) en imagen médica

La exactitud (*Accuracy*) es la métrica más intuitiva, pues representa la fracción de predicciones correctas sobre el total de muestras:

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN} \tag{7.3.1}$$

Sin embargo, en el contexto del diagnóstico de cáncer de piel con el *dataset* ISIC, la exactitud es una métrica profundamente engañosa. Debido al desbalanceo de clases (donde aproximadamente el 88 % de las imágenes son benignas), un modelo "perezoso" que se limitara a clasificar sistemáticamente todas las lesiones como benignas sin analizar un solo píxel obtendría un 88 % de *Accuracy*.

Desde un punto de vista matemático, el modelo parecería exitoso, pero desde un punto de vista clínico sería un desastre absoluto, ya que su capacidad para detectar melanomas sería del 0 %. Por esta razón, en este trabajo el *Accuracy* se relega a un segundo plano, utilizándose únicamente como una métrica de control y nunca como el criterio principal para validar la eficacia del sistema.

7.3.2 Sensibilidad (*Recall*): La métrica prioritaria

La Sensibilidad (o *Recall*) representa la capacidad del modelo para detectar correctamente todos los casos positivos reales (lesiones malignas):

$$\text{Recall} = \frac{VP}{VP + FN} \tag{7.3.2}$$

En la arquitectura propuesta, el *Recall* es la métrica reina para el *Head* A (triaje). En una herramienta de cribado clínico, el coste de oportunidad de un falso negativo (un cáncer ignorado) es infinitamente superior al de un falso positivo (una lesión benigna enviada a revisión).

Priorizar el *Recall* asegura que el sistema actúe como una red de seguridad térmica: es preferible que el modelo "levante la bandera roja" ante una lesión sospechosa que resulte ser benigna, a que permita que un melanoma pase desapercibido y progrese hacia una metástasis por falta de tratamiento temprano. Un alto *Recall* en el *Head* A garantiza la seguridad del paciente.

7.3.3 Especificidad y Precisión

Aunque la prioridad es la sensibilidad, un modelo que clasifique todo como cáncer tampoco sería útil, ya que saturaría los servicios de dermatología. Para equilibrar el sistema, se introducen la especificidad y la precisión:

- **Especificidad.** Mide la capacidad del modelo para identificar correctamente los casos negativos (lesiones benignas).

$$\text{Especificidad} = \frac{VN}{VN + FP} \tag{7.3.3}$$

  Una alta especificidad en este proyecto asegura que los pacientes con nevus comunes o lesiones queratósicas inocuas no sean sometidos a la ansiedad de un diagnóstico de sospecha de cáncer ni a procedimientos quirúrgicos innecesarios.
- **Precisión (*Precision*).** Representa la fiabilidad de las alertas positivas del modelo.

$$\text{Precision} = \frac{VP}{VP + FP} \tag{7.3.4}$$

  Responde a la pregunta: "De todas las veces que el modelo dijo que era cáncer, £cuántas veces lo fue realmente?". Una precisión baja implica un alto volumen de "falsas alarmas".

En la práctica clínica, existe un compromiso o *trade-off* constante: al intentar maximizar el *Recall* para no perder ningún cáncer, la precisión suele disminuir. El desafío de este proyecto y la configuración de sus funciones de pérdida (como la *Focal Loss*) es encontrar el punto de equilibrio donde el *Recall* sea lo suficientemente alto para garantizar la seguridad, sin que la precisión caiga a niveles que invaliden la utilidad logística del sistema en un hospital.

7.4 Métricas agregadas y de promediado

En problemas de clasificación compleja, evaluar la precisión y la sensibilidad por separado puede ofrecer una visión fragmentada del rendimiento. Para obtener una calificación única que resuma la calidad del modelo, se recurre a métricas agregadas que combinan los diferentes tipos de error en un solo valor escalar.

7.4.1 El *F1-Score* como medida de equilibrio

El *F1-Score* es la media armónica entre la precisión y la sensibilidad (*Recall*). A diferencia de la media aritmética simple, la media armónica penaliza de forma extrema los valores bajos. Esto significa que, para obtener un *F1-Score* alto, el modelo debe ser capaz de obtener buenos resultados tanto en precisión como en sensibilidad de forma simultánea.

La fórmula matemática se define como:

$$F1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} \tag{7.4.1}$$

En este proyecto, el *F1-Score* es fundamental porque evita el sesgo de optimización. Un modelo que tenga una sensibilidad perfecta (detecta todos los cánceres) pero una precisión pésima (clasifica todo como cáncer) tendrá un *F1-Score* bajo. Esta métrica obliga a la red neuronal a ser "selectiva" y "efectiva" al mismo tiempo, buscando un punto de equilibrio que sea viable para la práctica dermatológica real.

7.4.2 Estrategias de promediado: *Micro* vs. *Macro F1-Score*

Cuando el problema se traslada al escenario multiclase del ***Head* B** —donde el modelo debe distinguir entre seis patologías distintas— surge el dilema de cómo agregar los resultados de cada clase en un único indicador global. Existen dos estrategias principales:

1. ***Micro F1-Score.*** Calcula el rendimiento global contando el total de verdaderos positivos, falsos negativos y falsos positivos de todas las clases combinadas. En un *dataset* tan desbalanceado como el ISIC, el *Micro F1* se ve fuertemente influenciado por la clase mayoritaria (lesiones benignas). Un éxito en la detección de 20.000 nevus comunes eclipsaría matemáticamente el fracaso en la detección de 100 melanomas.
2. ***Macro F1-Score.*** Calcula el *F1-Score* de cada una de las seis clases de forma independiente y luego realiza una media aritmética simple de esos valores:

$$F1_{\text{macro}} = \frac{1}{N} \sum_{i=1}^{N} F1_i \tag{7.4.2}$$

Justificación clínica de la elección del *Macro F1-Score*:

En el desarrollo de este sistema, se ha seleccionado el ***Macro F1-Score*** como la métrica principal de optimización en Optuna y en la evaluación final. Esta decisión es estratégica: el promediado *Macro* otorga el mismo peso específico a cada categoría, independientemente de cuántas imágenes tenga en el *dataset*.

Desde una perspectiva médica, acertar un caso de **Carcinoma Espinocelular (SCC)** —clase muy minoritaria— tiene la misma importancia algorítmica para el *Macro F1* que acertar un caso de **Nevus (NV)** —clase muy mayoritaria—. Al utilizar esta métrica, se obliga a la inteligencia artificial a esforzarse por aprender las características sutiles de los cánceres más raros, impidiendo que el modelo se vuelva "perezoso" y se limite a especializarse únicamente en las patologías más frecuentes. Es, en esencia, una garantía matemática de que el sistema respeta la diversidad de la patología cutánea.

7.5 Evaluación probabilística de la red

A diferencia de las métricas deterministas, que evalúan al modelo tras aplicar un umbral de decisión rígido (típicamente $0,5$), la evaluación probabilística analiza la capacidad de la red para asignar probabilidades coherentes. En el *Head* A, el modelo no emite un veredicto absoluto, sino una probabilidad de malignidad comprendida entre 0 y 1. Evaluar esta salida bruta es esencial para entender el potencial real del sistema antes de tomar decisiones operativas.

7.5.1 Curva ROC (*Receiver Operating Characteristic*)

La curva ROC es una representación gráfica de la capacidad diagnóstica de un clasificador binario a medida que se varía su umbral de discriminación. Se construye enfrentando dos variables en un eje de coordenadas:

- **Eje Y (Sensibilidad):** La fracción de verdaderos positivos.
- **Eje X (1 — Especificidad):** La fracción de falsos positivos.

La curva ROC describe el compromiso (*trade-off*) entre atrapar todos los cánceres y no generar demasiadas falsas alarmas. En dermatología clínica, un punto en la esquina superior izquierda representaría el "diagnosticador perfecto" (100 % de sensibilidad y 100 % de especificidad). La forma de la curva en este proyecto permite identificar visualmente si el modelo es robusto: una curva que se eleva rápidamente hacia el margen superior indica que la red es capaz de identificar la mayoría de las lesiones malignas incurriendo en muy pocos errores de tipo I.

7.5.2 Área Bajo la Curva (AUC) como medida de separabilidad

El Área Bajo la Curva (*Area Under the Curve* o AUC-ROC) es el valor escalar que resume la información de la curva ROC. Su valor oscila entre $0,5$ (un modelo que predice al azar, equivalente a lanzar una moneda) y $1,0$ (un modelo que separa perfectamente ambas clases).

Matemáticamente, el AUC tiene una interpretación estadística muy potente en el contexto médico: representa la probabilidad de que, ante un par de muestras elegidas al azar (una maligna y otra benigna), el modelo asigne una puntuación de riesgo más alta a la lesión maligna que a la benigna.

Justificación del AUC como métrica de referencia para el *Head* A:

En el desarrollo de este sistema de triaje, el AUC se considera la métrica de rendimiento más fiable por las siguientes razones:

1. **Independencia del umbral.** A diferencia del *F1-Score* o el *Accuracy*, que dependen de un umbral arbitrario, el AUC evalúa la calidad de la **separabilidad** de la red. Indica qué tan bien "entiende" el modelo la diferencia entre un melanoma y un

nevus, independientemente de dónde se decida establecer el límite para la derivación clínica.

2. **Invarianza al desbalanceo.** El AUC no se ve distorsionado por la alta prevalencia de casos benignos en el *dataset* ISIC. Al evaluar el *ranking* relativo entre clases, ofrece una medida de la capacidad intrínseca del sistema para no ignorar los casos de cáncer.

En conclusión, mientras que otras métricas informan sobre cómo se comporta el modelo bajo una configuración fija, el AUC revela el potencial diagnóstico máximo que se puede extraer del *Head* A, permitiendo confirmar que el sistema ha aprendido patrones biológicos reales y no sesgos estadísticos.

7.6 Ajuste del Umbral de Decisión y Factor de Seguridad Clínico

La salida de la red neuronal en el *Head* A no es una clasificación binaria directa, sino una probabilidad continua $P(y = 1|x)$ en el intervalo $[0, 1]$. Para transformar esta probabilidad en un veredicto diagnóstico, es necesario aplicar un umbral de decisión (τ):

$$\hat{y} = \begin{cases} 1 & \text{si } P(y = 1|x) \geq \tau \\ 0 & \text{si } P(y = 1|x) < \tau \end{cases} \tag{7.6.1}$$

En la mayoría de los problemas de aprendizaje automático generalista, se utiliza un **umbral neutral matemático de** $0,5$. Sin embargo, en dermatología oncológica, este umbral es insuficiente y potencialmente peligroso. La asimetría en el coste de los errores dicta que un falso negativo (omitir un cáncer) es órdenes de magnitud más grave que un falso positivo (realizar una biopsia innecesaria).

Por ello, en este proyecto se introduce el concepto de **Factor de Seguridad Clínico**. En lugar de aceptar el umbral por defecto, se analiza la curva ROC para seleccionar un τ más conservador (situado habitualmente entre $0,2$ y $0,3$).

Al desplazar el umbral hacia la izquierda, se obliga al modelo a ser más "desconfiado": ante la mínima evidencia visual de malignidad, el sistema emitirá una alerta. Aunque esta decisión reduce la especificidad y aumenta las falsas alarmas, garantiza que el sistema cumpla con su función primordial de triaje: no permitir que ningún paciente con una lesión maligna sea enviado a casa sin una revisión especializada. Es la traducción matemática del principio médico *primum non nocere*.

7.7 Justificación clínica de la estrategia de evaluación final

Como cierre de este marco metodológico de evaluación, es imperativo justificar por qué se ha optado por una estrategia de métricas diferenciada para cada una de las dos

cabezas del modelo. Esta decisión responde a la necesidad de simular el flujo de trabajo de una unidad de dermatología real.

1. **Cabeza A (El "Escudo de Seguridad").** Para esta rama de triaje, la evaluación se centra de forma absoluta en el *Recall* y el AUC. El objetivo es la robustez en la detección. No se busca que el modelo sea un diagnosticador infalible, sino que sea un detector de riesgo impecable. Un AUC alto en esta fase asegura que la red tiene la capacidad intrínseca de separar el cáncer de la salud, permitiendo ajustar los umbrales para maximizar la supervivencia del paciente.
2. **Cabeza B (El "Especialista Virtual").** Una vez que la Cabeza A ha detectado el riesgo, la Cabeza B entra en juego para el diagnóstico diferencial. Aquí, la métrica prioritaria es el ***Macro F1-Score***. Al promediar el rendimiento de forma equitativa entre las seis clases maestras, se garantiza que el sistema sea un experto equilibrado. El uso del *Macro F1* impide que el modelo ignore patologías menos frecuentes pero igualmente peligrosas, como el Carcinoma Espinocelular (SCC), asegurando que el especialista humano reciba una sugerencia diagnóstica no sesgada por la prevalencia estadística de los nevus comunes.

En conclusión, la sinergia entre estas métricas permite validar un sistema que es, a la vez, seguro (gracias al *Recall* en el triaje) y preciso (gracias al *Macro F1* en el diagnóstico). Esta estrategia de evaluación cruzada garantiza que los resultados presentados en los capítulos posteriores no son meras estadísticas optimistas, sino indicadores de una herramienta con potencial de asistencia clínica real en el cribado del cáncer de piel.

Capítulo 8

Diseño de la Red Implementada

8.1 Arquitectura Global del Sistema de Fusión Triple

El sistema propuesto se fundamenta en un esquema de fusión tardía (*Late Fusion*). El grafo computacional se organiza en tres ramas expertas independientes que operan en paralelo para extraer vectores de características (*embeddings*) de alta dimensionalidad:

- **Rama 1 (Metadatos):** Un Perceptrón Multicapa (MLP) que procesa variables tabulares.
- **Rama 2 (ARP):** Una Red Neuronal Convolucional (CNN) optimizada para el espacio polar.
- **Rama 3 (RGB):** Un sistema híbrido que integra un Transformador de Visión (ViT) y una arquitectura residual (ResNet18).

Una vez que cada rama genera su propio vector de rasgos, estos se concatenan en un único tensor multimodal que alimenta a las dos cabezas de decisión finales (*Dual-Head*). Este enfoque de integración tardía es fundamental para evitar el olvido catastrófico de características visuales al introducir datos clínicos y permite que el modelo mantenga una visión de "rayos X" estructural combinada con el contexto epidemiológico del paciente.

8.2 Rama 1: Percepción Clínica (Metadatos MLP)

La primera rama del sistema actúa como un anclaje epidemiológico. Su función es transformar las variables demográficas y clínicas en una señal probabilística previa que condicione la interpretación visual de la red.

8.2.1 Topología del Perceptrón Multicapa Compartido

Basándose en la implementación del *script* `metadata_model.py`, la rama de metadatos se ha diseñado como un Perceptrón Multicapa (MLP) de dos etapas con un extractor de características compartido. La red recibe un vector de entrada de 13 dimensiones que contiene la edad aproximada y los datos codificados mediante *One-Hot Encoding* (sexo y localización anatómica).

La arquitectura interna se detalla a continuación:

- **Capa de Entrada y Expansión.** Una capa lineal de $13 \rightarrow 128$ neuronas. Esta capa proyecta los datos clínicos dispersos a un espacio de mayor dimensión para facilitar la búsqueda de correlaciones no lineales.
- **Estabilización y Activación.** Se aplica una capa de **Batch Normalization** seguida de la función de activación **GELU** (*Gaussian Error Linear Unit*). A diferencia de ReLU, GELU proporciona una transición más suave en el origen, mejorando el flujo del gradiente en modelos que combinan metadatos con transformadores.
- **Regularización.** Se ha incluido un **Dropout de** $0,3$ para evitar que la red dependa excesivamente de una única variable clínica (como la edad) y fuerce la distribución del peso diagnóstico.
- **Capa de Compresión y Salida.** Una segunda etapa lineal de $128 \rightarrow 64$ neuronas con **Dropout de** $0,2$, *BatchNorm* y GELU. El resultado final es un vector de rasgos de 64 dimensiones que condensa la información del paciente antes de la bifurcación de las cabezas diagnósticas.

8.2.2 Sintonización de Hiperparámetros (Optuna)

La configuración final de esta rama no ha sido arbitraria, sino el resultado de un estudio de optimización bayesiana mediante Optuna. Tras ejecutar múltiples iteraciones (*trials*), se determinaron los siguientes parámetros óptimos para garantizar la convergencia:

- **Tasa de Aprendizaje (LR):** $\sim 0,00406$.
- **Decaimiento de Pesos (*Weight Decay*):** $\sim 0,00095$ bajo el optimizador Adam.
- **Estrategia de Funciones de Pérdida:** Para esta rama, se implementó una ***Weighted CrossEntropy*** (Entropía Cruzada Ponderada) para el diagnóstico multiclase (*Head* B).

Justificación de la elección de *Weighted CE* frente a *Focal Loss*:

Aunque la *Focal Loss* es superior en el procesamiento de imágenes complejas, los experimentos con Optuna demostraron que, para la rama de metadatos tabulares, la ***Weighted CrossEntropy*** ofrecía una convergencia más estable. Ello se debe a que el desbalanceo en los metadatos es lineal y directo; aplicar un castigo basado en la frecuencia inversa de las clases resultó ser más efectivo para que el MLP no ignorara las prevalencias de cánceres minoritarios (como el SCC con peso $12,76$) en comparación con el factor modulador dinámico de la *Focal Loss*.

8.3 Rama 2: Análisis Estructural (CNN ARP)

La segunda rama del sistema multimodal procesa las imágenes resultantes de la transformación a coordenadas polares. Al ser imágenes que representan la topología de la lesión en lugar de su colorimetría, se ha implementado una Red Neuronal Convolucional

(CNN) específica diseñada para operar sobre un único canal de información (escala de grises).

8.3.1 Arquitectura Convolucional Personalizada

La arquitectura, denominada `ARPCNN6Class`, ha sido construida desde cero para maximizar la detección de irregularidades estructurales. El grafo computacional de esta rama se divide en cuatro bloques de extracción de rasgos y una etapa de agregación global:

- **Bloques de extracción (Convolución y Estabilización).** La red consta de cuatro bloques secuenciales. Cada bloque integra una capa de convolución con filtros de 3×3, una capa de *Batch Normalization* para estabilizar la distribución de los rasgos y una operación de *Max Pooling* de 2×2 para reducir la dimensionalidad espacial.
  1. **Bloque 1:** Procesa la entrada de $224 \times 224 \times 1$ y genera 32 mapas de características a 112×112.
  2. **Bloque 2:** Expande la profundidad a 64 canales y reduce el tamaño a 56×56.
  3. **Bloque 3:** Alcanza los 128 canales en una resolución de 28×28.
  4. **Bloque 4:** Culmina en 256 canales con una resolución final de 14×14.
- **Mejora arquitectónica: *Global Average Pooling* (GAP).** Para evitar el uso de capas densas masivas que dispararían el número de parámetros —evitando aproximadamente 25 millones de conexiones ineficientes—, se ha implementado una capa de `AdaptiveAvgPool2d`. Esta técnica colapsa cada uno de los 256 mapas de 14×14 a un único valor promedio, generando un vector de rasgos compacto y robusto frente a traslaciones en el eje polar.
- **Clasificador y *Dual-Head*.** Tras la agregación, la red cuenta con una capa lineal compartida de 128 neuronas protegida por un **Dropout de** $0,4$. Finalmente, el flujo se bifurca en las dos cabezas diagnósticas:
  - ***Head* A:** Una salida lineal para el riesgo binario.
  - ***Head* B:** Seis salidas para el diagnóstico multiclase diferencial.

8.3.2 Sintonización de Hiperparámetros (Optuna)

Dada la sensibilidad de los filtros convolucionales a la señal de las imágenes ARP, se realizó una búsqueda exhaustiva mediante Optuna enfocada en la estabilidad de la convergencia. Los resultados del experimento 36 (*Trial 36*) fueron identificados como óptimos y se utilizaron para el entrenamiento final del sistema:

- **Optimizador AdamW.** A diferencia de la rama de metadatos, aquí se optó por **AdamW** para desacoplar el decaimiento de pesos (*Weight Decay*) de la actualización del gradiente, mejorando la generalización sobre los bordes de la lesión.
- **Valores óptimos:**

- **Tasa de Aprendizaje (LR):** $\sim 8,995 \times 10^{-5}$.
- ***Weight Decay* (WD):** $\sim 5,142 \times 10^{-5}$.
- **Tamaño de lote (*Batch Size*):** 64 imágenes, optimizando el uso de la VRAM y la estabilidad de los gradientes.

La búsqueda también exploró el uso de factores de castigo para las clases malignas dentro de la función de pérdida. Optuna validó que aplicar un multiplicador a los pesos de las clases MEL, BCC y SCC permitía que la rama estructural ARP fuese significativamente más sensible a las irregularidades geométricas propias de los carcinomas y melanomas, compensando el desbalanceo natural del *dataset*.

8.4 Rama 3: Percepción Visual Híbrida (RGB)

Esta rama procesa imágenes dermatoscópicas estándar en color (RGB) de 224×224 píxeles. El objetivo es obtener una representación vectorial exhaustiva de la lesión mediante la concatenación de dos descriptores distintos que capturan diferentes escalas de información visual.

8.4.1 Extracción de rasgos locales: ResNet18

Para la captura de biomarcadores visuales de baja escala, como la regularidad de los bordes, el retículo pigmentario o las estructuras vasculares, se ha integrado una *ResNet18* como extractor de características convolucional.

- **Topología y *Transfer Learning*.** Se utiliza una implementación de `torchvision` preentrenada en ImageNet. Para adaptar la red como extractor puro, se han eliminado las dos últimas capas (la capa de promediado global y la capa completamente conectada original), manteniendo únicamente los bloques residuales encargados de la extracción de mapas de características.
- **Salida de la sub-rama.** Tras los bloques residuales, se aplica una capa de `AdaptiveAvgPool2d` que colapsa la información espacial en un vector de rasgos de 512 dimensiones. Esta arquitectura es ideal para detectar patrones locales repetitivos que definen la textura de las lesiones cutáneas.

8.4.2 Modelado de relaciones globales: Vision Transformer (ViT)

En paralelo a la CNN, se ha implementado un *Vision Transformer* (ViT-Base) mediante la librería `timm` para capturar la coherencia global y las relaciones espaciales a larga distancia de la lesión.

- **Arquitectura ViT.** Se utiliza el modelo `vit_base_patch16_224`, el cual divide la imagen en parches de 16×16 píxeles. Estos parches son procesados mediante mecanismos de autoatención global, permitiendo que la red entienda la asimetría

estructural de la lesión completa, superando las limitaciones de los campos receptivos de las CNN convencionales.

- **Salida de la sub-rama.** El ViT genera un vector de rasgos de 768 dimensiones.
- **Fusión híbrida interna.** Los vectores de la *ResNet* (512) y del ViT (768) se concatenan en una etapa de fusión tardía interna para formar un tensor de 1280 dimensiones. Este vector combinado se somete a un **Dropout de** $0,4$ antes de alimentar a las cabezas diagnósticas *Dual-Head* (*Head* A para riesgo binario y *Head* B para clasificación de seis clases).

8.4.3 Sintonización de hiperparámetros (Optuna)

Dada la alta complejidad de esta rama híbrida y su elevado número de parámetros (aproximadamente 97 millones), el proceso de optimización se diseñó para ser extremadamente eficiente y evitar la denominada "maldición de la dimensionalidad".

- **Estrategia de búsqueda reducida.** Tras realizar análisis de importancia funcional (fANOVA) en etapas previas, se decidió centrar la búsqueda en Optuna únicamente en los tres parámetros con mayor impacto en el rendimiento: el *base_lr*, el *weight_decay* y el parámetro γ de la *Focal Loss*.
- **Justificación de parámetros fijos.** Otros parámetros, como la tasa de abandono (*dropout*), las épocas de congelación inicial (LP) y los divisores de la tasa de aprendizaje diferencial, se fijaron a valores constantes basados en la literatura técnica y experimentos preliminares. Esta decisión estratégica permitió concentrar el poder de cómputo del algoritmo bayesiano en las variables de mayor impacto.
- **Rangos de búsqueda.** Se exploraron rangos logarítmicos para la tasa de aprendizaje (1×10^{-5} a 5×10^{-4}) y el decaimiento de pesos (1×10^{-4} a 1×10^{-2}), mientras que para γ se buscó un valor entre $2,0$ y $5,0$ para compensar el desbalanceo de clases.

Configuración óptima seleccionada:

A falta de completar el ciclo total de ejecuciones, los hiperparámetros identificados como candidatos para el modelo final son:

- ***Base Learning Rate* (LR):** `[VALOR_LR]` (fijado temporalmente en 1×10^{-4}).
- ***Weight Decay* (WD):** `[VALOR_WD]` (fijado temporalmente en 1×10^{-4}).
- **Gamma (γ):** `[VALOR_GAMMA]` (fijado temporalmente en $2,0$).

8.5 Integración y Toma de Decisión (*Late Fusion*)

Tras el procesamiento independiente de las tres ramas expertas, el sistema debe consolidar la información para emitir un veredicto diagnóstico. Se ha optado por una estrategia de Fusión Tardía (*Late Fusion*), la cual permite que cada modalidad alcance un nivel de abstracción profundo antes de ser combinada, evitando que el ruido de una

rama (por ejemplo, una imagen de baja calidad) corrompa prematuramente la señal de las demás.

8.5.1 Concatenación de tensores multimodales

La integración se realiza mediante la concatenación de los vectores de rasgos (*embeddings*) generados por los tres extractores. El resultado es un vector multimodal de 1472 dimensiones, compuesto de la siguiente forma:

- **Rama RGB:** Aporta 1280 dimensiones (768 del *ViT-Base* y 512 de la *ResNet18*).
- **Rama ARP:** Aporta 128 dimensiones tras su procesamiento convolucional y geométrico.
- **Rama de Metadatos:** Aporta 64 dimensiones que contienen el contexto demográfico.

Este tensor unificado representa el conocimiento total del sistema sobre el paciente, integrando textura, geometría, contexto global y antecedentes clínicos en un único espacio vectorial de alta dimensionalidad.

8.5.2 Topología de las Cabezas de Decisión (*Dual-Head*)

Para simular el flujo de decisión médico, el vector fusionado alimenta a una arquitectura de Doble Cabeza (*Dual-Head*). Ambas cabezas operan en paralelo, pero están diseñadas para responder a objetivos clínicos distintos:

1. ***Head* A (Triaje Binario).** Implementada como una capa lineal de $1472 \rightarrow 1$. Emite un único valor real (*Logit*) cuya interpretación probabilística mediante una función Sigmoide determina el riesgo de malignidad. Su diseño está optimizado para la detección temprana y la activación de alertas de derivación urgente.
2. ***Head* B (Diagnóstico Multiclase).** Implementada como una capa lineal de $1472 \rightarrow 6$. Proporciona seis valores brutos correspondientes a las seis clases maestras (NV, MEL, BCC, SCC, BKL, BG). Su función es el diagnóstico diferencial especializado, permitiendo identificar la estirpe celular exacta de la lesión.

8.6 Modelado Matemático del Entrenamiento Combinado

El éxito del sistema multimodal no depende solo de su arquitectura, sino de una formulación matemática del aprendizaje que respete las jerarquías de los datos y la seguridad del paciente.

8.6.1 Funciones de pérdida asimétricas e híbridas

Se ha diseñado un objetivo de optimización híbrido que combina dos funciones de pérdida para gestionar el desbalanceo y la criticidad médica:

- **Pérdida para el *Head* A (`BCEWithLogitsLoss`).** Se utiliza Entropía Cruzada Binaria combinada con un Factor de Castigo Clínico (`pos_weight`). Calcular la pérdida directamente sobre los *logits* garantiza una estabilidad numérica superior. El factor de castigo se ajusta para penalizar los falsos negativos con mayor severidad, forzando a la red a maximizar la sensibilidad diagnóstica.
- **Pérdida para el *Head* B (`WeightedCrossEntropy`).** Para la clasificación de las seis clases, se utiliza una Entropía Cruzada Ponderada. Basándose en los experimentos con Optuna, esta función demostró ser más estable que la *Focal Loss* en el modelo multimodal fusionado. Los pesos se calculan mediante la inversa de la frecuencia de clase, asegurando que el modelo otorgue la misma relevancia algorítmica a un melanoma que a un *nevus* común.

8.6.2 Aprendizaje Jerárquico mediante *Differential Learning Rates*

Siguiendo las directrices de Kumar et al. (2022) sobre la preservación de características preentrenadas, se ha implementado un esquema de Tasas de Aprendizaje Diferenciales (DLR). Este enfoque reconoce que los componentes de la red deben aprender a velocidades distintas según su naturaleza:

- **Nivel de Alta Velocidad ($LR/1$).** Aplicado a las cabezas de decisión finales. Al ser capas inicializadas aleatoriamente, requieren una adaptación rápida para aprender a interpretar la fusión de las tres ramas de información.
- **Nivel de Velocidad Robusta ($LR/10$).** Aplicado a las ramas convolucionales (*ResNet18* y *ARP CNN*) y al MLP de metadatos. Estas estructuras poseen sesgos inductivos que permiten refinarse sin colapsar matemáticamente.
- **Nivel de Velocidad Crítica ($LR/100$).** Aplicado exclusivamente al *Vision Transformer* (ViT). Una tasa de aprendizaje restrictiva asegura que sus mapas de atención global se ajusten microscópicamente a la dermatología sin sufrir el fenómeno del olvido catastrófico.

Este modelado jerárquico garantiza que el conocimiento previo de los extractores actúe como una base sólida para la decisión clínica, evitando que sea sobrescrito por el ruido del entrenamiento inicial.

8.7 Tácticas de Optimización y Rendimiento de Hardware

La complejidad del sistema multimodal propuesto exige una orquestación precisa entre la CPU y la GPU para evitar cuellos de botella y asegurar que el modelo converja en un tiempo razonable sin exceder los límites de memoria.

8.7.1 Regularización por *Modality Dropout*

En sistemas de fusión tardía (*Late Fusion*), existe el riesgo de que el modelo desarrolle una dependencia excesiva hacia la rama más rica en información (típicamente la RGB), ignorando las señales sutiles de los metadatos o la estructura ARP. Para mitigar este fenómeno, se ha explorado la técnica de ***Modality Dropout***.

Esta técnica consiste en "apagar" aleatoriamente una de las ramas durante el entrenamiento, poniendo a cero su vector de rasgos antes de la concatenación final. Al forzar a las cabezas de decisión a clasificar la lesión contando únicamente con la información parcial de las ramas restantes, se obliga a la red a extraer el máximo valor de cada modalidad. Clínicamente, esto dota al modelo de una robustez superior, permitiéndole emitir diagnósticos fiables incluso ante la ausencia de alguna fuente de datos (por ejemplo, un paciente sin historial clínico previo).

8.7.2 Prevención de *GPU Starvation*: *Prefetch* y Múltiples *Workers*

Uno de los problemas detectados en las fases iniciales fue el *GPU Starvation* (inanición de la GPU), donde la tarjeta gráfica permanecía inactiva esperando a que la CPU terminara de procesar y cargar las imágenes. Para solucionar esto y optimizar el flujo de datos, se configuraron los `DataLoaders` de PyTorch con las siguientes directrices:

- ***Multi-processing Loading*** **(`num_workers`).** Se asignaron múltiples hilos de procesamiento para la carga y transformación de imágenes en paralelo, asegurando que el siguiente lote (*batch*) esté siempre listo en la memoria RAM antes de que la GPU termine el cálculo actual.
- ***Pin Memory*** **y** ***Prefetch.*** Se activó la propiedad `pin_memory=True` para acelerar la transferencia de tensores desde la memoria del sistema a la memoria de la GPU, reduciendo la latencia de copia de datos a través del bus PCIe.

8.7.3 Escalado de memoria: *Gradient Accumulation* y *Mixed Precision* (AMP)

Debido al gran volumen de parámetros de la arquitectura híbrida (aproximadamente 97 millones), el entrenamiento con lotes grandes era inviable en el *hardware* convencional. Para superar esta limitación física sin sacrificar la estabilidad del gradiente, se implementaron dos tácticas críticas:

1. **Precisión Mixta Automática (AMP).** Implementada mediante `torch.cuda.amp`. Esta técnica permite realizar la mayoría de las operaciones matemáticas en formato de coma flotante de 16 bits (FP16) en lugar de los 32 bits tradicionales (FP32). El uso de AMP ha permitido:
    - Reducir el consumo de VRAM en casi un 50 %, permitiendo que el *Vision Transformer* y la *ResNet18* coexistan en la memoria gráfica.

- Acelerar el entrenamiento hasta en un 2× al aprovechar los *Tensor Cores* de la arquitectura NVIDIA.
- Mantener la precisión del modelo mediante un escalador de gradientes (`GradScaler`) que evita el desvanecimiento numérico en las capas críticas.

2. **Acumulación de Gradientes (*Gradient Accumulation*).** Para simular el efecto de entrenar con lotes de 64 o 128 imágenes cuando la memoria solo permitía físicamente lotes de 16 o 32, se optó por acumular los gradientes durante varios pasos antes de actualizar los pesos. Esta solución permite obtener una estimación del gradiente mucho más estable, lo cual es vital para la convergencia en el complejo paisaje de pérdida de un modelo de tres ramas.

Gracias a estas optimizaciones de bajo nivel, el sistema es capaz de procesar la totalidad del *dataset* con una eficiencia máxima, garantizando que el tiempo de investigación se invierta en la mejora de la arquitectura y no en esperas computacionales improductivas.

Capítulo 9

Evaluación, resultados y discusión

9.1 Configuración experimental

9.2 Resultados obtenidos

9.3 Comparativa entre configuraciones

9.4 Impacto de la fusión multimodal

9.5 Impacto del desbalanceo

9.6 Discusión de resultados

9.7 Limitaciones del estudio

Capítulo 10

Conclusiones y trabajo futuro

10.1 Conclusiones generales

10.2 Contribuciones del trabajo

10.3 Líneas futuras de investigación

Capítulo A

Anexos

A.1 Arquitecturas completas

A.2 Hiperparámetros

A.3 Diagramas adicionales