Título del Trabajo de Fin de Grado

Nombre del Autor

15 de abril de 2026

Resumen

Abstract

Agradecimientos

Índice general

Resumen **1**

Abstract **2**

Agradecimientos **3**

1. Introducción y justificación **11**

1.1. Contexto clínico e importancia del diagnóstico precoz del cáncer de piel . . 11
1.2. Limitaciones del diagnóstico visual tradicional 11
1.3. Aplicación de la inteligencia artificial en dermatología 11
1.4. Motivación del trabajo 11
1.4.1. Justificación técnica del enfoque propuesto 11
1.4.2. Justificación académica y social del estudio 11
1.5. Objetivos del trabajo 11
1.5.1. Objetivo general 11
1.5.2. Objetivos específicos 11
1.6. Alcance y delimitaciones del trabajo 11
1.7. Organización de la memoria 11

2. Estado del arte **12**

2.1. Introducción al estado del arte en clasificación de lesiones cutáneas 13
2.2. Métodos clásicos de diagnóstico asistido por ordenador 13
2.2.1. Extracción manual de características 13
2.2.2. Clasificadores tradicionales 13
2.3. Redes neuronales convolucionales en dermatología 13
2.3.1. CNN en clasificación de imágenes médicas 13
2.3.2. CNN aplicadas a lesiones cutáneas 13
2.4. Vision Transformers en visión por computador 13
2.4.1. Fundamentos de los Transformers 13
2.4.2. Aplicaciones de ViT en imagen médica 13
2.5. Modelos híbridos CNNTransformer 13
2.5.1. Motivación del enfoque híbrido 13

2.5.2. Resultados reportados en la literatura 13
2.6. Angular Radial Partitioning en análisis de imagen 13
2.6.1. Fundamentos teóricos del ARP 13
2.6.2. Uso de ARP en reconocimiento de patrones 13
2.7. Aprendizaje multimodal en medicina 13
2.7.1. Fusión de imagen y metadatos clínicos 13
2.7.2. Estrategias de fusión temprana, tardía e intermedia 13
2.8. Problemas abiertos en el estado del arte 13
2.8.1. Desbalanceo de clases 13
2.8.2. Heterogeneidad de bases de datos 13
2.8.3. Riesgos de *data leakage* 13
2.9. Posicionamiento del presente trabajo 13

3. Descripción de los datos **14**
3.1. Introducción a las bases de datos dermatológicas 14
3.2. Base de datos SLICE-3D (ISIC 2024 Challenge Dataset) 14
3.2.1. Descripción general 14
3.2.2. Tipos de imágenes 15
3.2.3. Metadatos clínicos disponibles 15
3.3. Base de datos ISIC Archive 16
3.3.1. Descripción general 16
3.3.2. Tipos de imágenes 16
3.3.3. Metadatos clínicos disponibles 16
3.3.4. Diferencias respecto a SLICE-3D 16
3.4. Otras fuentes de datos consideradas 16
3.4.1. HAM10000 16
3.5. Análisis del desbalanceo de clases 17
3.6. Distribución de diagnósticos 17
3.7. Heterogeneidad entre fuentes de datos 17
3.8. Análisis de variables y selección de metadatos 18
3.8.1. Variables demográficas y clínicas básicas (Plan A) 18
3.8.2. Variables de morfología avanzada TBP-LV (Plan B) 18
3.8.3. Identificación de variables de riesgo: Target Leakage y Bias 18
3.9. Identificadores clínicos y prevención de *data leakage* 18
3.10. Consideraciones éticas y de uso de datos 19

4. Metodología **21**
4.1. Enfoque de la investigación: Sistema de Triaje y Diagnóstico Dual 21
4.2. Diseño Experimental y Comparativa de Escenarios 21
4.2.1. Estudio de impacto de metadatos: Plan A vs. Plan B 21

4.2.2. Análisis de granularidad diagnóstica: Regímenes de 3 y 4 clases . . 21
4.3. Paradigma de Aprendizaje Multimodal y Complementariedad 21
4.4. Estrategia de Transferencia de Conocimiento (*Transfer Learning*) 21
4.5. Metodología de Validación y Robustez 21
4.5.1. Prevención de sesgos mediante Partición por Grupos Maestros . . . 21
4.5.2. Validación Cruzada (*5-fold Cross-Validation*) 21
4.6. Criterios de Evaluación y Selección del Modelo Óptimo 21
4.7. Flujo General del Sistema (*Pipeline* de ejecución) 21

5. Entorno de desarrollo y herramientas tecnológicas 22
5.1. Lenguaje de programación 23
5.2. Framework principal de Deep Learning: PyTorch 23
5.2.1. Justificación de la elección de PyTorch 23
5.2.2. Ecosistema Torchvision 23
5.3. Herramientas de procesamiento y manipulación de datos 23
5.3.1. NumPy y Pandas 23
5.3.2. Scikit-Learn 23
5.4. Librerías de visión por computador 23
5.4.1. OpenCV (cv2) y Pillow (PIL) 23
5.5. Librerías de optimización e interpretabilidad 23
5.5.1. Optimización Bayesiana con Optuna 23
5.5.2. Interpretabilidad visual con pytorch-grad-cam 23
5.6. Entorno de ejecución y recursos hardware 23
5.6.1. Configuración del entorno local (VS Code) 23
5.6.2. Limitaciones de VRAM y paralelización 23
5.7. Reproducibilidad y control de versiones 23
5.7.1. Fijación de semillas aleatorias (Seed locking) 23
5.7.2. Registro de métricas y *Logs* 23

6. Ingeniería y preprocesamiento de los datos 24
6.1. Introducción al preprocesamiento 24
6.2. Estrategia de fusión de bases de datos 24
6.3. Armonización de columnas y depuración de variables 24
6.4. Tratamiento de valores faltantes e imputación 24
6.5. Transformación de variables clínicas 24
6.5.1. Codificación categórica (One-Hot Encoding) 24
6.5.2. Normalización numérica 24
6.6. Preprocesamiento y generación de ramas visuales 24
6.6.1. Estandarización de la rama RGB 24
6.6.2. Transformación geométrica: Generación de la rama ARP 24

6.7. Estrategia de partición y prevención de *data leakage* 24
6.7.1. Identificadores clínicos y el *Master Group ID* 24
6.7.2. División de conjuntos de entrenamiento, validación y test 24

7. Métricas de evaluación y ajuste de umbrales 25
7.1. Introducción a la evaluación en escenarios de extremo desbalanceo 25
7.2. La Matriz de Confusión como base evaluativa 25
7.2.1. Formulación binaria (Cabeza A: Triage Clínico) 25
7.2.2. Formulación multiclase (Cabeza B: Diagnóstico Diferencial) 25
7.3. Métricas de evaluación deterministas 25
7.3.1. La trampa de la Exactitud (*Accuracy*) en imagen médica 25
7.3.2. Sensibilidad (*Recall*): La métrica prioritaria 25
7.3.3. Especificidad y Precisión 25
7.4. Métricas agregadas y de promediado 25
7.4.1. El *F1-Score* como medida de equilibrio 25
7.4.2. Estrategias de promediado: *Micro* vs. *Macro F1-Score* 25
7.5. Evaluación probabilística de la red 25
7.5.1. Curva ROC (*Receiver Operating Characteristic*) 25
7.5.2. Área Bajo la Curva (AUC) como medida de separabilidad 25
7.6. Ajuste del Umbral de Decisión y Factor de Seguridad Clínico 25
7.7. Justificación clínica de la estrategia de evaluación final 25

8. Diseño de la Red Implementada 26
8.1. Arquitectura Global del Sistema de Fusión Triple 26
8.2. Rama Visual Híbrida: Extractor RGB (CNN-ViT) 26
8.2.1. Módulo Convolucional: ResNet18 como extractor de rasgos locales . 26
8.2.2. Módulo de Atención: Vision Transformer para relaciones globales . 26
8.3. Rama de Análisis Estructural: Red Convolucional ARP 26
8.4. Rama de Percepción Clínica: Perceptrón Multicapa (MLP) 26
8.5. Integración y Toma de Decisión: *Late Fusion* 26
8.5.1. Topología de las Cabezas de Decisión (Dual-Head) 26
8.6. Modelado Matemático del Entrenamiento 26
8.6.1. Optimización frente al desbalanceo: *Focal Loss* 26
8.6.2. Función de pérdida combinada y ponderación de tareas 26
8.7. Tácticas de Entrenamiento Avanzado 26
8.7.1. Protocolo *Linear Probing* y *Fine-Tuning* global 26
8.7.2. Aprendizaje Jerárquico mediante *Differential Learning Rate* 26
8.7.3. Regularización por *Modality Dropout* 26
8.7.4. Gestión de memoria y *Gradient Accumulation* 26
8.8. Optimización Bayesiana de Hiperparámetros (Optuna) 26

9. Evaluación, resultados y discusión **27**
9.1. Configuración experimental 27
9.2. Resultados obtenidos 27
9.3. Comparativa entre configuraciones 27
9.4. Impacto de la fusión multimodal 27
9.5. Impacto del desbalanceo 27
9.6. Discusión de resultados 27
9.7. Limitaciones del estudio 27

10. Conclusiones y trabajo futuro **28**
10.1. Conclusiones generales 28
10.2. Contribuciones del trabajo 28
10.3. Líneas futuras de investigación 28

A. Anexos **29**
A.1. Arquitecturas completas 29
A.2. Hiperparámetros 29
A.3. Diagramas adicionales 29

Índice de figuras

Índice de cuadros

Capítulo 1

Introducción y justificación

1.1 Contexto clínico e importancia del diagnóstico precoz del cáncer de piel

1.2 Limitaciones del diagnóstico visual tradicional

1.3 Aplicación de la inteligencia artificial en dermatología

1.4 Motivación del trabajo

1.4.1 Justificación técnica del enfoque propuesto

1.4.2 Justificación académica y social del estudio

1.5 Objetivos del trabajo

1.5.1 Objetivo general

1.5.2 Objetivos específicos

1.6 Alcance y delimitaciones del trabajo

1.7 Organización de la memoria

Capítulo 2

Estado del arte

2.1 Introducción al estado del arte en clasificación de lesiones cutáneas

2.2 Métodos clásicos de diagnóstico asistido por ordenador

2.2.1 Extracción manual de características

2.2.2 Clasificadores tradicionales

2.3 Redes neuronales convolucionales en dermatología

2.3.1 CNN en clasificación de imágenes médicas

2.3.2 CNN aplicadas a lesiones cutáneas

2.4 Vision Transformers en visión por computador

2.4.1 Fundamentos de los Transformers

2.4.2 Aplicaciones de ViT en imagen médica

2.5 Modelos híbridos CNNTransformer

2.5.1 Motivación del enfoque híbrido

2.5.2 Resultados reportados en la literatura

2.6 Angular Radial Partitioning en análisis de imagen

2.6.1 Fundamentos teóricos del ARP

2.6.2 Uso de ARP en reconocimiento de patrones

2.7 Aprendizaje multimodal en medicina

2.7.1 Fusión de imagen y metadatos clínicos

2.7.2 Estrategias de fusión temprana, tardía e intermedia

Capítulo 3

Descripción de los datos

3.1 Introducción a las bases de datos dermatológicas

El desarrollo de sistemas de diagnóstico asistido por ordenador basados en aprendizaje profundo depende de manera crítica de la calidad, validez y representatividad de las bases de datos empleadas. En el ámbito de la dermatología, y en particular en el estudio del cáncer de piel, esta dependencia es aún más acusada debido a la elevada variabilidad morfológica de las lesiones cutáneas y a la baja prevalencia relativa de los casos malignos en la población general.

Para que un modelo de *deep learning* resulte clínicamente relevante, no basta con disponer de un gran volumen de imágenes. Es imprescindible que dichas imágenes estén correctamente anotadas, procedan de fuentes fiables y reflejen de forma razonable la distribución real de las patologías, evitando sesgos sistemáticos que puedan comprometer la capacidad de generalización del sistema. Asimismo, el desbalanceo extremo entre clases, habitual en bases de datos médicas, constituye uno de los principales retos metodológicos, ya que puede conducir a modelos con una alta exactitud global pero una sensibilidad reducida en las clases de mayor interés clínico.

En este contexto, el presente trabajo se apoya en bases de datos públicas ampliamente utilizadas y validadas por la comunidad científica, que se combinan de forma controlada con el objetivo de construir un conjunto de datos robusto, multimodal y adecuado para el entrenamiento y la evaluación de arquitecturas profundas complejas.

3.2 Base de datos SLICE-3D (ISIC 2024 Challenge Dataset)

3.2.1 Descripción general

La principal fuente de datos del presente estudio es la base de datos *SLICE-3D*, proporcionada en el marco del *ISIC 2024 Challenge Dataset*. Este conjunto de datos está compuesto por un total de 401 059 imágenes en formato JPEG, lo que lo convierte en una de las colecciones públicas más extensas disponibles actualmente para el análisis

automatizado de lesiones cutáneas.

Las imágenes incluidas en SLICE-3D han sido recopiladas y anotadas siguiendo protocolos estandarizados, lo que garantiza un alto grado de consistencia y fiabilidad en las etiquetas diagnósticas asociadas. No obstante, al igual que ocurre en la práctica clínica real, la distribución de diagnósticos presenta un desbalanceo muy acusado, con una clara predominancia de lesiones benignas frente a un número considerablemente menor de casos malignos.

En concreto, el conjunto de datos contiene del orden de 400 000 lesiones benignas, mientras que el número de imágenes correspondientes a lesiones malignas es significativamente inferior, representando únicamente un pequeño porcentaje del total. Este desbalanceo refleja fielmente la epidemiología del cáncer de piel, pero introduce importantes desafíos para el entrenamiento de modelos de clasificación basados en *deep learning*, especialmente en términos de sensibilidad y capacidad de detección de las clases minoritarias.

3.2.2 Tipos de imágenes

Las imágenes de SLICE-3D proceden principalmente de sistemas de dermatoscopía digital y de plataformas de *Total Body Photography* (TBP), proporcionando imágenes de alta resolución centradas en lesiones individuales. La variabilidad en las condiciones de adquisición, los dispositivos empleados y las características visuales (iluminación, enfoque, resolución, contraste, etc.) hace que este conjunto de datos resulte especialmente adecuado para evaluar la robustez de modelos de aprendizaje profundo frente a cambios de dominio y escenarios clínicos heterogéneos.

3.2.3 Metadatos clínicos disponibles

Una característica distintiva de SLICE-3D es la disponibilidad de un conjunto amplio y detallado de metadatos clínicos, que incluye variables demográficas, información anatómica y métricas cuantitativas avanzadas derivadas de TBP (`TBP-LV`). Entre estos metadatos se encuentran, de forma general:

- variables demográficas básicas (como edad aproximada y sexo del paciente),
- localización anatómica general de la lesión,
- descriptores cuantitativos relacionados con forma, tamaño, color y asimetría de la lesión.

Estos metadatos aportan información complementaria a la imagen cruda que puede resultar de gran valor para la clasificación clínica, especialmente en contextos de cribado (*screening*) o en escenarios en los que la información puramente visual puede resultar ambigua. En el marco del enfoque multimodal propuesto en este trabajo, estas variables constituyen una fuente adicional de evidencia que puede contribuir a mejorar la capacidad discriminativa del modelo.

3.3 Base de datos ISIC Archive

3.3.1 Descripción general

La base de datos *ISIC Archive* constituye un repositorio público de gran escala que agrupa un total de 549 590 imágenes dermatológicas, correspondientes a una amplia variedad de diagnósticos y procedentes de múltiples centros y estudios internacionales.

En el presente trabajo, *ISIC Archive* no se emplea de forma íntegra, sino que se utiliza de manera selectiva y estratégica. Con el objetivo de mitigar el desbalanceo extremo presente en *SLICE-3D*, se seleccionaron 27 084 imágenes correspondientes exclusivamente a casos malignos, incluyendo melanoma, carcinoma basocelular y carcinoma espinocelular.

Esta selección permite reforzar de forma significativa la representación de las clases malignas en el conjunto de datos global, manteniendo al mismo tiempo la coherencia clínica y la fiabilidad de las etiquetas diagnósticas. De este modo, *ISIC Archive* actúa como una fuente complementaria esencial para equilibrar el conjunto de entrenamiento sin introducir ruido innecesario ni comprometer la validez de los experimentos.

3.3.2 Tipos de imágenes

3.3.3 Metadatos clínicos disponibles

3.3.4 Diferencias respecto a SLICE-3D

Las principales diferencias entre ISIC Archive e ISIC Slice 3D son:

- **Distribución de clases**: ISIC Archive contiene únicamente lesiones malignas, mientras que Slice 3D incluye mayoritariamente lesiones benignas.
- **Riqueza de metadatos**: ISIC Archive dispone de un número menor de variables clínicas y descriptivas.
- **Rol en el estudio**: ISIC Archive se emplea como fuente estratégica para incrementar la presencia de lesiones malignas y reducir el desbalanceo de clases del conjunto global.

Estas diferencias motivan la adopción de estrategias específicas de fusión y tratamiento de datos, que se describirán en capítulos posteriores.

3.4 Otras fuentes de datos consideradas

3.4.1 HAM10000

La base de datos *HAM10000* fue analizada de forma preliminar como posible fuente complementaria. Sin embargo, se decidió no integrarla en la fase principal del estudio debido a diferencias en los criterios de anotación y a la existencia de solapamientos conceptuales

con las bases ISIC, que podrían complicar la armonización de datos sin aportar un beneficio proporcional en términos de diversidad o volumen efectivo.

3.5 Análisis del desbalanceo de clases

Uno de los principales retos identificados es el desbalanceo severo entre lesiones benignas y malignas, especialmente en ISIC Archive. Mientras que las lesiones benignas superan ampliamente las 400 000 muestras, los casos malignos representan una fracción muy reducida del conjunto total.

Este desbalanceo condiciona tanto el diseño del modelo como la selección de métricas de evaluación, haciendo necesario priorizar la sensibilidad y la capacidad de detección de casos malignos frente a la mera exactitud global.

3.6 Distribución de diagnósticos

Con el fin de unificar los diagnósticos heterogéneos presentes en las distintas fuentes, se definió un espacio de clases clínicas común compuesto por las siguientes categorías:

- **BEN**: lesiones benignas (nevus y otros diagnósticos no malignos).
- **MEL**: melanoma.
- **BCC**: carcinoma basocelular.
- **SCC+**: carcinoma espinocelular y lesiones precursoras (queratosis actínica, queratoacantoma).

Esta categorización busca equilibrar la coherencia clínica con la viabilidad estadística, evitando una fragmentación excesiva de las clases que pudiera dificultar el entrenamiento y la interpretación de los modelos.

3.7 Heterogeneidad entre fuentes de datos

La combinación de múltiples bases de datos introduce heterogeneidad en términos de:

- protocolos de adquisición de imagen,
- calidad y resolución de las imágenes,
- disponibilidad y formato de los metadatos,
- criterios diagnósticos empleados por los distintos centros.

En lugar de eliminar esta heterogeneidad mediante filtrado agresivo, el presente trabajo adopta un enfoque de armonización controlada. El objetivo es preservar la máxima cantidad de información posible, al tiempo que se unifican los aspectos clave necesarios para el entrenamiento de modelos multimodales capaces de aprender patrones invariantes a las diferencias entre fuentes.

3.8 Análisis de variables y selección de metadatos

El tratamiento de los metadatos clínicos constituye un elemento central del enfoque multimodal propuesto. Dado que SLICE-3D es la única base con características avanzadas, se definieron dos configuraciones experimentales diferenciadas:

3.8.1 Variables demográficas y clínicas básicas (Plan A)

Se definen como el conjunto mínimo de información disponible en un entorno de atención primaria, garantizando la comparabilidad con fuentes antiguas como ISIC Archive. Incluye:

- `age_approx`: Edad aproximada (vulnerabilidad sistémica).
- `sex`: Sexo biológico.
- `clin_size_long_diam_mm`: Tamaño físico de la lesión.
- `anatom_site_general`: Ubicación anatómica en el cuerpo.

3.8.2 Variables de morfología avanzada TBP-LV (Plan B)

Este conjunto explota al máximo la riqueza técnica del dataset SLICE-3D, incorporando más de 30 descriptores geométricos y de color derivados de Total Body Photography:

- **Morfología**: `tbp_lv_areaMM2`, `tbp_lv_perimeterMM`, `tbp_lv_eccentricity`.
- **Color y Contraste**: `tbp_lv_color_std_mean`, `tbp_lv_deltaA/B/L`.
- **Estructura 3D**: Coordenadas espaciales `tbp_lv_x/y/z`.

3.8.3 Identificación de variables de riesgo: Target Leakage y Bias

Uno de los pasos críticos de la auditoría de datos fue identificar variables que no deben estar presentes en la inferencia:

- **Target Leakage**: Variables obtenidas tras el diagnóstico histopatológico (`mel_thick_mm`, `mel_mitotic_index`). Su uso inflaría el rendimiento de forma irreal, ya que un sistema de triaje no dispone de esta información antes de la biopsia.
- **Bias por IA externa**: La columna `tbp_lv_dnn_lesion_confidence` representa la opinión de un modelo algorítmico previo. Se descarta para garantizar que el sistema propuesto aprenda de la imagen y no herede sesgos de predicciones ajenas.

3.9 Identificadores clínicos y prevención de *data leakage*

Para garantizar la validez experimental del estudio y evitar fugas de información entre los conjuntos de entrenamiento, validación y prueba, resulta fundamental analizar en detalle la estructura de los identificadores presentes en las bases de datos empleadas.

En general, las imágenes pueden estar asociadas a distintos tipos de identificadores:

- **Patient ID**: identifica de manera única a un paciente, que puede presentar una o varias lesiones.
- **Lesion ID**: identifica una lesión concreta, que pertenece a un único paciente pero puede estar representada por múltiples imágenes.
- **Identificador de imagen**: referencia una captura específica de una lesión determinada.

Esta estructura implica que no todas las imágenes son independientes entre sí. Un mismo paciente puede presentar varias lesiones, y una misma lesión puede estar representada por múltiples imágenes, lo que da lugar a grupos de datos altamente correlacionados. Si estos grupos se reparten de forma inadecuada entre los diferentes subconjuntos, se corre el riesgo de introducir *data leakage*, inflando artificialmente las métricas de rendimiento del modelo.

Durante el análisis preliminar se observó que la existencia de pacientes con múltiples lesiones y lesiones con múltiples imágenes daba lugar a grupos de tamaño elevado, lo que dificultaba la división equilibrada del conjunto de datos manteniendo, al mismo tiempo, la independencia entre los subconjuntos de entrenamiento y validación.

Para resolver este problema, se definió un identificador unificado denominado `master_group_id`, construido siguiendo las reglas que se detallan a continuación:

1. Si **Patient ID** y **Lesion ID** están presentes, el `master_group_id` se define a partir de la combinación de ambos identificadores, de forma que todas las imágenes correspondientes a una lesión concreta de un paciente queden agrupadas.
2. Si **Patient ID** es nulo pero **Lesion ID** no lo es, se utiliza directamente el **Lesion ID** como `master_group_id`.
3. Si **Lesion ID** es nulo pero **Patient ID** está disponible, se utiliza el **Patient ID** como `master_group_id`.
4. Si ambos identificadores son nulos, se asigna un identificador único por imagen, de modo que cada muestra forme un grupo independiente.

Este enfoque garantiza que todas las imágenes pertenecientes a un mismo paciente o a una misma lesión se asignen siempre al mismo subconjunto de datos (entrenamiento, validación o prueba), evitando *patient leakage* y asegurando una evaluación experimental rigurosa y realista del rendimiento de los modelos.

3.10 Consideraciones éticas y de uso de datos

Todas las bases de datos utilizadas en este trabajo son de acceso público y han sido anonimizadas por sus autores originales. No se dispone de información identificable de pacientes y el uso de los datos se realiza exclusivamente con fines académicos y de investigación, respetando las licencias y condiciones de uso establecidas por ISIC y por los repositorios correspondientes.

Además, se han adoptado medidas específicas para prevenir fugas de información entre

los conjuntos de entrenamiento, validación y prueba. En particular, se ha prestado especial atención a la separación de imágenes pertenecientes a un mismo paciente, con el objetivo de garantizar la validez experimental de los resultados y evitar una sobreestimación artificial del rendimiento de los modelos.

Capítulo 4

Metodología

4.1 Enfoque de la investigación: Sistema de Triaje y Diagnóstico Dual

4.2 Diseño Experimental y Comparativa de Escenarios

4.2.1 Estudio de impacto de metadatos: Plan A vs. Plan B

4.2.2 Análisis de granularidad diagnóstica: Regímenes de 3 y 4 clases

4.3 Paradigma de Aprendizaje Multimodal y Complementariedad

4.4 Estrategia de Transferencia de Conocimiento (*Transfer Learning*)

4.5 Metodología de Validación y Robustez

4.5.1 Prevención de sesgos mediante Partición por Grupos Maestros

4.5.2 Validación Cruzada (*5-fold Cross-Validation*)

4.6 Criterios de Evaluación y Selección del Modelo Óptimo

4.7 Flujo General del Sistema (*Pipeline* de ejecución)

Capítulo 5

Entorno de desarrollo y herramientas tecnológicas

5.1 Lenguaje de programación

5.2 Framework principal de Deep Learning: PyTorch

5.2.1 Justificación de la elección de PyTorch

5.2.2 Ecosistema Torchvision

5.3 Herramientas de procesamiento y manipulación de datos

5.3.1 NumPy y Pandas

5.3.2 Scikit-Learn

5.4 Librerías de visión por computador

5.4.1 OpenCV (cv2) y Pillow (PIL)

5.5 Librerías de optimización e interpretabilidad

5.5.1 Optimización Bayesiana con Optuna

5.5.2 Interpretabilidad visual con pytorch-grad-cam

5.6 Entorno de ejecución y recursos hardware

5.6.1 Configuración del entorno local (VS Code)

5.6.2 Limitaciones de VRAM y paralelización

5.7 Reproducibilidad y control de versiones

5.7.1 Fijación de semillas aleatorias (Seed locking)

5.7.2 Registro de métricas y *Logs*

Capítulo 6

Ingeniería y preprocesamiento de los datos

6.1 Introducción al preprocesamiento

6.2 Estrategia de fusión de bases de datos

6.3 Armonización de columnas y depuración de variables

6.4 Tratamiento de valores faltantes e imputación

6.5 Transformación de variables clínicas

6.5.1 Codificación categórica (One-Hot Encoding)

6.5.2 Normalización numérica

6.6 Preprocesamiento y generación de ramas visuales

6.6.1 Estandarización de la rama RGB

6.6.2 Transformación geométrica: Generación de la rama ARP

6.7 Estrategia de partición y prevención de *data leakage*

6.7.1 Identificadores clínicos y el *Master Group ID*

6.7.2 División de conjuntos de entrenamiento, validación y test

Capítulo 7

Métricas de evaluación y ajuste de umbrales

7.1 Introducción a la evaluación en escenarios de extremo desbalanceo

7.2 La Matriz de Confusión como base evaluativa

7.2.1 Formulación binaria (Cabeza A: Triage Clínico)

7.2.2 Formulación multiclase (Cabeza B: Diagnóstico Diferencial)

7.3 Métricas de evaluación deterministas

7.3.1 La trampa de la Exactitud (*Accuracy*) en imagen médica

7.3.2 Sensibilidad (*Recall*): La métrica prioritaria

7.3.3 Especificidad y Precisión

7.4 Métricas agregadas y de promediado

7.4.1 El *F1-Score* como medida de equilibrio

7.4.2 Estrategias de promediado: *Micro* vs. *Macro F1-Score*

7.5 Evaluación probabilística de la red

7.5.1 Curva ROC (*Receiver Operating Characteristic*)

7.5.2 Área Bajo la Curva (AUC) como medida de separabilidad

7.6 Ajuste del Umbral de Decisión y Factor de Seguridad Clínico

7.7 Justificación clínica de la estrategia de evaluación final

Capítulo 8

Diseño de la Red Implementada

8.1 Arquitectura Global del Sistema de Fusión Triple

8.2 Rama Visual Híbrida: Extractor RGB (CNN-ViT)

8.2.1 Módulo Convolucional: ResNet18 como extractor de rasgos locales

8.2.2 Módulo de Atención: Vision Transformer para relaciones globales

8.3 Rama de Análisis Estructural: Red Convolucional ARP

8.4 Rama de Percepción Clínica: Perceptrón Multicapa (MLP)

8.5 Integración y Toma de Decisión: *Late Fusion*

8.5.1 Topología de las Cabezas de Decisión (Dual-Head)

8.6 Modelado Matemático del Entrenamiento

8.6.1 Optimización frente al desbalanceo: *Focal Loss*

8.6.2 Función de pérdida combinada y ponderación de tareas

8.7 Tácticas de Entrenamiento Avanzado

8.7.1 Protocolo *Linear Probing* y *Fine-Tuning* global

8.7.2 Aprendizaje Jerárquico mediante *Differential Learning Rate*

8.7.3 Regularización por *Modality Dropout*

8.7.4 Gestión de memoria y *Gradient Accumulation*

8.8 Optimización Bayesiana de Hiperparámetros (Optuna)

Capítulo 9

Evaluación, resultados y discusión

9.1 Configuración experimental

9.2 Resultados obtenidos

9.3 Comparativa entre configuraciones

9.4 Impacto de la fusión multimodal

9.5 Impacto del desbalanceo

9.6 Discusión de resultados

9.7 Limitaciones del estudio

Capítulo 10

Conclusiones y trabajo futuro

10.1 Conclusiones generales

10.2 Contribuciones del trabajo

10.3 Líneas futuras de investigación

Capítulo A

Anexos

A.1 Arquitecturas completas

A.2 Hiperparámetros

A.3 Diagramas adicionales