Título del Trabajo de Fin de Grado

Nombre del Autor

19 de abril de 2026

Resumen

Abstract

Agradecimientos

Índice general

Resumen **1**

Abstract **2**

Agradecimientos **3**

1. Introducción y justificación **11**

1.1. Contexto clínico e importancia del diagnóstico precoz del cáncer de piel . . 11
1.2. Limitaciones del diagnóstico visual tradicional 11
1.3. Aplicación de la inteligencia artificial en dermatología 11
1.4. Motivación del trabajo 11
1.4.1. Justificación técnica del enfoque propuesto 11
1.4.2. Justificación académica y social del estudio 11
1.5. Objetivos del trabajo 11
1.5.1. Objetivo general 11
1.5.2. Objetivos específicos 11
1.6. Alcance y delimitaciones del trabajo 11
1.7. Organización de la memoria 11

2. Estado del arte **12**

2.1. Introducción al estado del arte en clasificación de lesiones cutáneas 13
2.2. Métodos clásicos de diagnóstico asistido por ordenador 13
2.2.1. Extracción manual de características 13
2.2.2. Clasificadores tradicionales 13
2.3. Redes neuronales convolucionales en dermatología 13
2.3.1. CNN en clasificación de imágenes médicas 13
2.3.2. CNN aplicadas a lesiones cutáneas 13
2.4. Vision Transformers en visión por computador 13
2.4.1. Fundamentos de los Transformers 13
2.4.2. Aplicaciones de ViT en imagen médica 13
2.5. Modelos híbridos CNNTransformer 13
2.5.1. Motivación del enfoque híbrido 13

2.5.2. Resultados reportados en la literatura 13
2.6. Angular Radial Partitioning en análisis de imagen 13
2.6.1. Fundamentos teóricos del ARP 13
2.6.2. Uso de ARP en reconocimiento de patrones 13
2.7. Aprendizaje multimodal en medicina 13
2.7.1. Fusión de imagen y metadatos clínicos 13
2.7.2. Estrategias de fusión temprana, tardía e intermedia 13
2.8. Problemas abiertos en el estado del arte 13
2.8.1. Desbalanceo de clases 13
2.8.2. Heterogeneidad de bases de datos 13
2.8.3. Riesgos de *data leakage* 13
2.9. Posicionamiento del presente trabajo 13

3. Descripción y Exploración de los Datos 14
3.1. Adquisición y Estructura del Dataset Original 14
3.1.1. Adquisición mediante `isic-cli` 14
3.1.2. Estructura y Composición Inicial 14
3.2. Diccionario de Variables y Naturaleza de los Datos 14
3.3. Análisis Exploratorio de Datos (EDA) Original 15
3.3.1. Distribución Demográfica 15
3.3.2. El Desbalanceo Diagnóstico Natural 15
3.4. Desarrollo del Script de Auditoría Forense 16

4. Metodología 17
4.1. Enfoque de la investigación: Triage Dual (*Dual-Head*) 17
4.2. Paradigma de Aprendizaje Multimodal 17
4.3. Armonización Taxonómica: El Sistema de 6 Clases 17
4.4. Estrategia de Aprendizaje y Transferencia de Conocimiento 17
4.4.1. Prevención del Olvido Catastrófico (*Catastrophic Forgetting*) 17
4.4.2. Protocolo *Linear Probing* seguido de *Fine-Tuning* (LP-FT) 17
4.5. Metodología de Validación y Robustez 17
4.5.1. Aislamiento hermético de pacientes 17
4.5.2. Validación Cruzada (*5-fold Cross-Validation*) 17
4.6. Criterios de Evaluación Clínica 17
4.7. Flujo General del Sistema (*Pipeline* de ejecución) 17

5. Entorno de desarrollo y herramientas tecnológicas 18
5.1. Lenguaje de programación 18
5.2. Framework principal de Deep Learning: PyTorch 19
5.2.1. Justificación de la elección de PyTorch 19

5.2.2. Ecosistema Torchvision y librerías asociadas 19
5.3. Herramientas de procesamiento y manipulación de datos 20
5.3.1. NumPy y Pandas 20
5.3.2. Scikit-Learn 20
5.4. Librerías de visión por computador 21
5.4.1. OpenCV y Pillow (PIL) 21
5.5. Librerías de optimización e interpretabilidad 22
5.5.1. Optimización Bayesiana con Optuna 22
5.5.2. Interpretabilidad visual con pytorch-grad-cam 22
5.6. Entorno de ejecución y recursos hardware 23
5.6.1. Configuración del entorno local 23
5.6.2. Limitaciones de VRAM y paralelización 23
5.7. Reproducibilidad y control de versiones 24
5.7.1. Fijación de semillas aleatorias (Seed locking) 24
5.7.2. Registro de métricas y *Logs* 24

6. Ingeniería y Preprocesamiento de los Datos 25
6.1. Introducción al preprocesamiento 25
6.2. Paso 1: Limpieza de Datos 25
6.2.1. Tratamiento de Identificadores y Lógica de `master_id` 25
6.2.2. Análisis de Valores Nulos (NaN) y Taxonomía en Cascada 26
6.2.3. Verificación de Duplicados 26
6.3. Paso 2: Integración de Datos 27
6.3.1. Análisis del Catálogo Diagnóstico Original 27
6.3.2. Armonización Taxonómica: El Sistema de 6 Clases (Head B) 27
6.3.3. Arquitectura Dual (*Dual-Head*) y Triaje Clínico 28
6.4. Paso 3: Transformación de Datos 29
6.4.1. Estrategia de Imputación de Valores Faltantes 29
6.4.2. Codificación Categórica: *One-Hot Encoding* (OHE) 29
6.4.3. Política de Escalado Numérico (Z-Score) 30
6.5. Paso 4: Reducción de Datos y Muestreo 30
6.5.1. Análisis Forense de Sesgos de Adquisición 30
6.5.2. El problema de la Red Perezosaz el Efecto *Clever Hans* 31
6.5.3. Estrategia de Muestreo Estratificado (227k Imágenes) 31
6.6. Preprocesamiento Vectorial de Imágenes (*Offline*) 32
6.6.1. Estandarización de la rama RGB 32
6.6.2. Transformación geométrica: Generación de la rama ARP 32
6.7. Partición del Dataset y Estrategia de Evaluación 32

7. Métricas de evaluación y ajuste de umbrales **33**
7.1. Introducción a la evaluación en escenarios de extremo desbalanceo 33
7.2. La Matriz de Confusión como base evaluativa 33
7.2.1. Formulación binaria (Cabeza A: Triage Clínico) 33
7.2.2. Formulación multiclase (Cabeza B: Diagnóstico Diferencial) 33
7.3. Métricas de evaluación deterministas 33
7.3.1. La trampa de la Exactitud (*Accuracy*) en imagen médica 33
7.3.2. Sensibilidad (*Recall*): La métrica prioritaria 33
7.3.3. Especificidad y Precisión 33
7.4. Métricas agregadas y de promediado 33
7.4.1. El *F1-Score* como medida de equilibrio 33
7.4.2. Estrategias de promediado: *Micro* vs. *Macro F1-Score* 33
7.5. Evaluación probabilística de la red 33
7.5.1. Curva ROC (*Receiver Operating Characteristic*) 33
7.5.2. Área Bajo la Curva (AUC) como medida de separabilidad 33
7.6. Ajuste del Umbral de Decisión y Factor de Seguridad Clínico 33
7.7. Justificación clínica de la estrategia de evaluación final 33

8. Diseño de la Red Implementada **34**
8.1. Arquitectura Global del Sistema de Fusión Triple 35
8.2. Rama 1: Percepción Clínica (Metadatos MLP) 35
8.2.1. Topología del Perceptrón Multicapa Compartido 35
8.2.2. Optimización Bayesiana (Optuna) 35
8.3. Rama 2: Análisis Estructural (CNN ARP) 35
8.3.1. Arquitectura Convolucional Personalizada 35
8.3.2. Sintonización de Hiperparámetros (Optuna) 35
8.4. Rama 3: Percepción Visual Híbrida (RGB) 35
8.4.1. Extracción de rasgos locales: ResNet18 35
8.4.2. Modelado de relaciones globales: Vision Transformer (ViT) 35
8.4.3. Sintonización de Hiperparámetros (Optuna) 35
8.5. Integración y Toma de Decisión (*Late Fusion*) 35
8.5.1. Concatenación de tensores multimodales 35
8.5.2. Topología de las Cabezas de Decisión (*Dual-Head*) 35
8.6. Modelado Matemático del Entrenamiento Combinado 35
8.6.1. Funciones de pérdida asimétricas e híbridas 35
8.6.2. Aprendizaje Jerárquico mediante *Differential Learning Rates* 35
8.7. Tácticas de Optimización y Rendimiento de Hardware 35
8.7.1. Regularización por *Modality Dropout* 35
8.7.2. Prevención de *GPU Starvation*: *Prefetch* y Múltiples *Workers* . . . 35

8.7.3. Escalado de memoria: *Gradient Accumulation* y *Mixed Precision* (AMP) . . . 35

9. Evaluación, resultados y discusión **36**
9.1. Configuración experimental . . . 36
9.2. Resultados obtenidos . . . 36
9.3. Comparativa entre configuraciones . . . 36
9.4. Impacto de la fusión multimodal . . . 36
9.5. Impacto del desbalanceo . . . 36
9.6. Discusión de resultados . . . 36
9.7. Limitaciones del estudio . . . 36

10. Conclusiones y trabajo futuro **37**
10.1. Conclusiones generales . . . 37
10.2. Contribuciones del trabajo . . . 37
10.3. Líneas futuras de investigación . . . 37

A. Anexos **38**
A.1. Arquitecturas completas . . . 38
A.2. Hiperparámetros . . . 38
A.3. Diagramas adicionales . . . 38

Índice de figuras

Índice de cuadros

Capítulo 1

Introducción y justificación

1.1 Contexto clínico e importancia del diagnóstico precoz del cáncer de piel

1.2 Limitaciones del diagnóstico visual tradicional

1.3 Aplicación de la inteligencia artificial en dermatología

1.4 Motivación del trabajo

1.4.1 Justificación técnica del enfoque propuesto

1.4.2 Justificación académica y social del estudio

1.5 Objetivos del trabajo

1.5.1 Objetivo general

1.5.2 Objetivos específicos

1.6 Alcance y delimitaciones del trabajo

1.7 Organización de la memoria

Capítulo 2

Estado del arte

2.1 Introducción al estado del arte en clasificación de lesiones cutáneas

2.2 Métodos clásicos de diagnóstico asistido por ordenador

2.2.1 Extracción manual de características

2.2.2 Clasificadores tradicionales

2.3 Redes neuronales convolucionales en dermatología

2.3.1 CNN en clasificación de imágenes médicas

2.3.2 CNN aplicadas a lesiones cutáneas

2.4 Vision Transformers en visión por computador

2.4.1 Fundamentos de los Transformers

2.4.2 Aplicaciones de ViT en imagen médica

2.5 Modelos híbridos CNNTransformer

2.5.1 Motivación del enfoque híbrido

2.5.2 Resultados reportados en la literatura

2.6 Angular Radial Partitioning en análisis de imagen

2.6.1 Fundamentos teóricos del ARP

2.6.2 Uso de ARP en reconocimiento de patrones

2.7 Aprendizaje multimodal en medicina

2.7.1 Fusión de imagen y metadatos clínicos

2.7.2 Estrategias de fusión temprana, tardía e intermedia

Capítulo 3

Descripción y Exploración de los Datos

3.1 Adquisición y Estructura del Dataset Original

3.1.1 Adquisición mediante `isic-cli`

La base de datos original se obtuvo del repositorio de la **International Skin Imaging Collaboration (ISIC)**. Debido al volumen masivo de información, se utilizó la herramienta oficial de línea de comandos `isic-cli`. Este método permitió una descarga estructurada y eficiente de las imágenes y su información asociada, garantizando la integridad de los archivos mediante protocolos de transferencia seguros.

3.1.2 Estructura y Composición Inicial

El dataset original descargado se compone de dos elementos fundamentales:

1. **Cuerpo de Imágenes:** Una colección de cientos de miles de archivos en formato JPEG de alta resolución, que representan capturas macroscópicas y dermatoscópicas de lesiones cutáneas.
2. **Archivo de Metadatos (CSV):** Un archivo tabular estándar de valores separados por comas que asocia cada identificador de imagen con la información sociodemográfica del paciente, clínica y técnica. El archivo crudo constaba de 552 598 registros (filas) y 37 características (columnas).

3.2 Diccionario de Variables y Naturaleza de los Datos

Para comprender el contexto del problema, es necesario definir la naturaleza de las variables proporcionadas por el archivo de metadatos. Las 37 características originales se pueden agrupar en tres grandes categorías:

- **Variables de Trazabilidad:** Identificadores únicos alfanuméricos como `isic_id` (ID de la fotografía), `patient_id` (ID del paciente) y `lesion_id` (ID de la lesión física).

- **Variables Sociodemográficas y Anatómicas:** Características del paciente en el momento de la captura, destacando `age_approx` (edad aproximada en tramos de 5 años), `sex` (sexo biológico) y `anatom_site_general` (región corporal general como torso, extremidades o cabeza/cuello).
- **Variables Técnicas de Adquisición:** Información sobre el hardware utilizado, siendo la más crítica `image_type`, que distingue entre fotografías tomadas con dermatoscopio digital de contacto y fotografías clínicas de cuerpo entero (TBP - *Total Body Photography*).
- **Variables Diagnósticas (*Ground Truth*):** Una serie de columnas, desde `diagnosis_1` hasta `diagnosis_5`, que catalogan la lesión con creciente nivel de especificidad histopatológica.

3.3 Análisis Exploratorio de Datos (EDA) Original

Antes de aplicar cualquier técnica de curación, se realizó un estudio estadístico descriptivo sobre el conjunto bruto de 552 598 registros para comprender la distribución de la población de estudio.

3.3.1 Distribución Demográfica

El análisis reveló una población mayoritariamente adulta, con una edad media de aproximada de 56.3 años. En cuanto a la distribución por sexos biológicos, se observó una prevalencia de pacientes masculinos (59.7 %) frente a pacientes femeninos (32.4 %), existiendo un 7.9 % de registros sin esta información definida. Respecto a la localización anatómica, las lesiones se concentraban predominantemente en el torso posterior (25.4 %) y las extremidades inferiores (24.0 %).

3.3.2 El Desbalanceo Diagnóstico Natural

El análisis de la variable objetivo primaria (`diagnosis_1`) demostró el severo desbalanceo inherente al cribado dermatológico en el mundo real. De los registros válidos iniciales:

- El **90.96 %** (502 646 muestras) correspondían a lesiones catalogadas estrictamente como **Benignas**.
- Apenas el **4.91 %** (27 111 muestras) eran tumores confirmados como **Malignos**.
- El resto se componía de diagnósticos indeterminados o campos vacíos.

Este hallazgo estadístico subrayó la necesidad imperativa de aplicar en fases posteriores funciones de pérdida especializadas (*Weighted CrossEntropy* o *BCE con pesos asimétricos*) para evitar que la futura red neuronal colapsara prediciendo siempre la clase mayoritaria sana.

3.4 Desarrollo del Script de Auditoría Forense

En lugar de asumir la validez directa de la información contenida en el archivo CSV, se desarrolló e implementó un **script de auditoría de datos automatizado**. El propósito de este programa fue realizar un análisis forense exhaustivo de la base de datos antes de aplicar cualquier técnica de limpieza. El script ejecutó dos procesos analíticos fundamentales:

1. **Análisis de correlación de valores nulos (NaNs) en diagnósticos:**
   El script analizó el porcentaje de valores perdidos a través de las diferentes columnas diagnósticas originales. Específicamente, calculó para cada categoría de un diagnóstico primario (`diagnostico_x`), qué porcentaje de valores nulos presentaba el diagnóstico secundario (`diagnostico_y`). Este cruce de datos permitió revelar matemáticamente que el etiquetado médico en la base de datos de ISIC sigue una **clasificación en cascada**. Los facultativos diagnostican desde niveles muy generales a niveles muy específicos; por tanto, cuando una lesión no puede ser clasificada con certeza en un nivel superior, todos los subniveles diagnósticos descendentes aparecen sistemáticamente como nulos (NaN).
2. **Detección de sesgos sistémicos mediante validación cruzada de metadatos:**
   Para garantizar que la futura red neuronal no aprendiera correlaciones espurias, el script realizó una validación cruzada entre cada metadato disponible y el diagnóstico final. Para cada valor único dentro de un metadato (por ejemplo, los distintos rangos de edad, sexos, o tipos de dispositivo), el algoritmo calculó la distribución porcentual exacta de lesiones malignas y benignas asociadas a dicho valor.
   Fue este análisis granular el que permitió descubrir sesgos críticos en la base de datos original. El hallazgo más notable fue el sesgo instrumental: el script evidenció que el porcentaje de casos malignos estaba fuertemente sesgado hacia un tipo de fotografía específico (capturas con dermatoscopio), mientras que la inmensa mayoría de las imágenes capturadas con sistemas de fotografía de cuerpo entero (TBP) resultaban ser diagnósticos benignos.

Los resultados extraídos por este script de auditoría sentaron las bases empíricas para todas las decisiones metodológicas tomadas en las fases de limpieza, integración y reducción de datos descritas en capítulos posteriores.

Capítulo 4

Metodología

4.1 Enfoque de la investigación: Triage Dual (*Dual-Head*)

4.2 Paradigma de Aprendizaje Multimodal

4.3 Armonización Taxonómica: El Sistema de 6 Clases

4.4 Estrategia de Aprendizaje y Transferencia de Conocimiento

4.4.1 Prevención del Olvido Catastrófico (*Catastrophic Forgetting*)

4.4.2 Protocolo *Linear Probing* seguido de *Fine-Tuning* (LP-FT)

4.5 Metodología de Validación y Robustez

4.5.1 Aislamiento hermético de pacientes

4.5.2 Validación Cruzada (*5-fold Cross-Validation*)

4.6 Criterios de Evaluación Clínica

4.7 Flujo General del Sistema (*Pipeline* de ejecución)

Capítulo 5

Entorno de desarrollo y herramientas tecnológicas

En este capítulo se detallan las herramientas hardware y software seleccionadas para la consecución de los objetivos del proyecto, justificando su elección en base a los requisitos de flexibilidad y rendimiento computacional exigidos por el procesamiento de imágenes médicas.

5.1 Lenguaje de programación

El desarrollo íntegro de este Trabajo de Fin de Grado se ha llevado a cabo utilizando **Python** (en su versión 3.x) como lenguaje de programación principal. La elección de Python no es arbitraria, sino que responde a su consolidación como el estándar *de facto* en la industria y en la comunidad investigadora dentro de los campos de la Inteligencia Artificial, el Aprendizaje Automático (*Machine Learning*) y el Aprendizaje Profundo (*Deep Learning*).

La principal ventaja que ofrece Python frente a lenguajes compilados de más bajo nivel (como C++ o Java) es su sintaxis clara y legible, la cual permite una abstracción total de la gestión de memoria y otorga al desarrollador la capacidad de centrarse enteramente en el diseño lógico y matemático de los algoritmos. Además, su naturaleza multiparadigma soportando programación orientada a objetos y programación funcional resulta ideal para estructurar proyectos de experimentación científica iterativa.

Sin embargo, el factor decisivo para su implementación en este trabajo es su inmenso y maduro ecosistema de librerías científicas. Python actúa como un lenguaje *"pegamento"* (*glue language*), lo que significa que, aunque el código se escriba con una sintaxis de alto nivel, las operaciones matemáticas subyacentes más costosas son ejecutadas en el *backend* mediante rutinas compiladas en C o C++, garantizando un rendimiento óptimo al procesar cientos de miles de imágenes médicas.

5.2 Framework principal de Deep Learning: PyTorch

Para la construcción, entrenamiento y evaluación de las redes neuronales, se ha optado por utilizar **PyTorch**, un marco de trabajo (*framework*) de código abierto desarrollado originalmente por el laboratorio de investigación en inteligencia artificial de Meta (FAIR).

5.2.1 Justificación de la elección de PyTorch

Aunque existen otras alternativas populares en la industria, como TensorFlow o Keras, la naturaleza específica de este proyecto exigía un *framework* que ofreciera el máximo nivel de flexibilidad y control a bajo nivel sobre la arquitectura de la red. PyTorch fue seleccionado por dos razones arquitectónicas fundamentales:

1. **El paradigma del Grafo Computacional Dinámico (*Define-by-Run*):** A diferencia de otros *frameworks* que exigen compilar un grafo estático antes de que fluyan los datos, PyTorch construye el grafo computacional sobre la marcha en cada iteración (*forward pass*). Esta característica resulta indispensable cuando se diseñan arquitecturas a medida que no siguen un flujo lineal tradicional. En el caso de este trabajo, el modelo propuesto (`HybridViTCNN`) fusiona las extracciones de características de dos paradigmas radicalmente distintos: una Red Neuronal Convolucional (CNN) y un *Vision Transformer* (ViT). Manejar la concatenación de estos tensores de diferente naturaleza geométrica es un proceso mucho más natural bajo un paradigma dinámico.
2. **Naturaleza "Pythónica" y depuración (*Debugging*):** PyTorch se integra de manera nativa con las herramientas de depuración de Python. Al trabajar con tensores directamente, es posible inspeccionar el valor numérico exacto de una activación o un gradiente en cualquier capa intermedia de la red. Esta transparencia ha sido crucial para diagnosticar problemas complejos durante el desarrollo, como la explosión de gradientes o la inspección de mapas de características para los algoritmos de interpretabilidad visual (Grad-CAM), permitiendo abrir la "caja negra" del modelo híbrido.

5.2.2 Ecosistema Torchvision y librerías asociadas

Uno de los pilares que sustentan a PyTorch es el paquete auxiliar `torchvision`, diseñado específicamente para resolver problemas de visión por computador. En este proyecto, su uso se ha centrado en dos tareas fundamentales:

- **Transfer Learning y extracción de pesos preentrenados:** Mediante `torchvision.models`, se ha instanciado la rama convolucional del modelo cargando una arquitectura *ResNet18* preentrenada con los pesos óptimos del desafío ImageNet1K. De manera análoga y complementaria, se integró la librería especializada `timm` (*PyTorch Image*

Models) para instanciar la rama atencional de la red, cargando los pesos de un *Vision Transformer* (`ViT-Tiny`).

- **Transformaciones y Aumento de Datos (*Data Augmentation*):** El módulo `torchvision.transforms` ha sido el motor encargado de procesar los lotes de imágenes en tiempo real. Permitió aplicar perturbaciones estocásticas (`RandomHorizontalFlip`, `ColorJitter`, `ElasticTransform`) durante el entrenamiento para actuar como un poderoso método de regularización, mitigando el sobreajuste y combatiendo los sesgos intrínsecos de los dispositivos de adquisición de las bases de datos.

5.3 Herramientas de procesamiento y manipulación de datos

El ecosistema de Python para ciencia de datos ha sido la columna vertebral del preprocesamiento y estructuración de la información clínica antes de su ingesta en las redes neuronales.

5.3.1 NumPy y Pandas

Para la manipulación de datos tabulares y metadatos clínicos, se ha recurrido a la combinación de las librerías `Pandas` y `NumPy`.

`Pandas` ha sido la herramienta fundamental para realizar la carga, limpieza y fusión (mediante operaciones *merge* y *concat*) de las múltiples bases de datos originadas tanto en repositorios históricos (ISIC Archive) como modernos (SLICE-3D). Su uso fue crítico para la limpieza de valores nulos, la imputación de datos faltantes —utilizando valores sentinela como -1— y, de manera muy especial, para la creación del identificador sintético *Master Group ID*. Este identificador, generado a partir de condiciones lógicas jerárquicas (priorizando el ID del paciente sobre el de la lesión), permitió consolidar el historial clínico y evitar colisiones de datos.

Por su parte, `NumPy` se utilizó para las transformaciones matriciales de bajo nivel y la vectorización de operaciones matemáticas. Funciones como `np.where` facilitaron la ejecución de lógica condicional rápida sobre conjuntos de más de 400.000 registros, mientras que las operaciones de apilamiento de matrices (`np.hstack`) permitieron ensamblar eficientemente las características numéricas y categóricas en un único tensor de entrada para alimentar la rama tabular del modelo (Perceptrón Multicapa).

5.3.2 Scikit-Learn

`Scikit-Learn` es el estándar *de facto* en el aprendizaje automático clásico, y en el marco de este proyecto de *Deep Learning* ha desempeñado un papel auxiliar indispensable para preparar el terreno de los datos y auditar los resultados. En concreto, se ha hecho un uso exhaustivo de sus módulos de preprocesamiento, partición y evaluación:

- **Normalización y Codificación:** Se empleó `StandardScaler` para aplicar una estandarización *Z-score* a las variables clínicas y geométricas numéricas (como la edad o el área de la lesión), garantizando que las magnitudes dispares no desestabilizaran los gradientes de la red neuronal. Paralelamente, se utilizó `OneHotEncoder` para transformar variables categóricas (como el sexo o la ubicación anatómica) en vectores binarios ortogonales.
- **Prevención de Fuga de Datos (*Data Leakage*):** Se implementó la clase `StratifiedGroupKFold` para generar las particiones de la validación cruzada. Esta herramienta matemática fue vital para asegurar dos condiciones simultáneamente: que la distribución fuertemente desbalanceada de clases de cáncer se mantuviera constante en cada partición (estratificación), y que todas las imágenes asociadas a un mismo *Master Group ID* recayeran de forma íntegra en el mismo subconjunto. Esto último previno de forma absoluta que el modelo memorizara anomalías sistémicas de un paciente concreto durante el entrenamiento.
- **Cálculo de Métricas Clínicas:** Los módulos de `sklearn.metrics` se integraron en el bucle nativo de PyTorch para evaluar el rendimiento del modelo en tiempo de ejecución. Permitió calcular de forma robusta métricas clínicas complejas como el Área Bajo la Curva ROC (AUC), el *F1-Score* macro, la sensibilidad (*Recall*) específica para el melanoma y la matriz de confusión multiclase.

5.4 Librerías de visión por computador

El preprocesamiento de imágenes dermatoscópicas, paso previo ineludible a la extracción de características profundas, se apoyó en dos de las librerías más consolidadas en el campo de la visión por computador.

5.4.1 OpenCV y Pillow (PIL)

La librería **Pillow (PIL)** se utilizó nativamente dentro de las clases de iteración de datos de PyTorch (`Dataset`). PIL destaca por su eficiencia y rapidez al decodificar archivos de imagen en formato RGB desde el disco de estado sólido, integrándose a la perfección con la cadena de transformaciones estocásticas (*Data Augmentation*) definida en el entrenamiento.

Por otro lado, **OpenCV** (*Open Source Computer Vision Library*) se erigió como el motor matemático crítico para la ingeniería de características visuales. Dada la variabilidad en la iluminación, los bordes artificiales (viñetas del dermatoscopio) y la presencia de artefactos clínicos (como reglas de medición o vello) en las imágenes originales, se empleó OpenCV para generar una representación alternativa de las lesiones: la transformada *Adaptive Radial Polar* (ARP).

Mediante funciones de conversión de espacios de color y la aplicación algorítmica de

proyecciones log-polares (`cv2.linearPolar`), OpenCV permitió desenrollar geométricamente la lesión, aislando su estructura morfológica y la asimetría de los bordes frente al ruido de adquisición. Esto fue determinante para alimentar una rama específica de la red neuronal, forzándola a ignorar el sesgo de la cámara (efecto *Clever Hans*) y centrarse en la patología.

5.5 Librerías de optimización e interpretabilidad

El entrenamiento de arquitecturas de aprendizaje profundo no solo requiere la definición de la red, sino también la búsqueda eficiente de sus hiperparámetros óptimos y la posterior auditoría clínica de sus decisiones. Para cubrir estas necesidades, se integraron herramientas avanzadas de optimización e Inteligencia Artificial Explicable (XAI).

5.5.1 Optimización Bayesiana con Optuna

La búsqueda de hiperparámetros óptimos es uno de los mayores desafíos computacionales en el entrenamiento de redes neuronales profundas. Tradicionalmente, se han utilizado enfoques de fuerza bruta como la búsqueda en cuadrícula (*Grid Search*). Sin embargo, dada la magnitud de los datos de este estudio y el coste temporal de entrenar la arquitectura `HybridViTCNN`, explorar todas las combinaciones posibles resultaba computacionalmente inasumible.

Para solventar esta limitación, se implementó el *framework* `Optuna`, el cual emplea algoritmos de Optimización Bayesiana —específicamente el estimador TPE (*Tree-structured Parzen Estimator*)—. A diferencia de la búsqueda aleatoria o en cuadrícula, `Optuna` utiliza el historial de los experimentos previos para predecir probabilísticamente qué zonas del espacio de hiperparámetros tienen mayor potencial de mejorar el modelo, convergiendo a la solución óptima en una fracción del tiempo.

En este trabajo, `Optuna` fue fundamental para sintonizar el *Learning Rate*, el decaimiento de pesos (*Weight Decay*) y, de forma crítica, el parámetro γ (gamma) de la función de coste *Focal Loss*, esencial para calibrar la penalización ante el fuerte desbalanceo clínico de las clases.

5.5.2 Interpretabilidad visual con pytorch-grad-cam

Uno de los principales impedimentos para la adopción clínica de los modelos de *Deep Learning* es su naturaleza de "caja negra" (*black-box*). Un modelo puede arrojar excelentes métricas de validación por los motivos equivocados, aprendiendo atajos estadísticos en lugar de características anatómicas reales.

Para dotar al modelo de explicabilidad clínica, se integró la librería `pytorch-grad-cam`. Esta herramienta implementa el algoritmo *Grad-CAM* (*Gradient-weighted Class Activation*

Mapping), el cual utiliza los gradientes que fluyen hacia la última capa convolucional de la red —en este caso, el bloque de extracción de la arquitectura *ResNet18*— para generar un mapa de calor que resalta las regiones espaciales de la imagen que mayor impacto tuvieron en la decisión final.

El uso de esta librería resultó de incalculable valor durante la fase forense del proyecto para identificar fugas de información (*Target Leakage*) y diagnosticar el conocido efecto *Clever Hans* o sesgo de dominio. Como se analizará en la memoria, los mapas de calor permitieron descubrir que, antes de aplicar técnicas de regularización geométricas, el modelo ignoraba la lesión cutánea y basaba su diagnóstico maligno en artefactos visuales de los dispositivos de adquisición (como viñetas oscuras de dermatoscopios antiguos o marcas de tinta quirúrgica).

5.6 Entorno de ejecución y recursos hardware

El entrenamiento de modelos híbridos que fusionan tensores de distinta naturaleza sobre cientos de miles de imágenes exige una orquestación precisa de los recursos de *hardware* y *software*.

5.6.1 Configuración del entorno local

Como Entorno de Desarrollo Integrado (IDE) principal se utilizó **Visual Studio Code** (VS Code). Su elección se fundamenta en su robusta integración con Python, su capacidad para ejecutar y depurar *Jupyter Notebooks* de forma nativa, y su versatilidad para gestionar entornos virtuales aislados.

5.6.2 Limitaciones de VRAM y paralelización

El desarrollo del proyecto se enfrentó a un desafío de infraestructura significativo, dividiéndose la ejecución en dos entornos distintos:

- **Entorno Local (Estación de trabajo):** Equipado con un procesador de alto rendimiento y 32 GB de memoria RAM de sistema, pero limitado por una unidad de procesamiento gráfico (GPU) NVIDIA de 6 GB de VRAM. Este entorno se utilizó para la limpieza de datos tabulares, ingeniería de características, análisis forense y pruebas unitarias.
- **Entorno en la Nube (Kaggle):** Para el entrenamiento exhaustivo a gran escala, se recurrió a un entorno multi-GPU compuesto por dos tarjetas **NVIDIA Tesla T4** de 15 GB de VRAM cada una.

El principal cuello de botella radicó en el consumo de memoria gráfica. La arquitectura propuesta procesa simultáneamente un bloque convolucional y un *Vision Transformer*, los cuales deben almacenar sus respectivos mapas de activaciones y gradientes durante el paso

hacia atrás (*backward pass*). Al intentar procesar tamaños de lote (*batch sizes*) de 128 o 256 imágenes, la red saturaba la capacidad gráfica, provocando errores de tipo *CUDA Out of Memory* (OOM).

Adicionalmente, el trasiego de imágenes de alta resolución desde el disco hacia la GPU corría el riesgo de generar un cuello de botella de entrada/salida (E/S). Esto se mitigó mediante el uso de discos de estado sólido **NVMe** y el uso de múltiples hilos de lectura (*DataLoaders workers*). La solución técnica para sortear la limitación de VRAM —basada en la Acumulación de Gradientes (*Gradient Accumulation*) y la Precisión Mixta Automática (*AMP*)— será detallada en el Capítulo 8.

5.7 Reproducibilidad y control de versiones

5.7.1 Fijación de semillas aleatorias (Seed locking)

5.7.2 Registro de métricas y *Logs*

Capítulo 6

Ingeniería y Preprocesamiento de los Datos

6.1 Introducción al preprocesamiento

La validez de cualquier sistema de diagnóstico asistido por computadora (*Computer-Aided Diagnosis*) basado en aprendizaje profundo depende, en última instancia, de la integridad y representatividad de los datos de entrenamiento. En dermatología, el desafío es doble: por un lado, existe un desbalance natural entre lesiones benignas y malignas; por otro, la captura de datos médicos suele estar sujeta a variabilidades técnicas que pueden introducir correlaciones espurias o sesgos.

Este capítulo detalla el exhaustivo proceso de ingeniería de datos llevado a cabo, desde la adquisición de la base de datos original hasta la generación de un dataset curado, transformado y particionado para garantizar un entrenamiento robusto y una evaluación exenta de *data leakage*.

6.2 Paso 1: Limpieza de Datos

La primera fase del preprocesamiento consistió en auditar la completitud de la base de datos original (552 598 imágenes y 37 columnas), tratar los valores perdidos (*Missing Values*), eliminar redundancias e inconsistencias en la identificación de los pacientes.

6.2.1 Tratamiento de Identificadores y Lógica de `master_id`

El rastreo de los pacientes es un aspecto crítico en el análisis de imágenes médicas para garantizar que las particiones de entrenamiento y evaluación sean completamente independientes (*Patient-Level Split*). Tras realizar la auditoría forense sobre los 552 598 identificadores de imágenes originales (`isic_id`), se detectaron inconsistencias severas en las columnas de seguimiento (`patient_id` y `lesion_id`):

- **Registros Completos (14.6 %):** Un total de 80 612 imágenes poseían simultáneamente `patient_id` y `lesion_id`. En estos casos, se priorizó el `patient_id` como clave principal para agrupar todas las lesiones de un mismo individuo.

- **Pacientes sin lesión definida (71.5 %):** 395 154 imágenes presentaban `patient_id` pero carecían de `lesion_id`. Dado que se conocía al individuo, se utilizó directamente el `patient_id` como clave de agrupación.
- **Lesiones sin paciente asignado (8.2 %):** 45 249 imágenes tenían `lesion_id` pero no `patient_id`. En este escenario, la lesión en sí misma se trató como un grupo clínico aislado y se empleó su `lesion_id` como clave.
- **El "Limbo Clínico"(5.7 %):** Se identificaron 31 583 imágenes (casi el 6 % del dataset) que carecían de ambos identificadores. Ante la imposibilidad de garantizar la trazabilidad de estas muestras y el alto riesgo de provocar fugas de datos (*Data Leakage*) en etapas posteriores, **estos registros fueron eliminados permanentemente**.

Para unificar esta disparidad en una estructura hermética, se programó la generación de la columna algorítmica **`master_id`**, la cual actúa como la única variable de control para agrupar datos según las reglas de priorización descritas.

6.2.2 Análisis de Valores Nulos (NaN) y Taxonomía en Cascada

La auditoría también reveló un volumen crítico de valores perdidos en los metadatos. Se observó que múltiples columnas presentaban más del 90 % de nulos (ej., `mel_mitotic_index`: 99.97 %, `mel_thick_mm`: 99.84 %).

En cuanto a las columnas de diagnóstico principal, se observó que el etiquetado médico seguía una lógica de **clasificación en cascada**: los facultativos catalogan la lesión desde términos generales a específicos. Al cruzar las columnas `diagnosis_1`, `diagnosis_2` y `diagnosis_3`, se comprobó que si un nivel superior presentaba un valor nulo (NaN) o el término Ïndeterminate"(3 314 casos, un 0.60 % del total), los subniveles descendentes arrastraban ese vacío.

En consecuencia, los registros con información diagnóstica faltante o clasificados como Ïndeterminate"fueron suprimidos para asegurar que la red neuronal solo asimile *Ground Truth* validado clínicamente.

6.2.3 Verificación de Duplicados

Finalmente, se ejecutó una comprobación automatizada sobre el subconjunto restante. El análisis de integridad certificó que existían **0 filas idénticas** en su totalidad y **0 identificadores de imagen duplicados**, asegurando que ninguna muestra inflaría artificialmente el rendimiento del modelo durante el entrenamiento.

6.3 Paso 2: Integración de Datos

La integración de datos implicó armonizar la inmensa disparidad de nomenclaturas patológicas del dataset original para diseñar un sistema objetivo, clínicamente coherente y viable para el aprendizaje profundo multitarea.

6.3.1 Análisis del Catálogo Diagnóstico Original

La auditoría del dataset reveló que la clasificación original estaba fragmentada en cinco niveles de profundidad (`diagnosis_1` a `diagnosis_5`).

- El nivel `diagnosis_1` ofrecía una visión puramente binaria (90.96 % Benigno, 4.91 % Maligno).
- El nivel `diagnosis_2` separaba por linaje celular (ej. proliferaciones melanocíticas frente a epiteliales).
- Los niveles `diagnosis_3`, `diagnosis_4` y `diagnosis_5` contenían un catálogo exhaustivo con docenas de patologías y sus respectivos subtipos histopatológicos (ej. Melanoma in situ, Melanoma nodular, Nevus de Spitz, Nevus displásico, etc.).

Entrenar una red neuronal para predecir docenas de subtipos histológicos (como diferenciar un Nevus de Clark de un Nevus de Reed) a partir de imágenes macroscópicas es clínicamente inviable e introduce un ruido matemático severo debido a la escasez de muestras en las clases minoritarias. Por tanto, se hizo imprescindible un proceso de fusión de clases (*Class Mapping*).

6.3.2 Armonización Taxonómica: El Sistema de 6 Clases (Head B)

Se analizaron todas las subcategorías y se agruparon en 6 clases maestras basándose en su comportamiento biológico, su apariencia visual y la decisión clínica subyacente. Esta agrupación define la salida multiclase del modelo (**Head B**):

1. **[0] Nevus (NV) – 37 197 muestras:** Se agruparon aquí todas las proliferaciones melanocíticas benignas. Esto incluye el término genérico "Nevus.ªsí como todos sus subtipos descritos en los niveles 4 y 5 (*Nevus displásico, atípico, de Spitz, de Reed, dérmico, congénito, etc.*). **Justificación clínica:** Independientemente de su subtipo histológico, todos los nevus son lunares benignos cuyo manejo clínico es la simple observación rutinaria.
2. **[1] Melanoma (MEL) – 10 245 muestras:** Se fusionaron todos los estadios y variantes del cáncer melanocítico (*Melanoma in situ, invasivo, lentigo maligno, diseminación superficial, nodular, etc.*). **Justificación clínica:** El melanoma es el cáncer de piel con mayor tasa de mortalidad. Agrupar todas sus variantes asegura que el modelo disponga del mayor volumen de datos posible para aprender a detectar cualquier morfología que requiera escisión quirúrgica urgente.

3. [2] **Carcinoma Basocelular (BCC) – 12 195 muestras:** Agrupa los carcinomas basocelulares (*nodular, superficial, infiltrante, esclerosante*). **Justificación clínica:** Es el cáncer de piel no melanocítico (NMSC) más común. Posee un perfil visual muy distinto al melanoma (apariencia perlada, telangiectasias), por lo que debe ser una clase independiente.
4. [3] **Carcinoma Espinocelular (SCC) – 3 018 muestras:** Incluye los carcinomas de células escamosas (*in situ, invasivo, enfermedad de Bowen*) y el queratoacantoma. **Justificación clínica:** Al igual que el BCC, es un cáncer queratinocítico, pero con mayor potencial de metástasis, requiriendo un manejo terapéutico diferenciado.
5. [4] **Queratosis Benignas (BKL) – 6 194 muestras:** Esta clase es de vital importancia algorítmica. Agrupa las queratosis seborreicas, los lentigos solares y las queratosis liquenoides. **Justificación clínica:** Estas lesiones benignas son los grandes ïmitadores"del melanoma. Suelen ser oscuras, asimétricas y con bordes irregulares, siendo la causa principal de falsos positivos en la práctica clínica. Aislar estas patologías en una clase propia obliga a la red neuronal a aprender específicamente las sutilezas visuales que las diferencian de un melanoma real.
6. [5] **Benigno Genérico (BG) – 156 087 muestras:** Esta clase actúa como un çajón de sastre"para el resto de afecciones cutáneas inocuas no melanocíticas (*Dermatofibromas, hemangiomas, cicatrices, verrugas, quistes, pólipos, etc.*). **Justificación clínica:** Estas lesiones presentan morfologías muy variadas pero comparten el mismo desenlace médico: no representan peligro para el paciente. Poseen muy pocas muestras individuales para conformar sus propias clases sin generar un desbalance extremo, por lo que su agrupación es la solución matemática óptima.

6.3.3 Arquitectura Dual (*Dual-Head*) y Triaje Clínico

Para maximizar la utilidad médica del sistema, se configuró una arquitectura de red con dos ramas de decisión simultáneas (*Multi-task Learning*):

- **Head A (Clasificación Binaria de Riesgo):** Su función es realizar un triaje primario simulando la decisión crítica de un médico generalista: *£Es peligroso o no?*. Para ello, mapea internamente las 6 clases en dos grupos absolutos:
  - **Maligno (Etiqueta 1):** Engloba las clases 1 (MEL), 2 (BCC) y 3 (SCC).
  - **Benigno (Etiqueta 0):** Engloba las clases 0 (NV), 4 (BKL) y 5 (BG).

  Esta cabeza se entrena con una función de pérdida fuertemente penalizada para evitar los falsos negativos (no dejar pasar ningún cáncer).
- **Head B (Clasificación Diagnóstica Multiclase):** Su función simula la evaluación de un dermatólogo especialista, intentando predecir la patología exacta entre las 6 clases maestras (0 a 5) descritas anteriormente.

El entrenamiento conjunto de ambas cabezas permite que la red extraiga características más robustas, forzando al modelo a aprender primero la gravedad subyacente de la lesión

antes de especificar su diagnóstico exacto.

6.4 Paso 3: Transformación de Datos

La fase de transformación tuvo como objetivo adecuar matemáticamente los datos tabulares para su ingesta por parte de la red neuronal (Perceptrón Multicapa), garantizando que las representaciones numéricas no introdujeran suposiciones falsas ni sesgos artificiales.

6.4.1 Estrategia de Imputación de Valores Faltantes

En el procesamiento tradicional de datos, es común recurrir a técnicas de imputación estadística como la sustitución por la media (para números) o por la moda (para categorías). Sin embargo, en un contexto médico, inventar datos clínicos asumiendo que un valor faltante corresponde al paciente "promedio"supone un riesgo inaceptable y altera la distribución real de la población. Por ello, se adoptaron técnicas de **imputación explícita de ausencia**:

- **Variables Numéricas (`age_approx`): Imputación por Valor Centinela.**
  En lugar de rellenar las edades faltantes con la edad media del dataset (lo cual crearía un pico artificial en la distribución de edades y engañaría al modelo), se imputó el valor `-1.0`. Este valor actúa como un çentinela.º ancla fuera de la distribución natural. Al introducir este valor extremo, la red neuronal aprende que el `-1.0` no representa a un paciente que no ha nacido, sino que representa un patrón matemático distinto: la *ausencia de información*. Esto permite al modelo ajustar sus pesos para tomar decisiones basándose en el resto de variables cuando la edad es desconocida, sin ser engañado por una edad media ficticia.
- **Variables Categóricas (`sex`, `anatom_site_general`): Categoría `unknown`.**
  Del mismo modo, imputar un sexo faltante con la moda (por ejemplo, "masculino"si es la clase mayoritaria) introduce un sesgo de género directo en el paciente. La técnica óptima empleada fue crear e imputar la etiqueta explícita **`unknown`**. Al tratar la falta de datos como una categoría válida y separada, se respeta la incertidumbre clínica real y el modelo aprende a calibrar sus predicciones cuando ignora la localización anatómica o el sexo del individuo.

6.4.2 Codificación Categórica: *One-Hot Encoding* (OHE)

Las redes neuronales solo comprenden vectores numéricos. Una práctica ineficiente (y a menudo errónea) es aplicar *Label Encoding*, que asigna un número entero a cada categoría (ej. Cabeza = 1, Torso = 2, Piernas = 3). Hacer esto forzaría a la red a asumir una relación ordinal falsa, implicando matemáticamente que las Piernas valen "más.º son "tres veces la Cabeza", lo cual es un absurdo anatómico y biológico.

Para resolver esto, se aplicó la técnica de ***One-Hot Encoding*** **(OHE)**. Esta transformación toma cada variable categórica y genera tantas columnas nuevas como valores únicos existan. A cada fila se le asigna un 1 en la columna correspondiente y un 0 en el resto.

Ventajas de usar OHE frente a no usarlo:

1. **Ortogonalidad matemática:** Garantiza que todas las categorías sean equidistantes e independientes entre sí en el espacio vectorial. Ninguna ubicación anatómica ni sexo tiene un peso numérico superior inherente.
2. **Activación de pesos independiente:** Permite a la red neuronal (a través de los parámetros del Perceptrón Multicapa) aprender un peso (w) y un sesgo (b) completamente aislado para el "torso"frente a la çabeza", mejorando significativamente la interpretabilidad y el rendimiento del triaje.

6.4.3 Política de Escalado Numérico (Z-Score)

Para que la red neuronal converja correctamente y los gradientes no se desestabilicen, las variables numéricas (como la edad) deben ser estandarizadas mediante normalización *Z-score* ($z = \frac{x-\mu}{\sigma}$).

Sin embargo, se determinó metodológicamente que esta normalización **no debe realizarse de forma global** (*offline*) sobre la totalidad del dataset antes de la partición. Si se calculara la media (μ) y la desviación estándar (σ) usando todos los datos, la información de las edades del conjunto de prueba (*Test Set*) çontaminaría.[el] conjunto de entrenamiento, incurriendo en un sutil pero peligroso *Data Leakage*.

Por consiguiente, el escalado se difirió a la etapa de entrenamiento: el *Z-score* se calcula y se aplica dinámicamente, extrayendo la media y la desviación estándar de forma estricta y exclusiva del subconjunto de entrenamiento correspondiente a cada *fold* de la validación cruzada.

6.5 Paso 4: Reducción de Datos y Muestreo

6.5.1 Análisis Forense de Sesgos de Adquisición

Para garantizar la capacidad de generalización del modelo, se realizó un análisis cruzado entre todos los metadatos y las etiquetas diagnósticas buscando correlaciones espurias. El hallazgo más crítico de la auditoría fue el descubrimiento de un severo **sesgo instrumental** ligado a la variable `image_type` (tipo de fotografía).

La base de datos original (552 598 imágenes) presentaba la siguiente distribución instrumental:

- **Fotografía de cuerpo entero (*TBP tile: close-up*):** 401 059 imágenes. De estas, el **99.9 % (400 552)** eran lesiones benignas, y apenas un 0.1 % (393) eran malignas.

- **Dermatoscopía digital (*dermoscopic*):** 124 752 imágenes. Aquí se concentraba la gran mayoría de los cánceres, con **21 620 lesiones malignas** (17.3 %) frente a 98 745 benignas (79.2 %).
- **Fotografía clínica macroscópica (*clinical: close-up*):** 9 316 imágenes, con una altísima prevalencia de malignidad (4 787 malignas, 51.4 %).

6.5.2 El problema de la Red Perezosaz el Efecto *Clever Hans*

Las imágenes dermatoscópicas presentan artefactos visuales muy característicos, como bordes negros circulares, esquinas oscurecidas o marcas de gel de inmersión, ausentes en las fotografías TBP. Si la red neuronal se entrenase con la distribución original en bruto, se convertiría en una **red perezosa"** (*lazy network*). En lugar de aprender los intrincados patrones morfológicos del cáncer (asimetría, bordes, estructuras reticulares), la red optimizaría su función de pérdida aprendiendo a distinguir el tipo de cámara: si detecta un borde negro (dermatoscopio) sube la probabilidad de malignidad, y si ve piel limpia (TBP) asume que es benigno.

Este fenómeno, conocido como el **efecto *Clever Hans***, ya fue corroborado en iteraciones previas de modelos dermatológicos. Al aplicar técnicas de interpretabilidad visual como **Grad-CAM** (Mapas de Activación de Clase ponderados por Gradiente), se observó empíricamente que los mapas de calor (*heatmaps*) de la red no se centraban en la lesión cutánea, sino que se activaban intensamente en las esquinas negras del dermatoscopio.

Una posible solución técnica sería aplicar un *Data Augmentation* extremadamente agresivo (recortes severos, enmascaramiento de bordes, transformaciones elásticas extremas) para destruir los artefactos del dermatoscopio. Sin embargo, esta es una solución destructiva que elimina el contexto periférico de la lesión y altera la escala real de los lunares. La solución metodológicamente correcta debe aplicarse en la raíz: el balanceo representativo de los datos.

6.5.3 Estrategia de Muestreo Estratificado (227k Imágenes)

Para forzar al modelo a extraer características intrínsecas de las lesiones, es imperativo mostrarle tanto ejemplos benignos como malignos procedentes de todos los dominios instrumentales. En lugar de utilizar exclusivamente imágenes dermatoscópicas (lo que limitaría el modelo a un solo tipo de hardware), se diseñó un muestreo estratégico para conformar un corpus robusto de aproximadamente **227 000 imágenes**:

1. **Bloque Dermatoscópico (Homogeneidad de dominio):** Se seleccionaron ∼20 000 imágenes malignas dermatoscópicas (prácticamente la totalidad disponible). Para balancear este dominio, se emparejaron con ∼86 000 imágenes benignas tomadas exactamente con el mismo tipo de dermatoscopio. Así, la red aprende que el borde negro no es sinónimo de cáncer.

2. **Bloque TBP/Clínico (Compensación y Diversidad):** Dado que la tecnología TBP representa el futuro del cribado dermatológico, se retuvo un volumen masivo de ∼110 000 imágenes benignas de este formato. Para evitar que la red asocie TBP exclusivamente a benignidad, se inyectó la totalidad de las ∼7 000 imágenes malignas restantes procedentes de fotografías clínicas y TBP.

Esta técnica de reducción y balanceo garantiza un conjunto de datos **agnóstico al dispositivo de captura**. Una vez completado este muestreo, la columna `image_type` fue eliminada definitivamente del archivo de metadatos, garantizando que el algoritmo carezca de atajos matemáticos y se vea obligado a basar sus predicciones diagnósticas única y exclusivamente en la morfología de la lesión y la fisiología del paciente.

6.6 Preprocesamiento Vectorial de Imágenes (*Offline*)

6.6.1 Estandarización de la rama RGB

6.6.2 Transformación geométrica: Generación de la rama ARP

6.7 Partición del Dataset y Estrategia de Evaluación

La fase final del preprocesamiento fue la división del dataset en una proporción 85/15:

- **Test Set (15 %):** Un conjunto ciego de pacientes extraído mediante **`GroupShuffleSplit`** basado en el `master_id`. Esto asegura que todas las imágenes de un mismo paciente estén exclusivamente en un conjunto, imposibilitando que el modelo memorice características individuales de la piel.
- **Training/Val Set (85 %):** Destinado al desarrollo del modelo, donde se aplicará una técnica de **`StratifiedGroupKFold`** para la validación cruzada.

Tras este proceso, las columnas finales que alimentarán el sistema son: `isic_id`, `patient_id`, `lesion_id`, `master_id`, `age_approx`, `target`, y las variantes vectorizadas de `sex` y `anatom_site_general`.

Capítulo 7

Métricas de evaluación y ajuste de umbrales

7.1 Introducción a la evaluación en escenarios de extremo desbalanceo

7.2 La Matriz de Confusión como base evaluativa

7.2.1 Formulación binaria (Cabeza A: Triage Clínico)

7.2.2 Formulación multiclase (Cabeza B: Diagnóstico Diferencial)

7.3 Métricas de evaluación deterministas

7.3.1 La trampa de la Exactitud (*Accuracy*) en imagen médica

7.3.2 Sensibilidad (*Recall*): La métrica prioritaria

7.3.3 Especificidad y Precisión

7.4 Métricas agregadas y de promediado

7.4.1 El *F1-Score* como medida de equilibrio

7.4.2 Estrategias de promediado: *Micro* vs. *Macro F1-Score*

7.5 Evaluación probabilística de la red

7.5.1 Curva ROC (*Receiver Operating Characteristic*)

7.5.2 Área Bajo la Curva (AUC) como medida de separabilidad

7.6 Ajuste del Umbral de Decisión y Factor de Seguridad Clínico

7.7 Justificación clínica de la estrategia de evaluación final

Capítulo 8

Diseño de la Red Implementada

8.1 Arquitectura Global del Sistema de Fusión Triple

8.2 Rama 1: Percepción Clínica (Metadatos MLP)

8.2.1 Topología del Perceptrón Multicapa Compartido

8.2.2 Optimización Bayesiana (Optuna)

8.3 Rama 2: Análisis Estructural (CNN ARP)

8.3.1 Arquitectura Convolucional Personalizada

8.3.2 Sintonización de Hiperparámetros (Optuna)

8.4 Rama 3: Percepción Visual Híbrida (RGB)

8.4.1 Extracción de rasgos locales: ResNet18

8.4.2 Modelado de relaciones globales: Vision Transformer (ViT)

8.4.3 Sintonización de Hiperparámetros (Optuna)

8.5 Integración y Toma de Decisión (*Late Fusion*)

8.5.1 Concatenación de tensores multimodales

8.5.2 Topología de las Cabezas de Decisión (*Dual-Head*)

8.6 Modelado Matemático del Entrenamiento Combinado

8.6.1 Funciones de pérdida asimétricas e híbridas

8.6.2 Aprendizaje Jerárquico mediante *Differential Learning Rates*

8.7 Tácticas de Optimización y Rendimiento de Hardware

8.7.1 Regularización por *Modality Dropout*

8.7.2 Prevención de *GPU Starvation*: *Prefetch* y Múltiples *Workers*

Capítulo 9

Evaluación, resultados y discusión

9.1 Configuración experimental

9.2 Resultados obtenidos

9.3 Comparativa entre configuraciones

9.4 Impacto de la fusión multimodal

9.5 Impacto del desbalanceo

9.6 Discusión de resultados

9.7 Limitaciones del estudio

Capítulo 10

Conclusiones y trabajo futuro

10.1 Conclusiones generales

10.2 Contribuciones del trabajo

10.3 Líneas futuras de investigación

Capítulo A

Anexos

A.1 Arquitecturas completas

A.2 Hiperparámetros

A.3 Diagramas adicionales