Título del Trabajo de Fin de Grado

Nombre del Autor

17 de abril de 2026

Resumen

Abstract

Agradecimientos

Índice general

Resumen **1**

Abstract **2**

Agradecimientos **3**

1. Introducción y justificación **11**

1.1. Contexto clínico e importancia del diagnóstico precoz del cáncer de piel . . 11
1.2. Limitaciones del diagnóstico visual tradicional 11
1.3. Aplicación de la inteligencia artificial en dermatología 11
1.4. Motivación del trabajo 11
1.4.1. Justificación técnica del enfoque propuesto 11
1.4.2. Justificación académica y social del estudio 11
1.5. Objetivos del trabajo 11
1.5.1. Objetivo general 11
1.5.2. Objetivos específicos 11
1.6. Alcance y delimitaciones del trabajo 11
1.7. Organización de la memoria 11

2. Estado del arte **12**

2.1. Introducción al estado del arte en clasificación de lesiones cutáneas 13
2.2. Métodos clásicos de diagnóstico asistido por ordenador 13
2.2.1. Extracción manual de características 13
2.2.2. Clasificadores tradicionales 13
2.3. Redes neuronales convolucionales en dermatología 13
2.3.1. CNN en clasificación de imágenes médicas 13
2.3.2. CNN aplicadas a lesiones cutáneas 13
2.4. Vision Transformers en visión por computador 13
2.4.1. Fundamentos de los Transformers 13
2.4.2. Aplicaciones de ViT en imagen médica 13
2.5. Modelos híbridos CNNTransformer 13
2.5.1. Motivación del enfoque híbrido 13

2.5.2. Resultados reportados en la literatura 13
2.6. Angular Radial Partitioning en análisis de imagen 13
2.6.1. Fundamentos teóricos del ARP 13
2.6.2. Uso de ARP en reconocimiento de patrones 13
2.7. Aprendizaje multimodal en medicina 13
2.7.1. Fusión de imagen y metadatos clínicos 13
2.7.2. Estrategias de fusión temprana, tardía e intermedia 13
2.8. Problemas abiertos en el estado del arte 13
2.8.1. Desbalanceo de clases 13
2.8.2. Heterogeneidad de bases de datos 13
2.8.3. Riesgos de *data leakage* 13
2.9. Posicionamiento del presente trabajo 13

3. Descripción de los datos **14**
3.1. Introducción a las bases de datos dermatológicas 14
3.2. Base de datos SLICE-3D (ISIC 2024 Challenge Dataset) 14
3.2.1. Descripción general 14
3.2.2. Tipos de imágenes 15
3.2.3. Metadatos clínicos disponibles 15
3.3. Base de datos ISIC Archive 16
3.3.1. Descripción general 16
3.3.2. Tipos de imágenes 16
3.3.3. Metadatos clínicos disponibles 16
3.3.4. Diferencias respecto a SLICE-3D 16
3.4. Otras fuentes de datos consideradas 16
3.4.1. HAM10000 16
3.5. Análisis del desbalanceo de clases 17
3.6. Distribución de diagnósticos 17
3.7. Heterogeneidad entre fuentes de datos 17
3.8. Análisis de variables y selección de metadatos 18
3.8.1. Variables demográficas y clínicas básicas (Plan A) 18
3.8.2. Variables de morfología avanzada TBP-LV (Plan B) 18
3.8.3. Identificación de variables de riesgo: Target Leakage y Bias 18
3.9. Identificadores clínicos y prevención de *data leakage* 18
3.10. Consideraciones éticas y de uso de datos 19

4. Metodología **21**
4.1. Enfoque de la investigación: Sistema de Triaje y Diagnóstico Dual 21
4.2. Diseño Experimental y Comparativa de Escenarios 21
4.2.1. Estudio de impacto de metadatos: Plan A vs. Plan B 21

4.2.2. Análisis de granularidad diagnóstica: Regímenes de 3 y 4 clases . . 21
4.3. Paradigma de Aprendizaje Multimodal y Complementariedad 21
4.4. Estrategia de Transferencia de Conocimiento (*Transfer Learning*) 21
4.5. Metodología de Validación y Robustez 21
4.5.1. Prevención de sesgos mediante Partición por Grupos Maestros . . . 21
4.5.2. Validación Cruzada (*5-fold Cross-Validation*) 21
4.6. Criterios de Evaluación y Selección del Modelo Óptimo 21
4.7. Flujo General del Sistema (*Pipeline* de ejecución) 21

5. Entorno de desarrollo y herramientas tecnológicas 22
5.1. Lenguaje de programación 22
5.2. Framework principal de Deep Learning: PyTorch 23
5.2.1. Justificación de la elección de PyTorch 23
5.2.2. Ecosistema Torchvision y librerías asociadas 23
5.3. Herramientas de procesamiento y manipulación de datos 24
5.3.1. NumPy y Pandas 24
5.3.2. Scikit-Learn 24
5.4. Librerías de visión por computador 25
5.4.1. OpenCV y Pillow (PIL) 25
5.5. Librerías de optimización e interpretabilidad 26
5.5.1. Optimización Bayesiana con Optuna 26
5.5.2. Interpretabilidad visual con pytorch-grad-cam 26
5.6. Entorno de ejecución y recursos hardware 27
5.6.1. Configuración del entorno local 27
5.6.2. Limitaciones de VRAM y paralelización 27
5.7. Reproducibilidad y control de versiones 28
5.7.1. Fijación de semillas aleatorias (Seed locking) 28
5.7.2. Registro de métricas y *Logs* 28

6. Ingeniería y preprocesamiento de los datos 29
6.1. Introducción al preprocesamiento 29
6.2. Estrategia de fusión de bases de datos 29
6.3. Armonización de columnas y depuración de variables 29
6.4. Tratamiento de valores faltantes e imputación 29
6.5. Transformación de variables clínicas 29
6.5.1. Codificación categórica (One-Hot Encoding) 29
6.5.2. Normalización numérica 29
6.6. Preprocesamiento y generación de ramas visuales 29
6.6.1. Estandarización de la rama RGB 29
6.6.2. Transformación geométrica: Generación de la rama ARP 29

6.7. Estrategia de partición y prevención de *data leakage* 29
6.7.1. Identificadores clínicos y el *Master Group ID* 29
6.7.2. División de conjuntos de entrenamiento, validación y test 29

7. Métricas de evaluación y ajuste de umbrales 30
7.1. Introducción a la evaluación en escenarios de extremo desbalanceo 30
7.2. La Matriz de Confusión como base evaluativa 30
7.2.1. Formulación binaria (Cabeza A: Triage Clínico) 30
7.2.2. Formulación multiclase (Cabeza B: Diagnóstico Diferencial) 30
7.3. Métricas de evaluación deterministas 30
7.3.1. La trampa de la Exactitud (*Accuracy*) en imagen médica 30
7.3.2. Sensibilidad (*Recall*): La métrica prioritaria 30
7.3.3. Especificidad y Precisión 30
7.4. Métricas agregadas y de promediado 30
7.4.1. El *F1-Score* como medida de equilibrio 30
7.4.2. Estrategias de promediado: *Micro* vs. *Macro F1-Score* 30
7.5. Evaluación probabilística de la red 30
7.5.1. Curva ROC (*Receiver Operating Characteristic*) 30
7.5.2. Área Bajo la Curva (AUC) como medida de separabilidad 30
7.6. Ajuste del Umbral de Decisión y Factor de Seguridad Clínico 30
7.7. Justificación clínica de la estrategia de evaluación final 30

8. Diseño de la Red Implementada 31
8.1. Arquitectura Global del Sistema de Fusión Triple 31
8.2. Rama Visual Híbrida: Extractor RGB (CNN-ViT) 31
8.2.1. Módulo Convolucional: ResNet18 como extractor de rasgos locales . 31
8.2.2. Módulo de Atención: Vision Transformer para relaciones globales . 31
8.3. Rama de Análisis Estructural: Red Convolucional ARP 31
8.4. Rama de Percepción Clínica: Perceptrón Multicapa (MLP) 31
8.5. Integración y Toma de Decisión: *Late Fusion* 31
8.5.1. Topología de las Cabezas de Decisión (Dual-Head) 31
8.6. Modelado Matemático del Entrenamiento 31
8.6.1. Optimización frente al desbalanceo: *Focal Loss* 31
8.6.2. Función de pérdida combinada y ponderación de tareas 31
8.7. Tácticas de Entrenamiento Avanzado 31
8.7.1. Protocolo *Linear Probing* y *Fine-Tuning* global 31
8.7.2. Aprendizaje Jerárquico mediante *Differential Learning Rate* 31
8.7.3. Regularización por *Modality Dropout* 31
8.7.4. Gestión de memoria y *Gradient Accumulation* 31
8.8. Optimización Bayesiana de Hiperparámetros (Optuna) 31

9. Evaluación, resultados y discusión **32**
9.1. Configuración experimental 32
9.2. Resultados obtenidos 32
9.3. Comparativa entre configuraciones 32
9.4. Impacto de la fusión multimodal 32
9.5. Impacto del desbalanceo 32
9.6. Discusión de resultados 32
9.7. Limitaciones del estudio 32

10. Conclusiones y trabajo futuro **33**
10.1. Conclusiones generales 33
10.2. Contribuciones del trabajo 33
10.3. Líneas futuras de investigación 33

A. Anexos **34**
A.1. Arquitecturas completas 34
A.2. Hiperparámetros 34
A.3. Diagramas adicionales 34

Índice de figuras

Índice de cuadros

Capítulo 1

Introducción y justificación

1.1 Contexto clínico e importancia del diagnóstico precoz del cáncer de piel

1.2 Limitaciones del diagnóstico visual tradicional

1.3 Aplicación de la inteligencia artificial en dermatología

1.4 Motivación del trabajo

1.4.1 Justificación técnica del enfoque propuesto

1.4.2 Justificación académica y social del estudio

1.5 Objetivos del trabajo

1.5.1 Objetivo general

1.5.2 Objetivos específicos

1.6 Alcance y delimitaciones del trabajo

1.7 Organización de la memoria

Capítulo 2

Estado del arte

2.1 Introducción al estado del arte en clasificación de lesiones cutáneas

2.2 Métodos clásicos de diagnóstico asistido por ordenador

2.2.1 Extracción manual de características

2.2.2 Clasificadores tradicionales

2.3 Redes neuronales convolucionales en dermatología

2.3.1 CNN en clasificación de imágenes médicas

2.3.2 CNN aplicadas a lesiones cutáneas

2.4 Vision Transformers en visión por computador

2.4.1 Fundamentos de los Transformers

2.4.2 Aplicaciones de ViT en imagen médica

2.5 Modelos híbridos CNNTransformer

2.5.1 Motivación del enfoque híbrido

2.5.2 Resultados reportados en la literatura

2.6 Angular Radial Partitioning en análisis de imagen

2.6.1 Fundamentos teóricos del ARP

2.6.2 Uso de ARP en reconocimiento de patrones

2.7 Aprendizaje multimodal en medicina

2.7.1 Fusión de imagen y metadatos clínicos

2.7.2 Estrategias de fusión temprana, tardía e intermedia

Capítulo 3

Descripción de los datos

3.1 Introducción a las bases de datos dermatológicas

El desarrollo de sistemas de diagnóstico asistido por ordenador basados en aprendizaje profundo depende de manera crítica de la calidad, validez y representatividad de las bases de datos empleadas. En el ámbito de la dermatología, y en particular en el estudio del cáncer de piel, esta dependencia es aún más acusada debido a la elevada variabilidad morfológica de las lesiones cutáneas y a la baja prevalencia relativa de los casos malignos en la población general.

Para que un modelo de *deep learning* resulte clínicamente relevante, no basta con disponer de un gran volumen de imágenes. Es imprescindible que dichas imágenes estén correctamente anotadas, procedan de fuentes fiables y reflejen de forma razonable la distribución real de las patologías, evitando sesgos sistemáticos que puedan comprometer la capacidad de generalización del sistema. Asimismo, el desbalanceo extremo entre clases, habitual en bases de datos médicas, constituye uno de los principales retos metodológicos, ya que puede conducir a modelos con una alta exactitud global pero una sensibilidad reducida en las clases de mayor interés clínico.

En este contexto, el presente trabajo se apoya en bases de datos públicas ampliamente utilizadas y validadas por la comunidad científica, que se combinan de forma controlada con el objetivo de construir un conjunto de datos robusto, multimodal y adecuado para el entrenamiento y la evaluación de arquitecturas profundas complejas.

3.2 Base de datos SLICE-3D (ISIC 2024 Challenge Dataset)

3.2.1 Descripción general

La principal fuente de datos del presente estudio es la base de datos *SLICE-3D*, proporcionada en el marco del *ISIC 2024 Challenge Dataset*. Este conjunto de datos está compuesto por un total de 401 059 imágenes en formato JPEG, lo que lo convierte en una de las colecciones públicas más extensas disponibles actualmente para el análisis

automatizado de lesiones cutáneas.

Las imágenes incluidas en SLICE-3D han sido recopiladas y anotadas siguiendo protocolos estandarizados, lo que garantiza un alto grado de consistencia y fiabilidad en las etiquetas diagnósticas asociadas. No obstante, al igual que ocurre en la práctica clínica real, la distribución de diagnósticos presenta un desbalanceo muy acusado, con una clara predominancia de lesiones benignas frente a un número considerablemente menor de casos malignos.

En concreto, el conjunto de datos contiene del orden de 400 000 lesiones benignas, mientras que el número de imágenes correspondientes a lesiones malignas es significativamente inferior, representando únicamente un pequeño porcentaje del total. Este desbalanceo refleja fielmente la epidemiología del cáncer de piel, pero introduce importantes desafíos para el entrenamiento de modelos de clasificación basados en *deep learning*, especialmente en términos de sensibilidad y capacidad de detección de las clases minoritarias.

3.2.2 Tipos de imágenes

Las imágenes de SLICE-3D proceden principalmente de sistemas de dermatoscopía digital y de plataformas de *Total Body Photography* (TBP), proporcionando imágenes de alta resolución centradas en lesiones individuales. La variabilidad en las condiciones de adquisición, los dispositivos empleados y las características visuales (iluminación, enfoque, resolución, contraste, etc.) hace que este conjunto de datos resulte especialmente adecuado para evaluar la robustez de modelos de aprendizaje profundo frente a cambios de dominio y escenarios clínicos heterogéneos.

3.2.3 Metadatos clínicos disponibles

Una característica distintiva de SLICE-3D es la disponibilidad de un conjunto amplio y detallado de metadatos clínicos, que incluye variables demográficas, información anatómica y métricas cuantitativas avanzadas derivadas de TBP (`TBP-LV`). Entre estos metadatos se encuentran, de forma general:

- variables demográficas básicas (como edad aproximada y sexo del paciente),
- localización anatómica general de la lesión,
- descriptores cuantitativos relacionados con forma, tamaño, color y asimetría de la lesión.

Estos metadatos aportan información complementaria a la imagen cruda que puede resultar de gran valor para la clasificación clínica, especialmente en contextos de cribado (*screening*) o en escenarios en los que la información puramente visual puede resultar ambigua. En el marco del enfoque multimodal propuesto en este trabajo, estas variables constituyen una fuente adicional de evidencia que puede contribuir a mejorar la capacidad discriminativa del modelo.

3.3 Base de datos ISIC Archive

3.3.1 Descripción general

La base de datos *ISIC Archive* constituye un repositorio público de gran escala que agrupa un total de 549 590 imágenes dermatológicas, correspondientes a una amplia variedad de diagnósticos y procedentes de múltiples centros y estudios internacionales.

En el presente trabajo, *ISIC Archive* no se emplea de forma íntegra, sino que se utiliza de manera selectiva y estratégica. Con el objetivo de mitigar el desbalanceo extremo presente en *SLICE-3D*, se seleccionaron 27 084 imágenes correspondientes exclusivamente a casos malignos, incluyendo melanoma, carcinoma basocelular y carcinoma espinocelular.

Esta selección permite reforzar de forma significativa la representación de las clases malignas en el conjunto de datos global, manteniendo al mismo tiempo la coherencia clínica y la fiabilidad de las etiquetas diagnósticas. De este modo, *ISIC Archive* actúa como una fuente complementaria esencial para equilibrar el conjunto de entrenamiento sin introducir ruido innecesario ni comprometer la validez de los experimentos.

3.3.2 Tipos de imágenes

3.3.3 Metadatos clínicos disponibles

3.3.4 Diferencias respecto a SLICE-3D

Las principales diferencias entre ISIC Archive e ISIC Slice 3D son:

- **Distribución de clases**: ISIC Archive contiene únicamente lesiones malignas, mientras que Slice 3D incluye mayoritariamente lesiones benignas.
- **Riqueza de metadatos**: ISIC Archive dispone de un número menor de variables clínicas y descriptivas.
- **Rol en el estudio**: ISIC Archive se emplea como fuente estratégica para incrementar la presencia de lesiones malignas y reducir el desbalanceo de clases del conjunto global.

Estas diferencias motivan la adopción de estrategias específicas de fusión y tratamiento de datos, que se describirán en capítulos posteriores.

3.4 Otras fuentes de datos consideradas

3.4.1 HAM10000

La base de datos *HAM10000* fue analizada de forma preliminar como posible fuente complementaria. Sin embargo, se decidió no integrarla en la fase principal del estudio debido a diferencias en los criterios de anotación y a la existencia de solapamientos conceptuales

con las bases ISIC, que podrían complicar la armonización de datos sin aportar un beneficio proporcional en términos de diversidad o volumen efectivo.

3.5 Análisis del desbalanceo de clases

Uno de los principales retos identificados es el desbalanceo severo entre lesiones benignas y malignas, especialmente en ISIC Archive. Mientras que las lesiones benignas superan ampliamente las 400 000 muestras, los casos malignos representan una fracción muy reducida del conjunto total.

Este desbalanceo condiciona tanto el diseño del modelo como la selección de métricas de evaluación, haciendo necesario priorizar la sensibilidad y la capacidad de detección de casos malignos frente a la mera exactitud global.

3.6 Distribución de diagnósticos

Con el fin de unificar los diagnósticos heterogéneos presentes en las distintas fuentes, se definió un espacio de clases clínicas común compuesto por las siguientes categorías:

- **BEN**: lesiones benignas (nevus y otros diagnósticos no malignos).
- **MEL**: melanoma.
- **BCC**: carcinoma basocelular.
- **SCC+**: carcinoma espinocelular y lesiones precursoras (queratosis actínica, queratoacantoma).

Esta categorización busca equilibrar la coherencia clínica con la viabilidad estadística, evitando una fragmentación excesiva de las clases que pudiera dificultar el entrenamiento y la interpretación de los modelos.

3.7 Heterogeneidad entre fuentes de datos

La combinación de múltiples bases de datos introduce heterogeneidad en términos de:

- protocolos de adquisición de imagen,
- calidad y resolución de las imágenes,
- disponibilidad y formato de los metadatos,
- criterios diagnósticos empleados por los distintos centros.

En lugar de eliminar esta heterogeneidad mediante filtrado agresivo, el presente trabajo adopta un enfoque de armonización controlada. El objetivo es preservar la máxima cantidad de información posible, al tiempo que se unifican los aspectos clave necesarios para el entrenamiento de modelos multimodales capaces de aprender patrones invariantes a las diferencias entre fuentes.

3.8 Análisis de variables y selección de metadatos

El tratamiento de los metadatos clínicos constituye un elemento central del enfoque multimodal propuesto. Dado que SLICE-3D es la única base con características avanzadas, se definieron dos configuraciones experimentales diferenciadas:

3.8.1 Variables demográficas y clínicas básicas (Plan A)

Se definen como el conjunto mínimo de información disponible en un entorno de atención primaria, garantizando la comparabilidad con fuentes antiguas como ISIC Archive. Incluye:

- `age_approx`: Edad aproximada (vulnerabilidad sistémica).
- `sex`: Sexo biológico.
- `clin_size_long_diam_mm`: Tamaño físico de la lesión.
- `anatom_site_general`: Ubicación anatómica en el cuerpo.

3.8.2 Variables de morfología avanzada TBP-LV (Plan B)

Este conjunto explota al máximo la riqueza técnica del dataset SLICE-3D, incorporando más de 30 descriptores geométricos y de color derivados de Total Body Photography:

- **Morfología**: `tbp_lv_areaMM2`, `tbp_lv_perimeterMM`, `tbp_lv_eccentricity`.
- **Color y Contraste**: `tbp_lv_color_std_mean`, `tbp_lv_deltaA/B/L`.
- **Estructura 3D**: Coordenadas espaciales `tbp_lv_x/y/z`.

3.8.3 Identificación de variables de riesgo: Target Leakage y Bias

Uno de los pasos críticos de la auditoría de datos fue identificar variables que no deben estar presentes en la inferencia:

- **Target Leakage**: Variables obtenidas tras el diagnóstico histopatológico (`mel_thick_mm`, `mel_mitotic_index`). Su uso inflaría el rendimiento de forma irreal, ya que un sistema de triaje no dispone de esta información antes de la biopsia.
- **Bias por IA externa**: La columna `tbp_lv_dnn_lesion_confidence` representa la opinión de un modelo algorítmico previo. Se descarta para garantizar que el sistema propuesto aprenda de la imagen y no herede sesgos de predicciones ajenas.

3.9 Identificadores clínicos y prevención de *data leakage*

Para garantizar la validez experimental del estudio y evitar fugas de información entre los conjuntos de entrenamiento, validación y prueba, resulta fundamental analizar en detalle la estructura de los identificadores presentes en las bases de datos empleadas.

En general, las imágenes pueden estar asociadas a distintos tipos de identificadores:

- **Patient ID**: identifica de manera única a un paciente, que puede presentar una o varias lesiones.
- **Lesion ID**: identifica una lesión concreta, que pertenece a un único paciente pero puede estar representada por múltiples imágenes.
- **Identificador de imagen**: referencia una captura específica de una lesión determinada.

Esta estructura implica que no todas las imágenes son independientes entre sí. Un mismo paciente puede presentar varias lesiones, y una misma lesión puede estar representada por múltiples imágenes, lo que da lugar a grupos de datos altamente correlacionados. Si estos grupos se reparten de forma inadecuada entre los diferentes subconjuntos, se corre el riesgo de introducir *data leakage*, inflando artificialmente las métricas de rendimiento del modelo.

Durante el análisis preliminar se observó que la existencia de pacientes con múltiples lesiones y lesiones con múltiples imágenes daba lugar a grupos de tamaño elevado, lo que dificultaba la división equilibrada del conjunto de datos manteniendo, al mismo tiempo, la independencia entre los subconjuntos de entrenamiento y validación.

Para resolver este problema, se definió un identificador unificado denominado `master_group_id`, construido siguiendo las reglas que se detallan a continuación:

1. Si **Patient ID** y **Lesion ID** están presentes, el `master_group_id` se define a partir de la combinación de ambos identificadores, de forma que todas las imágenes correspondientes a una lesión concreta de un paciente queden agrupadas.
2. Si **Patient ID** es nulo pero **Lesion ID** no lo es, se utiliza directamente el **Lesion ID** como `master_group_id`.
3. Si **Lesion ID** es nulo pero **Patient ID** está disponible, se utiliza el **Patient ID** como `master_group_id`.
4. Si ambos identificadores son nulos, se asigna un identificador único por imagen, de modo que cada muestra forme un grupo independiente.

Este enfoque garantiza que todas las imágenes pertenecientes a un mismo paciente o a una misma lesión se asignen siempre al mismo subconjunto de datos (entrenamiento, validación o prueba), evitando *patient leakage* y asegurando una evaluación experimental rigurosa y realista del rendimiento de los modelos.

3.10 Consideraciones éticas y de uso de datos

Todas las bases de datos utilizadas en este trabajo son de acceso público y han sido anonimizadas por sus autores originales. No se dispone de información identificable de pacientes y el uso de los datos se realiza exclusivamente con fines académicos y de investigación, respetando las licencias y condiciones de uso establecidas por ISIC y por los repositorios correspondientes.

Además, se han adoptado medidas específicas para prevenir fugas de información entre

los conjuntos de entrenamiento, validación y prueba. En particular, se ha prestado especial atención a la separación de imágenes pertenecientes a un mismo paciente, con el objetivo de garantizar la validez experimental de los resultados y evitar una sobreestimación artificial del rendimiento de los modelos.

Capítulo 4

Metodología

4.1 Enfoque de la investigación: Sistema de Triaje y Diagnóstico Dual

4.2 Diseño Experimental y Comparativa de Escenarios

4.2.1 Estudio de impacto de metadatos: Plan A vs. Plan B

4.2.2 Análisis de granularidad diagnóstica: Regímenes de 3 y 4 clases

4.3 Paradigma de Aprendizaje Multimodal y Complementariedad

4.4 Estrategia de Transferencia de Conocimiento (*Transfer Learning*)

4.5 Metodología de Validación y Robustez

4.5.1 Prevención de sesgos mediante Partición por Grupos Maestros

4.5.2 Validación Cruzada (*5-fold Cross-Validation*)

4.6 Criterios de Evaluación y Selección del Modelo Óptimo

4.7 Flujo General del Sistema (*Pipeline* de ejecución)

Capítulo 5

Entorno de desarrollo y herramientas tecnológicas

En este capítulo se detallan las herramientas hardware y software seleccionadas para la consecución de los objetivos del proyecto, justificando su elección en base a los requisitos de flexibilidad y rendimiento computacional exigidos por el procesamiento de imágenes médicas.

5.1 Lenguaje de programación

El desarrollo íntegro de este Trabajo de Fin de Grado se ha llevado a cabo utilizando **Python** (en su versión 3.x) como lenguaje de programación principal. La elección de Python no es arbitraria, sino que responde a su consolidación como el estándar *de facto* en la industria y en la comunidad investigadora dentro de los campos de la Inteligencia Artificial, el Aprendizaje Automático (*Machine Learning*) y el Aprendizaje Profundo (*Deep Learning*).

La principal ventaja que ofrece Python frente a lenguajes compilados de más bajo nivel (como C++ o Java) es su sintaxis clara y legible, la cual permite una abstracción total de la gestión de memoria y otorga al desarrollador la capacidad de centrarse enteramente en el diseño lógico y matemático de los algoritmos. Además, su naturaleza multiparadigma soportando programación orientada a objetos y programación funcional resulta ideal para estructurar proyectos de experimentación científica iterativa.

Sin embargo, el factor decisivo para su implementación en este trabajo es su inmenso y maduro ecosistema de librerías científicas. Python actúa como un lenguaje *"pegamento"* (*glue language*), lo que significa que, aunque el código se escriba con una sintaxis de alto nivel, las operaciones matemáticas subyacentes más costosas son ejecutadas en el *backend* mediante rutinas compiladas en C o C++, garantizando un rendimiento óptimo al procesar cientos de miles de imágenes médicas.

5.2 Framework principal de Deep Learning: PyTorch

Para la construcción, entrenamiento y evaluación de las redes neuronales, se ha optado por utilizar **PyTorch**, un marco de trabajo (*framework*) de código abierto desarrollado originalmente por el laboratorio de investigación en inteligencia artificial de Meta (FAIR).

5.2.1 Justificación de la elección de PyTorch

Aunque existen otras alternativas populares en la industria, como TensorFlow o Keras, la naturaleza específica de este proyecto exigía un *framework* que ofreciera el máximo nivel de flexibilidad y control a bajo nivel sobre la arquitectura de la red. PyTorch fue seleccionado por dos razones arquitectónicas fundamentales:

1. **El paradigma del Grafo Computacional Dinámico (*Define-by-Run*):** A diferencia de otros *frameworks* que exigen compilar un grafo estático antes de que fluyan los datos, PyTorch construye el grafo computacional sobre la marcha en cada iteración (*forward pass*). Esta característica resulta indispensable cuando se diseñan arquitecturas a medida que no siguen un flujo lineal tradicional. En el caso de este trabajo, el modelo propuesto (`HybridViTCNN`) fusiona las extracciones de características de dos paradigmas radicalmente distintos: una Red Neuronal Convolucional (CNN) y un *Vision Transformer* (ViT). Manejar la concatenación de estos tensores de diferente naturaleza geométrica es un proceso mucho más natural bajo un paradigma dinámico.
2. **Naturaleza "Pythónica" y depuración (*Debugging*):** PyTorch se integra de manera nativa con las herramientas de depuración de Python. Al trabajar con tensores directamente, es posible inspeccionar el valor numérico exacto de una activación o un gradiente en cualquier capa intermedia de la red. Esta transparencia ha sido crucial para diagnosticar problemas complejos durante el desarrollo, como la explosión de gradientes o la inspección de mapas de características para los algoritmos de interpretabilidad visual (Grad-CAM), permitiendo abrir la "caja negra" del modelo híbrido.

5.2.2 Ecosistema Torchvision y librerías asociadas

Uno de los pilares que sustentan a PyTorch es el paquete auxiliar `torchvision`, diseñado específicamente para resolver problemas de visión por computador. En este proyecto, su uso se ha centrado en dos tareas fundamentales:

- **Transfer Learning y extracción de pesos preentrenados:** Mediante `torchvision.models`, se ha instanciado la rama convolucional del modelo cargando una arquitectura *ResNet18* preentrenada con los pesos óptimos del desafío ImageNet1K. De manera análoga y complementaria, se integró la librería especializada `timm` (*PyTorch Image*

Models) para instanciar la rama atencional de la red, cargando los pesos de un *Vision Transformer* (`ViT-Tiny`).

- **Transformaciones y Aumento de Datos (*Data Augmentation*):** El módulo `torchvision.transforms` ha sido el motor encargado de procesar los lotes de imágenes en tiempo real. Permitió aplicar perturbaciones estocásticas (`RandomHorizontalFlip`, `ColorJitter`, `ElasticTransform`) durante el entrenamiento para actuar como un poderoso método de regularización, mitigando el sobreajuste y combatiendo los sesgos intrínsecos de los dispositivos de adquisición de las bases de datos.

5.3 Herramientas de procesamiento y manipulación de datos

El ecosistema de Python para ciencia de datos ha sido la columna vertebral del preprocesamiento y estructuración de la información clínica antes de su ingesta en las redes neuronales.

5.3.1 NumPy y Pandas

Para la manipulación de datos tabulares y metadatos clínicos, se ha recurrido a la combinación de las librerías `Pandas` y `NumPy`.

`Pandas` ha sido la herramienta fundamental para realizar la carga, limpieza y fusión (mediante operaciones *merge* y *concat*) de las múltiples bases de datos originadas tanto en repositorios históricos (ISIC Archive) como modernos (SLICE-3D). Su uso fue crítico para la limpieza de valores nulos, la imputación de datos faltantes —utilizando valores sentinela como -1— y, de manera muy especial, para la creación del identificador sintético *Master Group ID*. Este identificador, generado a partir de condiciones lógicas jerárquicas (priorizando el ID del paciente sobre el de la lesión), permitió consolidar el historial clínico y evitar colisiones de datos.

Por su parte, `NumPy` se utilizó para las transformaciones matriciales de bajo nivel y la vectorización de operaciones matemáticas. Funciones como `np.where` facilitaron la ejecución de lógica condicional rápida sobre conjuntos de más de 400.000 registros, mientras que las operaciones de apilamiento de matrices (`np.hstack`) permitieron ensamblar eficientemente las características numéricas y categóricas en un único tensor de entrada para alimentar la rama tabular del modelo (Perceptrón Multicapa).

5.3.2 Scikit-Learn

`Scikit-Learn` es el estándar *de facto* en el aprendizaje automático clásico, y en el marco de este proyecto de *Deep Learning* ha desempeñado un papel auxiliar indispensable para preparar el terreno de los datos y auditar los resultados. En concreto, se ha hecho un uso exhaustivo de sus módulos de preprocesamiento, partición y evaluación:

- **Normalización y Codificación:** Se empleó `StandardScaler` para aplicar una estandarización *Z-score* a las variables clínicas y geométricas numéricas (como la edad o el área de la lesión), garantizando que las magnitudes dispares no desestabilizaran los gradientes de la red neuronal. Paralelamente, se utilizó `OneHotEncoder` para transformar variables categóricas (como el sexo o la ubicación anatómica) en vectores binarios ortogonales.
- **Prevención de Fuga de Datos (*Data Leakage*):** Se implementó la clase `StratifiedGroupKFold` para generar las particiones de la validación cruzada. Esta herramienta matemática fue vital para asegurar dos condiciones simultáneamente: que la distribución fuertemente desbalanceada de clases de cáncer se mantuviera constante en cada partición (estratificación), y que todas las imágenes asociadas a un mismo *Master Group ID* recayeran de forma íntegra en el mismo subconjunto. Esto último previno de forma absoluta que el modelo memorizara anomalías sistémicas de un paciente concreto durante el entrenamiento.
- **Cálculo de Métricas Clínicas:** Los módulos de `sklearn.metrics` se integraron en el bucle nativo de PyTorch para evaluar el rendimiento del modelo en tiempo de ejecución. Permitió calcular de forma robusta métricas clínicas complejas como el Área Bajo la Curva ROC (AUC), el *F1-Score* macro, la sensibilidad (*Recall*) específica para el melanoma y la matriz de confusión multiclase.

5.4 Librerías de visión por computador

El preprocesamiento de imágenes dermatoscópicas, paso previo ineludible a la extracción de características profundas, se apoyó en dos de las librerías más consolidadas en el campo de la visión por computador.

5.4.1 OpenCV y Pillow (PIL)

La librería **Pillow (PIL)** se utilizó nativamente dentro de las clases de iteración de datos de PyTorch (`Dataset`). PIL destaca por su eficiencia y rapidez al decodificar archivos de imagen en formato RGB desde el disco de estado sólido, integrándose a la perfección con la cadena de transformaciones estocásticas (*Data Augmentation*) definida en el entrenamiento.

Por otro lado, **OpenCV** (*Open Source Computer Vision Library*) se erigió como el motor matemático crítico para la ingeniería de características visuales. Dada la variabilidad en la iluminación, los bordes artificiales (viñetas del dermatoscopio) y la presencia de artefactos clínicos (como reglas de medición o vello) en las imágenes originales, se empleó OpenCV para generar una representación alternativa de las lesiones: la transformada *Adaptive Radial Polar* (ARP).

Mediante funciones de conversión de espacios de color y la aplicación algorítmica de

proyecciones log-polares (`cv2.linearPolar`), OpenCV permitió desenrollar geométricamente la lesión, aislando su estructura morfológica y la asimetría de los bordes frente al ruido de adquisición. Esto fue determinante para alimentar una rama específica de la red neuronal, forzándola a ignorar el sesgo de la cámara (efecto *Clever Hans*) y centrarse en la patología.

5.5 Librerías de optimización e interpretabilidad

El entrenamiento de arquitecturas de aprendizaje profundo no solo requiere la definición de la red, sino también la búsqueda eficiente de sus hiperparámetros óptimos y la posterior auditoría clínica de sus decisiones. Para cubrir estas necesidades, se integraron herramientas avanzadas de optimización e Inteligencia Artificial Explicable (XAI).

5.5.1 Optimización Bayesiana con Optuna

La búsqueda de hiperparámetros óptimos es uno de los mayores desafíos computacionales en el entrenamiento de redes neuronales profundas. Tradicionalmente, se han utilizado enfoques de fuerza bruta como la búsqueda en cuadrícula (*Grid Search*). Sin embargo, dada la magnitud de los datos de este estudio y el coste temporal de entrenar la arquitectura `HybridViTCNN`, explorar todas las combinaciones posibles resultaba computacionalmente inasumible.

Para solventar esta limitación, se implementó el *framework* `Optuna`, el cual emplea algoritmos de Optimización Bayesiana —específicamente el estimador TPE (*Tree-structured Parzen Estimator*)—. A diferencia de la búsqueda aleatoria o en cuadrícula, `Optuna` utiliza el historial de los experimentos previos para predecir probabilísticamente qué zonas del espacio de hiperparámetros tienen mayor potencial de mejorar el modelo, convergiendo a la solución óptima en una fracción del tiempo.

En este trabajo, `Optuna` fue fundamental para sintonizar el *Learning Rate*, el decaimiento de pesos (*Weight Decay*) y, de forma crítica, el parámetro γ (gamma) de la función de coste *Focal Loss*, esencial para calibrar la penalización ante el fuerte desbalanceo clínico de las clases.

5.5.2 Interpretabilidad visual con pytorch-grad-cam

Uno de los principales impedimentos para la adopción clínica de los modelos de *Deep Learning* es su naturaleza de "caja negra" (*black-box*). Un modelo puede arrojar excelentes métricas de validación por los motivos equivocados, aprendiendo atajos estadísticos en lugar de características anatómicas reales.

Para dotar al modelo de explicabilidad clínica, se integró la librería `pytorch-grad-cam`. Esta herramienta implementa el algoritmo *Grad-CAM* (*Gradient-weighted Class Activation*

Mapping), el cual utiliza los gradientes que fluyen hacia la última capa convolucional de la red —en este caso, el bloque de extracción de la arquitectura *ResNet18*— para generar un mapa de calor que resalta las regiones espaciales de la imagen que mayor impacto tuvieron en la decisión final.

El uso de esta librería resultó de incalculable valor durante la fase forense del proyecto para identificar fugas de información (*Target Leakage*) y diagnosticar el conocido efecto *Clever Hans* o sesgo de dominio. Como se analizará en la memoria, los mapas de calor permitieron descubrir que, antes de aplicar técnicas de regularización geométricas, el modelo ignoraba la lesión cutánea y basaba su diagnóstico maligno en artefactos visuales de los dispositivos de adquisición (como viñetas oscuras de dermatoscopios antiguos o marcas de tinta quirúrgica).

5.6 Entorno de ejecución y recursos hardware

El entrenamiento de modelos híbridos que fusionan tensores de distinta naturaleza sobre cientos de miles de imágenes exige una orquestación precisa de los recursos de *hardware* y *software*.

5.6.1 Configuración del entorno local

Como Entorno de Desarrollo Integrado (IDE) principal se utilizó **Visual Studio Code** (VS Code). Su elección se fundamenta en su robusta integración con Python, su capacidad para ejecutar y depurar *Jupyter Notebooks* de forma nativa, y su versatilidad para gestionar entornos virtuales aislados.

5.6.2 Limitaciones de VRAM y paralelización

El desarrollo del proyecto se enfrentó a un desafío de infraestructura significativo, dividiéndose la ejecución en dos entornos distintos:

- **Entorno Local (Estación de trabajo):** Equipado con un procesador de alto rendimiento y 32 GB de memoria RAM de sistema, pero limitado por una unidad de procesamiento gráfico (GPU) NVIDIA de 6 GB de VRAM. Este entorno se utilizó para la limpieza de datos tabulares, ingeniería de características, análisis forense y pruebas unitarias.
- **Entorno en la Nube (Kaggle):** Para el entrenamiento exhaustivo a gran escala, se recurrió a un entorno multi-GPU compuesto por dos tarjetas **NVIDIA Tesla T4** de 15 GB de VRAM cada una.

El principal cuello de botella radicó en el consumo de memoria gráfica. La arquitectura propuesta procesa simultáneamente un bloque convolucional y un *Vision Transformer*, los cuales deben almacenar sus respectivos mapas de activaciones y gradientes durante el paso

hacia atrás (*backward pass*). Al intentar procesar tamaños de lote (*batch sizes*) de 128 o 256 imágenes, la red saturaba la capacidad gráfica, provocando errores de tipo *CUDA Out of Memory* (OOM).

Adicionalmente, el trasiego de imágenes de alta resolución desde el disco hacia la GPU corría el riesgo de generar un cuello de botella de entrada/salida (E/S). Esto se mitigó mediante el uso de discos de estado sólido **NVMe** y el uso de múltiples hilos de lectura (*DataLoaders workers*). La solución técnica para sortear la limitación de VRAM —basada en la Acumulación de Gradientes (*Gradient Accumulation*) y la Precisión Mixta Automática (*AMP*)— será detallada en el Capítulo 8.

5.7 Reproducibilidad y control de versiones

5.7.1 Fijación de semillas aleatorias (Seed locking)

5.7.2 Registro de métricas y *Logs*

Capítulo 6

Ingeniería y preprocesamiento de los datos

6.1 Introducción al preprocesamiento

6.2 Estrategia de fusión de bases de datos

6.3 Armonización de columnas y depuración de variables

6.4 Tratamiento de valores faltantes e imputación

6.5 Transformación de variables clínicas

6.5.1 Codificación categórica (One-Hot Encoding)

6.5.2 Normalización numérica

6.6 Preprocesamiento y generación de ramas visuales

6.6.1 Estandarización de la rama RGB

Menciona cómo esto redujo drásticamente el peso del dataset en disco y permitió que las transformaciones Online se limitaran únicamente a operaciones de bajo coste (giros, brillos), disparando la velocidad de lectura.

6.6.2 Transformación geométrica: Generación de la rama ARP

6.7 Estrategia de partición y prevención de *data leakage*

6.7.1 Identificadores clínicos y el *Master Group ID*

6.7.2 División de conjuntos de entrenamiento, validación y test

Capítulo 7

Métricas de evaluación y ajuste de umbrales

7.1 Introducción a la evaluación en escenarios de extremo desbalanceo

7.2 La Matriz de Confusión como base evaluativa

7.2.1 Formulación binaria (Cabeza A: Triage Clínico)

7.2.2 Formulación multiclase (Cabeza B: Diagnóstico Diferencial)

7.3 Métricas de evaluación deterministas

7.3.1 La trampa de la Exactitud (*Accuracy*) en imagen médica

7.3.2 Sensibilidad (*Recall*): La métrica prioritaria

7.3.3 Especificidad y Precisión

7.4 Métricas agregadas y de promediado

7.4.1 El *F1-Score* como medida de equilibrio

7.4.2 Estrategias de promediado: *Micro* vs. *Macro F1-Score*

7.5 Evaluación probabilística de la red

7.5.1 Curva ROC (*Receiver Operating Characteristic*)

7.5.2 Área Bajo la Curva (AUC) como medida de separabilidad

7.6 Ajuste del Umbral de Decisión y Factor de Seguridad Clínico

7.7 Justificación clínica de la estrategia de evaluación final

Capítulo 8

Diseño de la Red Implementada

8.1 Arquitectura Global del Sistema de Fusión Triple

8.2 Rama Visual Híbrida: Extractor RGB (CNN-ViT)

8.2.1 Módulo Convolucional: ResNet18 como extractor de rasgos locales

8.2.2 Módulo de Atención: Vision Transformer para relaciones globales

8.3 Rama de Análisis Estructural: Red Convolucional ARP

8.4 Rama de Percepción Clínica: Perceptrón Multicapa (MLP)

8.5 Integración y Toma de Decisión: *Late Fusion*

8.5.1 Topología de las Cabezas de Decisión (Dual-Head)

8.6 Modelado Matemático del Entrenamiento

8.6.1 Optimización frente al desbalanceo: *Focal Loss*

8.6.2 Función de pérdida combinada y ponderación de tareas

8.7 Tácticas de Entrenamiento Avanzado

8.7.1 Protocolo *Linear Probing* y *Fine-Tuning* global

8.7.2 Aprendizaje Jerárquico mediante *Differential Learning Rate*

8.7.3 Regularización por *Modality Dropout*

8.7.4 Gestión de memoria y *Gradient Accumulation*

8.8 Optimización Bayesiana de Hiperparámetros (Optuna)

Capítulo 9

Evaluación, resultados y discusión

9.1 Configuración experimental

9.2 Resultados obtenidos

9.3 Comparativa entre configuraciones

9.4 Impacto de la fusión multimodal

9.5 Impacto del desbalanceo

9.6 Discusión de resultados

9.7 Limitaciones del estudio

Capítulo 10

Conclusiones y trabajo futuro

10.1 Conclusiones generales

10.2 Contribuciones del trabajo

10.3 Líneas futuras de investigación

Capítulo A

Anexos

A.1 Arquitecturas completas

A.2 Hiperparámetros

A.3 Diagramas adicionales